

APS-LSTM : Exploiting Multi-Periodicity and Diverse Spatial Dependencies for Flood Forecasting

<https://arxiv.org/abs/2412.06835>

1) 아이디어 (Basic Idea)

APS-LSTM은 홍수 예측을 위해 시간 패턴과 공간 관계를 동시에 고려한 모델임.

문제 인식

1. 시간 패턴 복잡함

- 강우/유량 시계열은 단순 증가/감소가 아니라 여러 주기성을 동시에 가짐
- 일반 LSTM은 전체 시계열만 보므로 주기별 패턴을 명확히 잡기 어려움

2. 공간적 의존성 다양함

- 서로 다른 관측소 간 유량이나 강우의 영향은 지형, 강 위치 등에 따라 다름
- 단순 LSTM은 한 지점 데이터만 보면 다른 지점과의 관계를 충분히 학습하지 못함

APS-LSTM 접근 방법

1. Multi-Periodicity (주기별 시계열 분리)

- FFT(Fast Fourier Transform)로 시계열을 여러 주기 성분으로 나눔
- 예: 24시간 패턴, 7일 패턴, 계절 패턴 따로 학습 가능
- 각 주기별로 다른 특징을 따로 학습하면 모델이 시간 패턴을 더 잘 포착함

2. Spatial Dependencies (공간 Self-Attention)

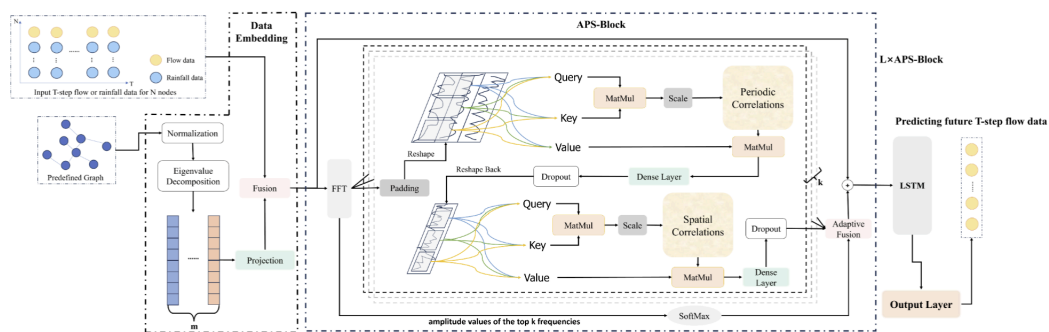
- 주기별 데이터를 다시 공간 단위로 연결
- Self-Attention 적용, 서로 다른 관측소가 서로 어떻게 영향을 주는지 학습

- 단순 연결보다 중요한 지점 간 상호 영향에 가중치를 두어 예측 정확도 향상

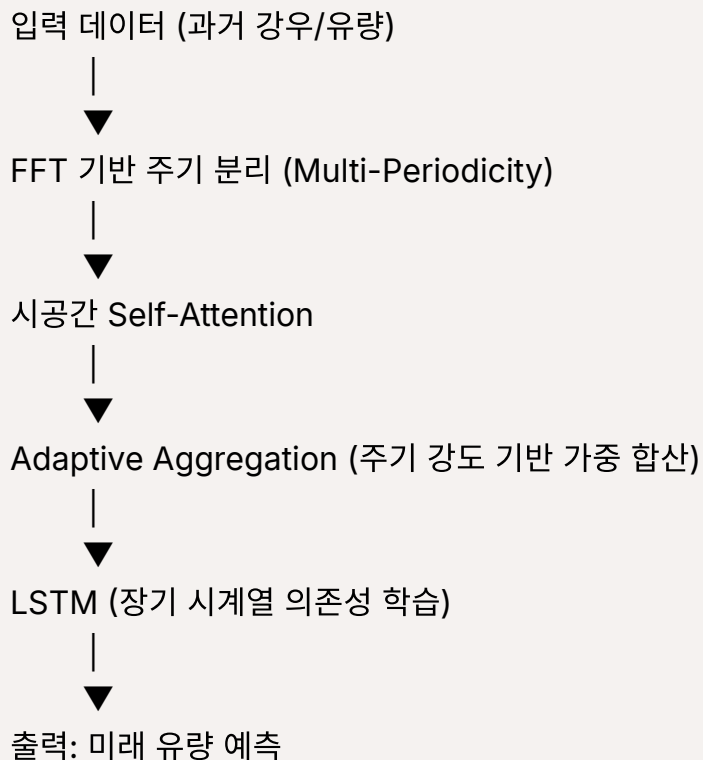
3. Adaptive Aggregation (적응적 결합)

- 주기별로 나온 특징을 주기 강도(amplitude)에 따라 가중합
- 중요 주기가 최종 예측에 더 크게 반영됨

2) 모델 구조 (Architecture)



APS-LSTM 전체 흐름:



각 단계 상세 설명

1. FFT 기반 주기 분리

- 시계열 데이터를 주기별로 나눔
- 모델이 장단기 패턴을 명확히 학습

2. 시공간 Self-Attention

- 주기별 데이터를 지점 단위로 연결
- 각 지점이 다른 지점에 주는 영향력을 계산
- 시공간 상호작용 정보를 풍부하게 반영

3. Adaptive Aggregation

- 주기별 결과를 강도 기반으로 합산
- 모델이 중요한 주기에 더 집중

4. LSTM

- 장기 시계열 패턴 학습
- 최종적으로 미래 유량 예측

3) 데이터 및 실험 결과

입력/출력 변수

- 입력(X)
 - 과거 강우/유량 시계열
 - 여러 관측소 포함, $T \times N$ 형태 (T =시간 길이, N =관측소 수)
- 출력(Y)
 - 미래 유량 예측 (예: 다음 6시간 유량)

데이터셋

- TunXi 구역: 11개 강우 관측소 + 1개 유량 관측소
- ChangHua 구역: 7개 강우 관측소 + 1개 유량 관측소

비교 모델

- LSTM, GRU (기본 시계열 모델)

- TimesNet, DLinear (주기 모델)
- STA-LSTM, Graph WaveNet (시공간 모델)

평가 지표

- RMSE, MAE, MAPE

결과

- 대부분 지표에서 APS-LSTM이 우수
 - 장기 예측(T+3 이상)에서도 성능 유지 높음
 - TunXi 데이터 예:
 - RMSE 약 4% 개선
 - MAE 9% 개선
 - MAPE 19% 개선
-