

# TaBERT : Pretraining for Joint Understanding of Textual and Tabular Data

<https://arxiv.org/abs/2005.08314>

## 0. Introduction

- 긴 시계열(long-term time series)을 정확히 예측하는 것은 어려운 문제였음
- Transformer 기반 모델들이 등장했지만, 긴 horizon에서 성능 급락 문제가 지속됨
- 주요 원인은 다음 두 가지였음
  - self-attention이 시계열의 주기성\*을 제대로 반영하지 못함
  - autoregressive 구조로 인해 horizon이 길어질수록 오차 누적이 심해짐
- Auto-Correlation 메커니즘과 Series Decomposition 구조를 도입함
- 기존 Transformer 기반 LTSF(Long-Term Series Forecasting) 모델보다 장기 구간에서 큰 폭의 성능 향상을 달성함

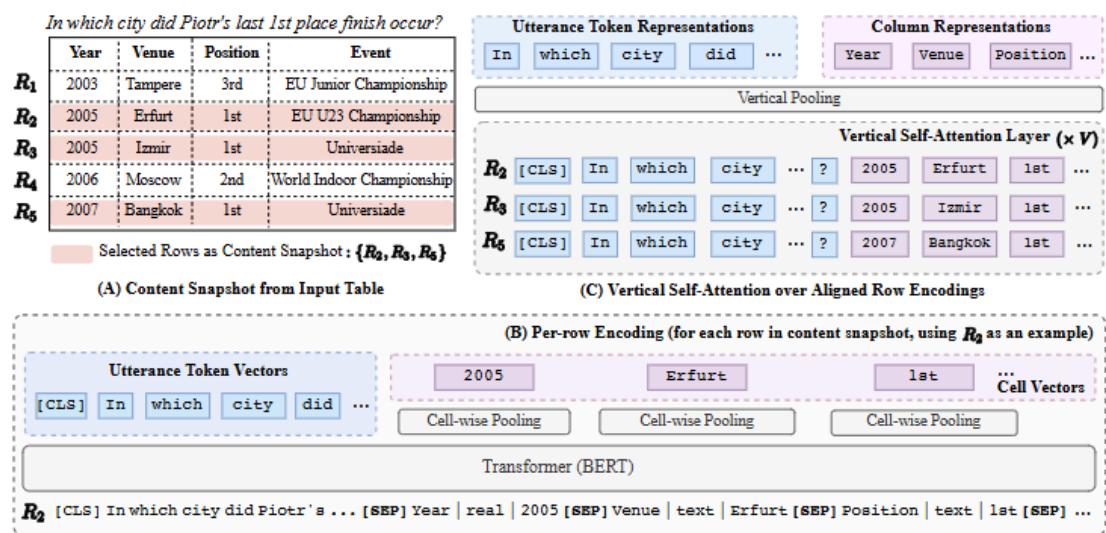
## 1. Overview

- Autoformer는 Encoder-Decoder 구조를 유지하면서 내부 블록을 Decomposition + Auto-Correlation으로 재설계함
- Self-attention 대신 Auto-Correlation을 사용해 반복적 패턴 주기를 직접 찾아냄
- 각 블록마다 시계열을 trend와 seasonal로 분해해 noise를 줄이고 학습 안정성을 확보함
- Decoder는 trend는 linear interpolation, seasonal은 Auto-Correlation 기반 보간으로 예측

## 2. Challenges

- Transformer의 self-attention은 긴 시계열에서 다음 문제를 가짐
  - attention이 패턴 간 유사성을 직접적으로 계산하지 못함
  - 길이가 늘어날수록 복잡도 증가
  - autoregressive 방식의 누적 오류
- 실무에서 사용되는 시계열은 계절성, 갑작스러운 변화, 장기 패턴 등이 혼재해 모델링이 어려움
- 기존 LTSF 연구들은 주기적 패턴을 직접적으로 다루지 못해 장기 성능이 떨어지는 경향 있었음
- 따라서 긴 horizon에서 안정적 성능을 내기 위한 구조가 필요했음

### 3. Method



- 모델은 **Series Decomposition**과 **Auto-Correlation Mechanism** 두 축으로 설계됨
- Encoder와 Decoder 모두 decomposition을 반복적으로 적용하는 구조로 구성됨
- Self-attention을 완전히 Auto-Correlation으로 대체함

## Series Decomposition

- 입력 시계열을 **trend + seasonal**로 분해함
- moving average 기반 방식 사용함
- decomposition은 각 블록에서 residual connection 대체 방식으로 반복 적용됨
- 분해를 통해 noise가 줄고 장기 예측 안정성이 높아짐
- encoder와 decoder 모두 동일한 decomposition 구조 사용함

## Auto-Correlation Mechanism

- self-attention을 대체하는 핵심 모듈임
- 시계열을 shift 시킨 여러 복사본과의 \*\*Auto-Correlation(자기상관)\*\*을 계산함
- correlation score가 높은 shift들 중 **top-k delay**를 선택함
- 선택된 delay의 seasonal 패턴을 재조합하여 새로운 representation 생성함
- 반복 패턴이 강한 시계열의 seasonality를 명시적으로 학습 가능함
- self-attention 대비 복잡도가 더 낮고 장기 패턴 포착 능력이 뛰어남

## Encoder 구조

- 입력을 decomposition으로 trend와 seasonal로 분리함
- seasonal만 Auto-Correlation을 통과함
- trend는 별도로 분리되어 다음 블록으로 전달됨
- 블록마다 decomposition이 반복되어 안정적 feature 추출이 가능해짐

## Decoder 구조

- 디코더 입력 역시 decomposition으로 trend/seasonal 분리됨
- seasonal 입력은 Auto-Correlation으로 과거 주기 패턴을 불러와 예측에 활용함
- trend는 linear extrapolation 방식으로 예측됨
- autoregressive 방식 없이 전체 horizon을 한 번에 출력하도록 설계됨

## 4. Experiments

- 사용 데이터셋

- ETTh1, ETTh2
- ETTm1, ETTm2
- Electricity
- Exchange-Rate
- Traffic
- 예측 길이(horizon)는 96, 192, 336, 720
- 비교 모델
  - Transformer 계열: Informer, LogTrans, Reformer
  - 딥러닝 계열: LSTM, N-BEATS
  - 기존 시계열 기반 모델 등
- MSE, MAE로 평가
- 모델은 모든 horizon에서 안정적으로 성능 측정됨

## 5. Results

Previous Systems on WikiTableQuestions				Top-ranked Systems on Spider Leaderboard			
Model	DEV	TEST		Model	DEV. ACC.		
Pasupat and Liang (2015)	37.0	37.1		Global-GNN (Bogin et al., 2019a)	52.7		
Neelakantan et al. (2016)	34.1	34.2		EditSQL + BERT (Zhang et al., 2019a)	57.6		
Ensemble 15 Models	37.5	37.7		RatSQL (Wang et al., 2019a)	60.9		
Zhang et al. (2017)	40.6	43.7		IRNet + BERT (Guo et al., 2019)	60.3		
Dasigi et al. (2019)	43.1	44.3		+ Memory + Coarse-to-Fine	61.9		
Agarwal et al. (2019)	43.2	44.1		IRNet V2 + BERT	63.9		
Ensemble 10 Models	—	46.9		RyanSQL + BERT (Choi et al., 2020)	<b>66.6</b>		
Wang et al. (2019b)	43.7	44.5		Our System based on TranX (Yin and Neubig, 2018)			
Our System based on MAPO (Liang et al., 2018)				Mean	Best		
Base Parser <sup>†</sup>	42.3 ±0.3	42.7	43.1 ±0.5	43.8			
w/ BERT <sub>Base</sub> (K = 1)	49.6 ±0.5	50.4	49.4 ±0.5	49.2	w/ BERT <sub>Base</sub> (K = 1)	61.8 ±0.8	62.4
– content snapshot	49.1 ±0.6	50.0	48.8 ±0.9	50.2	– content snapshot	59.6 ±0.7	60.3
w/ TABERT <sub>Base</sub> (K = 1)	51.2 ±0.5	51.6	50.4 ±0.5	51.2	w/ TABERT <sub>Base</sub> (K = 1)	63.3 ±0.6	64.2
– content snapshot	49.9 ±0.4	50.3	49.4 ±0.4	50.0	– content snapshot	60.4 ±1.3	61.8
w/ TABERT <sub>Base</sub> (K = 3)	51.6 ±0.5	52.4	51.4 ±0.3	51.3	w/ TABERT <sub>Base</sub> (K = 3)	63.3 ±0.7	64.1
w/ BERT <sub>Large</sub> (K = 1)	50.3 ±0.4	50.8	49.6 ±0.5	50.1	w/ BERT <sub>Large</sub> (K = 1)	61.3 ±1.2	62.9
w/ TABERT <sub>Large</sub> (K = 1)	51.6 ±1.1	52.7	51.2 ±0.9	51.5	w/ TABERT <sub>Large</sub> (K = 1)	64.0 ±0.4	64.4
w/ TABERT <sub>Large</sub> (K = 3)	52.2 ±0.7	<b>53.0</b>	51.8 ±0.6	<b>52.3</b>	w/ TABERT <sub>Large</sub> (K = 3)	<b>64.5 ±0.6</b>	<b>65.2</b>

u: How many years before was the film <i>Bacchae</i> out before <i>the Watermelon</i> ?			
Input to TABERT <sub>Large</sub> (K = 3) ▷ Content Snapshot with Three Rows			
Film	Year	Function	Notes
The Bacchae	2002	Producer	Screen adaptation of...
The Trojan Women	2004	Producer/Actress	Documentary film...
The Watermelon	2008	Producer	Oddball romantic comedy...

Input to TABERT <sub>Large</sub> (K = 1) ▷ Content Snapshot with One Synthetic Row			
Film	Year	Function	Notes
The Watermelon	2013	Producer	Screen adaptation of...

Cell Linearization Template	WIKIQ.	SPIDER
Pretrained TABERT <sub>Base</sub> Models (K = 1)		
<u>Column Name</u>	49.6 ±0.4	60.0 ±1.1
<u>Column Name</u>   <u>Type</u> <sup>†</sup> (-content snap.)	49.9 ±0.4	60.4 ±1.3
<u>Column Name</u>   <u>Type</u>   <u>Cell Value</u> <sup>†</sup>	51.2 ±0.5	63.3 ±0.6
BERT <sub>Base</sub> Models		
<u>Column Name</u> (Hwang et al., 2019)	49.0 ±0.4	58.6 ±0.3
<u>Column Name</u> is <u>Cell Value</u> (Chen19)	50.2 ±0.4	63.1 ±0.7

- Autoformer는 모든 데이터셋에서 long-horizon 기준 SOTA 기록
- 특히 예측 길이가 336, 720처럼 매우 길어질수록 성능 우위가 두드러짐
- Ablation 결과
  - Auto-Correlation 제거 시 성능 급락
  - Decomposition 제거 시 장기 구간에서 특히 불안정
- 계산량(FLOPs)은 Informer보다 낮으면서 성능은 더 좋음
- long-term forecasting에서 Transformer 기반 모델 중 가장 안정적인 모델로 평가됨

## 6. Insight

- 시계열에서 seasonality는 매우 중요한 구조인데, 기존 Transformer는 이를 명시적으로 다루지 못했음
- Auto-Correlation은 반복 패턴을 직접 modeling하므로 시계열 특성에 더 적합함
- autoregressive 제거가 horizon 증가에 따른 누적 오류를 근본적으로 줄여줌
- decomposition은 trend를 분리하여 seasonal만 모델링하게 함 → 예측 난이도 감소
- 실무적으로 전력 수요, 교통량 같은 반복 패턴이 강한 데이터에 특히 유리
- 비주기적 시계열에서는 개선 폭이 작을 가능성 있음
- moving average 기반 decomposition이 모든 데이터에 최적은 아닐 수 있음