From RankNet to LambdaRank to LambdaMART : An Overview

https://www.microsoft.com/en-us/research/wp-content/uploads/2016/02/MSR-TR-2010-82.pdf

---

0. Introduction

- sparse 데이터에서 feature interaction 학습 문제를 해결하려는 연구
- 기존 방법은 두 가지 한계 존재
  - SVM, Linear model → interaction 학습 어려움
  - Matrix Factorization → 특정 구조(user-item)에만 적용 가능
- 특히 추천 시스템은 대부분 high sparsity 문제를 가짐
- 본 논문은 이를 해결하기 위해 **Factorization Machines (FM)** 제안
- 핵심 기여
  - 모든 변수 간 interaction을 일반화된 방식으로 학습
  - sparse 데이터에서도 안정적 학습 가능
  - 다양한 문제 (추천, CTR 등)에 통합적으로 적용 가능

1. Overview

- FM은 선형 모델 + latent factor interaction 구조
- 모든 feature 간 pairwise interaction을 factorization으로 모델링
- 입력은 one-hot 또는 sparse vector 형태
- Matrix Factorization을 일반 feature space로 확장한 형태
- 핵심 아이디어
  - interaction weight를 직접 학습하지 않고
  - latent vector 내적 형태로 계산

- 적용 가능 영역
  - 추천 시스템
  - 클릭률 예측 (CTR)
  - 랭킹 문제

2. Challenges

- Sparse 데이터에서 interaction 학습 어려움
- feature 조합 수가 매우 큼 → 직접 학습 불가능
- 기존 방법 한계
  - Polynomial regression → 파라미터 수 폭발
  - SVM → interaction 표현 제한
  - Matrix Factorization → 특정 구조에 종속
- 실무 문제
  - cold feature (관측 적은 feature) 처리 어려움
  - high-dimensional 데이터 학습 비용 증가

3. Method

- FM 기본 식

$$\hat{y}(x) = w_0 + \sum_{i=1}^{n} w_i x_i + \sum_{i=1}^{n} \sum_{j=i+1}^{n} \langle v_i, v_j \rangle x_i x_j$$

- 구성 요소
  - w0 : global bias
  - wi : 1차 linear weight
  - vi : k-dimensional latent vector
- 핵심 구조
  - 모든 pairwise interaction을 ⟨vi,vj⟩ 로 계산

    - 파라미터 수를 $O(n^2) \rightarrow O(nk)$로 감소
- 계산 최적화
    - naive 계산은 $O(n^2)$
    - reformulation 통해 $O(nk)$로 개선
- 학습 방법
    - SGD (Stochastic Gradient Descent)
    - ALS (Alternating Least Squares)
    - Bayesian 방식 가능
- 특징
    - sparse input에서도 효율적
    - feature engineering 없이 interaction 학습 가능

4. Experiments

- 데이터 특성
    - sparse high-dimensional 데이터
    - 추천 및 CTR 관련 데이터셋 사용
- 비교 대상
    - SVM
    - Polynomial regression
    - Matrix Factorization
- 평가 방식
    - regression → RMSE
    - ranking → accuracy 계열 지표
- 실험 설계
    - 다양한 sparsity 수준 테스트
    - latent factor dimension 변화 실험

5. Results

- FM이 대부분 baseline 대비 성능 우수
- 특히 sparse 환경에서 큰 성능 향상
- Matrix Factorization과 유사하거나 더 높은 성능
- 핵심 결과
  - feature interaction을 효과적으로 학습
  - 데이터가 sparse할수록 성능 차이 증가
- 효율성
  - 계산 복잡도 감소
  - large-scale 데이터에서도 적용 가능
- 한계
  - higher-order interaction (3차 이상) 제한적
  - hyperparameter (k) 선택 중요

6. Insight

- FM은 **Ma**trix Factorization의 일반화 모델
- 추천 시스템에서 중요한 “feature interaction” 문제를 해결
- 장점
  - sparse 데이터에 매우 강함
  - 다양한 문제에 동일 구조 적용 가능
  - 구현 단순 + 확장성 높음
- 단점
  - interaction이 pairwise로 제한
  - nonlinear 표현력은 딥러닝 대비 부족
- 실무적 의미
  - CTR 예측, 광고 시스템에서 매우 강력
  - DeepFM, Wide&Deep 등 최신 모델의 기반

- 연구적 의미
  - “feature interaction을 factorization으로 해결” 패러다임 제시
  - 이후 Deep Learning 기반 추천 모델로 확장되는 출발점