Neural Graph Collaborative Filtering

https://arxiv.org/pdf/1905.08108

0. Introduction

- 협업 필터링은 추천 시스템의 핵심 방법
- 기존 방법 한계
  - Matrix Factorization → 선형 관계만 모델링
  - Neural CF → non-linearity는 있지만 graph 구조 미반영
- 문제점
  - user-item interaction graph의 구조적 정보 손실
- 연구 목적
  - 그래프 구조를 직접 활용하는 추천 모델 설계
- 핵심 기여
  - GNN 기반 collaborative filtering 제안
  - high-order connectivity 반영
  - 기존 모델 대비 성능 개선

1. Overview

- user-item bipartite graph 기반 모델
- 전체 흐름
  - embedding 초기화
  - graph propagation 수행
  - multi-layer aggregation
  - 예측 수행
- 특징

    - k-hop neighborhood까지 정보 확장
    - 단순 interaction → 구조적 관계 학습
- 적용 데이터
    - implicit feedback 기반 추천 데이터

2. Challenges

- 데이터 희소성 문제
    - 대부분 interaction이 sparse
- high-order 관계 학습의 어려움
    - 깊어질수록 noise 증가
- 기존 접근법 한계
    - MF → 표현력 부족
    - Neural CF → graph 구조 미반영
- 학습 안정성 문제
    - layer 증가 시 over-smoothing 발생 가능

3. Method

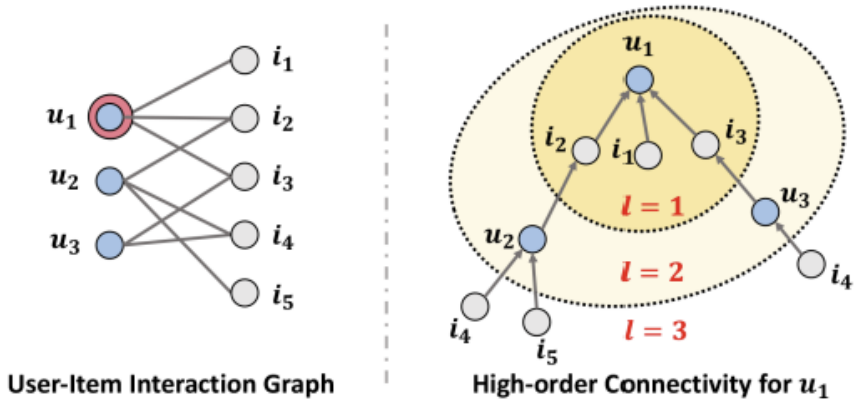

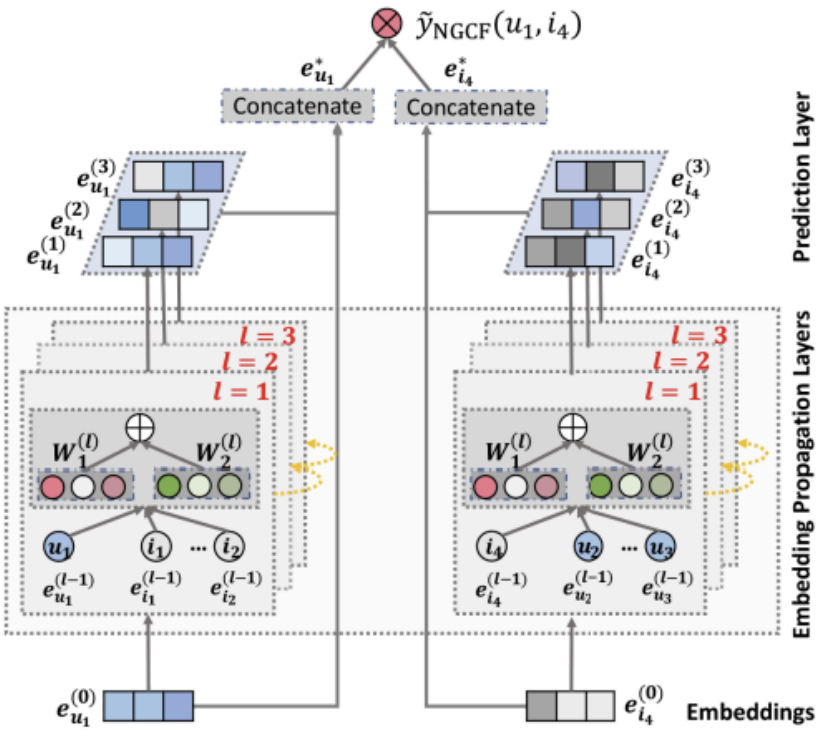

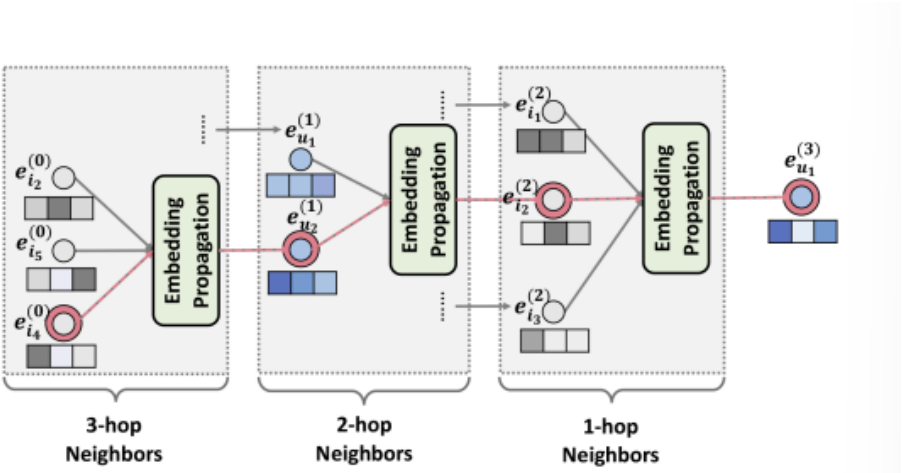

- Graph Representation
  - user-item bipartite graph 구성
  - adjacency matrix 기반 표현
- Embedding Initialization
  - user, item 각각 embedding 초기화
- Message Passing
  - 이웃 노드로부터 정보 전달

    - layer별 embedding 업데이트
    - 특징
        - high-order connectivity 반영
        - non-linear interaction 포함
- Aggregation
    - 각 layer embedding을 결합
    - final representation 생성
- Prediction
    - user embedding과 item embedding 내적
    - ranking score 계산
- Learning
    - Bayesian Personalized Ranking 기반 학습
    - positive / negative 샘플 비교
    - pairwise ranking 최적화

4. Experiments

Dataset	#Users	#Items	#Interactions	Density
Gowalla	29,858	40,981	1,027,370	0.00084
Yelp2018*	31,668	38,048	1,561,406	0.00130
Amazon-Book	52,643	91,599	2,984,108	0.00062

- 데이터셋
    - Gowalla
    - Yelp2018
    - Amazon-Book
- 평가 지표
    - Recall@K

    - NDCG@K
- 비교 대상
    - Matrix Factorization
    - Neural Collaborative Filtering
    - 기타 graph 기반 baseline

5. Results

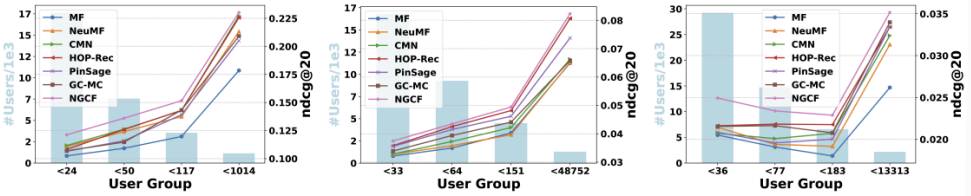

(a) ndcg on Gowalla (b) ndcg on Yelp2018* (c) ndcg on Amazon-book

	Gowalla		Yelp2018*		Amazon-Book	
	recall	ndcg	recall	ndcg	recall	ndcg
NGCF-1	**0.1556**	**0.1315**	**0.0543**	**0.0442**	**0.0313**	**0.0241**
NGCF-1$_{\text{SVD++}}$	0.1517	0.1265	0.0504	0.0414	0.0297	0.0232
NGCF-1$_{\text{GC-MC}}$	0.1523	0.1307	0.0518	0.0420	0.0305	0.0234
NGCF-1$_{\text{PinSage}}$	0.1534	0.1308	0.0516	0.0420	0.0293	0.0231

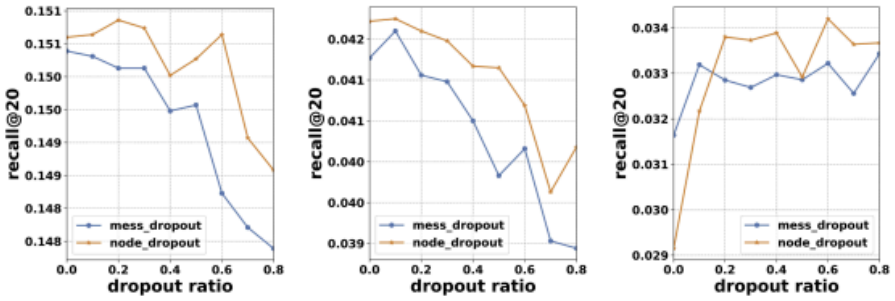

(a) Gowalla (b) Yelp2018* (c) Amazon-Book

Figure 5: Effect of node dropout and message dropout ratios.

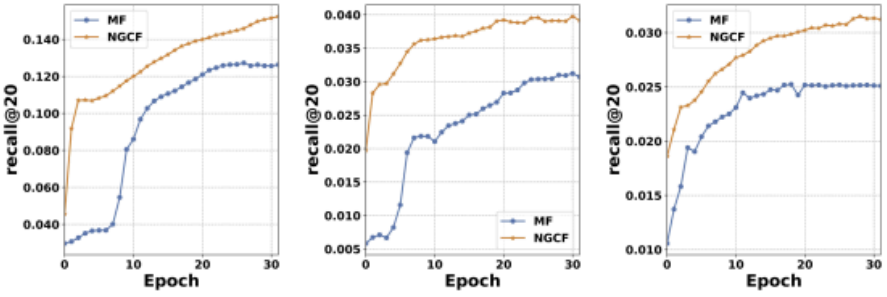

(a) Gowalla (b) Yelp2018* (c) Amazon-Book

- NGCF가 대부분 데이터셋에서 성능 우수
- Recall, NDCG 기준 개선 확인
- layer 영향
  - shallow → 성능 부족
  - 적절한 depth → 성능 향상
  - 너무 깊음 → 성능 저하
- ablation 결과
  - message passing 제거 시 성능 감소
  - high-order 정보 중요성 확인

6. Insight

- 그래프 구조 활용이 추천 성능에 핵심 요소
- 장점
  - high-order 관계 학습 가능
  - 표현력 증가
- 단점
  - 계산 비용 증가
  - 모델 복잡성
  - over-smoothing 문제
- 실무적 시사점
  - 단순 MF보다 graph 기반 접근 유리
  - 하지만 단순화 필요 → LightGCN으로 발전
- 연구 흐름
  - NGCF → LightGCN → Graph-based 추천 확장