

Session-based Recommendation with Graph Neural Networks

<https://arxiv.org/pdf/1811.00855>

0. Introduction

- 세션 기반 추천은 사용자 프로필 없이 세션 내 행동만으로 다음 아이템을 예측하는 문제임
- 기존 RNN 기반 모델은 세션 내 복잡한 전이 구조를 단순 순서 정보로만 학습해 한계가 있었음
- 세션을 그래프 구조로 표현하고 GNN을 활용해 아이템 간 전이 관계를 학습하는 새로운 접근 제안함
- 세션의 마지막 행동을 중심으로 한 현재 관심과 세션 전체의 글로벌 선호를 함께 고려하는 attention 메커니즘 도입함
- 두 개의 공개 데이터셋에서 기존 모델보다 우수한 성능 달성함

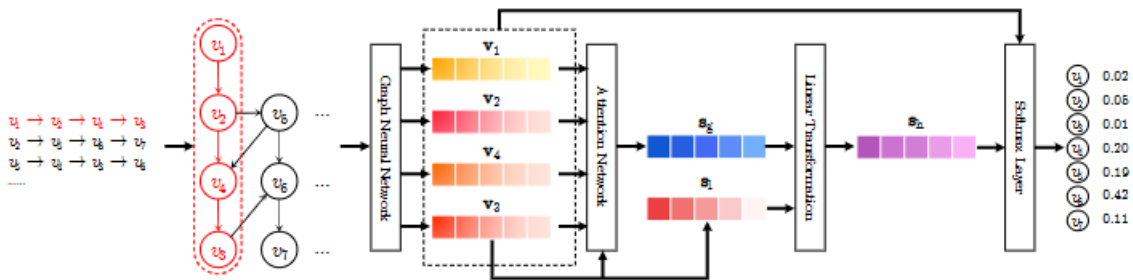
1. Overview

- 핵심 아이디어는 세션 내 아이템 전이를 그래프로 표현하고 GNN으로 노드 간 관계를 학습하는 것임
- 세션 그래프는 아이템을 노드로 클릭 순서를 방향성 간선으로 구성함
- 모델 전체 구조는 세션 그래프 구성 → 노드 임베딩 학습 → 세션 임베딩 생성 → 점수 계산 및 추천 순으로 진행됨
- 데이터셋은 YooChoose와 Diginetica 사용, 평가 지표는 Hit@K와 MRR임
- 기대 효과는 세션 내 복잡한 전이 구조를 효과적으로 학습하고 기존 순차 모델보다 정확한 추천 가능하게 하는 것임

2. Challenges

- 세션 기반 추천에서는 사용자 장기 히스토리가 없어 세션 내 정보만으로 표현 학습해야 함
- 아이템 간 전이가 단순 선형 순서가 아니라 반복, 건너뛰기 등 복잡한 구조를 가짐
- 현재 관심과 전체 선호를 동시에 반영하는 모델 설계가 어려움
- 세션 길이가 길거나 아이템 수가 많을 경우 그래프 구조의 계산 비용과 확장성 문제가 존재함

3. Method



- 세션을 아이템 노드와 클릭 간 전이로 이루어진 방향 그래프로 변환함
- 간선 가중치는 등장 횟수를 기준으로 정규화하여 사용함
- 노드 표현은 Gated Graph Neural Network(GGNN) 구조로 학습함
- 노드 업데이트는 GRU 형태의 게이트 연산으로 수행되며 각 노드의 인접 노드 정보가 포함됨
- 출발 방향과 도착 방향을 구분해 두 개의 인접 행렬로 구성함
- 세션 표현은 로컬 임베딩과 글로벌 임베딩을 결합함
- 로컬 임베딩은 세션의 마지막 클릭 아이템 벡터 사용함
- 글로벌 임베딩은 세션 내 모든 아이템 벡터에 attention 가중치를 주어 가중합 계산함
- 최종 세션 임베딩은 두 임베딩을 선형 변환으로 결합한 형태임
- 추천 단계에서는 세션 임베딩과 각 아이템 벡터의 내적으로 점수를 계산함
- softmax를 통해 다음 클릭 확률 예측하고 크로스엔트로피 손실로 학습함

4. Experiments

Statistics	Yoochoose 1/64	Yoochoose 1/4	Diginetica
# of clicks	557,248	8,326,407	982,961
# of training sessions	369,859	5,917,745	719,470
# of test sessions	55,898	55,898	60,858
# of items	16,766	29,618	43,097
Average length	6.16	5.71	5.12

- 데이터셋은 YooChoose와 Diginetica 사용함
- 비교 모델로 POP, S-POP, Item-KNN, BPR-MF, FPMC, GRU4REC, NARM, STAMP 등 포함함
- Hit@20, MRR@20 기준으로 평가함
- 세션 길이에 따른 성능 비교 진행해 짧은 세션과 긴 세션 모두에서 일관된 성능 확인함
- 그래프 연결 방식에 따른 변형 모델 실험해 성능 차이 분석함

5. Results

Method	Yoochoose 1/64		Yoochoose 1/4		Diginetica	
	P@20	MRR@20	P@20	MRR@20	P@20	MRR@20
POP	6.71	1.65	1.33	0.30	0.89	0.20
S-POP	30.44	18.35	27.08	17.75	21.06	13.68
Item-KNN	51.60	21.81	52.31	21.70	35.75	11.57
BPR-MF	31.31	12.08	3.40	1.57	5.24	1.98
FPMC	45.62	15.01	–	–	26.53	6.95
GRU4REC	60.64	22.89	59.53	22.60	29.45	8.33
NARM	68.32	28.63	69.73	29.23	49.70	16.17
STAMP	68.74	29.67	70.44	30.00	45.64	14.32
SR-GNN	70.57	30.94	71.36	31.89	50.73	17.59




Figure 3: The performance of different connection schemes




Figure 4: The performance of different session representations

Method	Yoochoose 1/64		Diginetica	
	Short	Long	Short	Long
NARM	71.44	60.79	51.22	45.75
STAMP	70.69	64.73	47.26	40.39
SR-GNN-L	70.11	69.73	49.04	50.97
SR-GNN-ATT	70.31	70.64	50.35	51.05
SR-GNN	70.47	70.70	50.49	51.27

- SR-GNN은 모든 데이터셋에서 기존 모델 대비 높은 Hit@20과 MRR@20 달성함
- 짧은 세션에서도 안정적인 성능 유지하며 RNN 기반 모델 대비 긴 세션에서 성능 저하가 적었음
- ablation 결과 attention 기반 글로벌 임베딩이 단순 평균보다 효과적임이 확인됨
- 로컬 임베딩만 사용한 경우에도 기본 수준 이상의 성능을 보였으나 두 임베딩 결합 시 최적의 결과 나옴
- 모델은 그래프 구조 덕분에 전이 관계를 명확히 포착해 순차적 한계를 극복함
- 다만 아이템 속성 정보나 대규모 세션 처리 효율성은 논문에서 다루지 않음

6. Insight

- 이 연구는 세션을 순차열이 아닌 그래프로 해석한 첫 시도로 추천 시스템 구조적 전환점이 됨
- 세션 내 전이 관계를 GNN으로 학습함으로써 사용자 단기 관심을 정교하게 포착함
- 로컬과 글로벌 관심을 함께 고려하는 설계가 실제 추천 상황에서 중요한 시사점 제공함
- 실무 적용 시 세션 길이 그래프 생성 비용 실시간 업데이트 문제 고려 필요함
- 향후 연구에서는 아이템 메타데이터나 장기 사용자 정보 결합 대규모 그래프 효율화 방향으로 확장 가능함
- **키워드:** 세션기반추천, 그래프신경망, 세션그래프, 아이템전이, 하이브리드세션임베딩