SLi-Rec : Self-supervised Learning for Sequential Recommendation

https://arxiv.org/pdf/2008.07873

0. Introduction

- 순차 추천에서 데이터 희소성 문제를 해결하고자 함. 기존 모델들은 item 예측 손실만으로 학습되어 연관 정보 활용이 제한적임.
- 자기지도 학습(self-supervised learning)을 통해 시퀀스 정보와 속성 간 상관관계를 보존하고자 함.
- 기존 sequential recommender들이 최종 예측 성능 향상에만 집중해 representation 학습이 취약함.
- 핵심 기여는 mutual information maximization 기반 self-supervised objective를 도입하여 표현 학습 품질을 높인 점임.
- 이 방법은 sparse scenario에서도 일반화 성능 향상을 기대할 수 있음.

1. Overview

- S^3-Rec는 self-attentive 신경망 구조를 기반으로 함.
- Sequence 내 다양한 정보(속성, 아이템, subsequence) 간 상호 정보를 극대화함.
- Pre-training과 Fine-tuning 전략으로 시퀀스 표현을 강화함.
- 여러 real-world dataset에서 실험하여 희소한 데이터 상황에서도 강한 성능을 보임.
- 전체 목표는 단순 item 예측을 넘어 **표현 학습 강화 및 시퀀스 패턴 이해**에 있음.

2. Challenges

- 사용자 행동 시퀀스가 매우 sparse하여 의미 있는 패턴 학습이 어려움.

- Item prediction loss만으로는 sequence context와 속성 정보를 충분히 반영하지 못함.
- 모델 표현 학습 범위가 좁아 희소 데이터에서 일반화가 떨어짐.
- 기존 방법은 sequence 내 다중 수준 정보 상관관계를 활용하지 못함.
- 실제 서비스 적용 시 데이터 부족과 노이즈가 모델 성능 저하로 이어질 수 있음.

3. Method

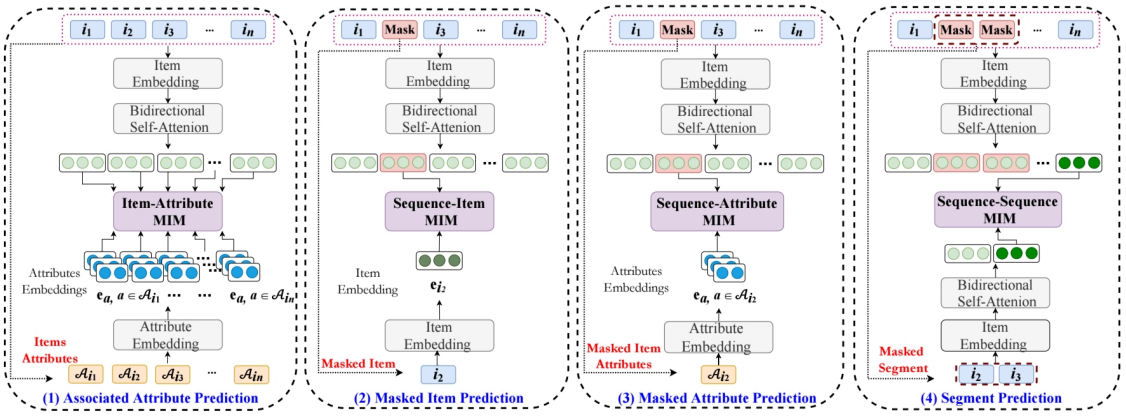

- Self-attentive backbone을 통해 시퀀스 내 패턴을 캡쳐함.
- Mutual Information Maximization을 통해 서로 다른 데이터 요소 간 상호 정보를 극대화.
- Self-supervised objectives:
  - Associated Attribute Prediction: 속성과 아이템 간 상관 관계 학습
  - Masked Item Prediction: 일부 아이템 마스킹 후 예측
  - Masked Attribute Prediction: 속성 마스킹 후 예측
  - Segment Prediction: subsequence 전체 관계 학습
- Pre-training 단계에서 self-supervised loss를 최적화하고 Fine-tuning 단계에서 최종 추천 task에 맞춰 모델을 조정.

4. Experiments

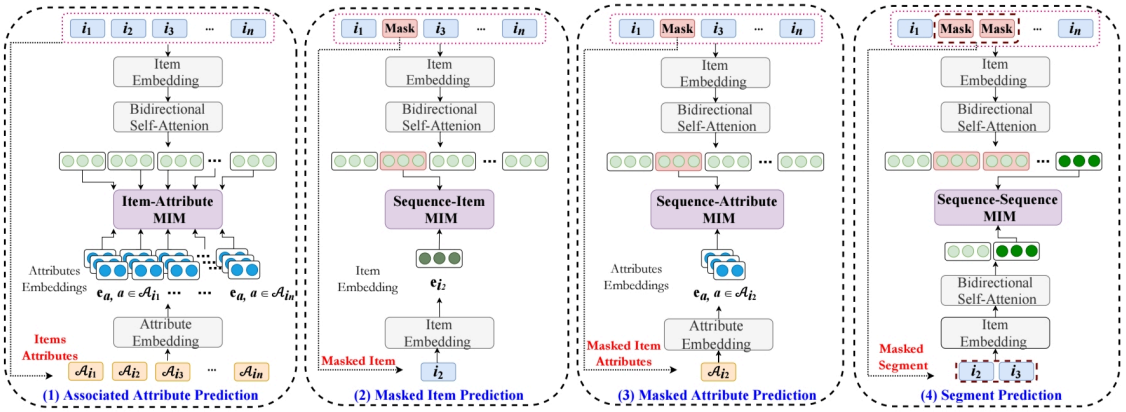

- 6개의 real-world dataset 사용.
- 데이터셋은 다양한 도메인을 포함하여 일반화 능력을 테스트.
- Baseline으로 GRU4Rec, SASRec, FDSA 등 기존 sequential 추천 모델과 비교.
- 평가 지표는 Hit Ratio(HR) 및 NDCG.
- 실험 변수로 self-supervised objective 유무, 데이터 희소성 수준 등을 포함.

5. Results

Datasets	Metric	PopRec	FM	AutoInt	GRU4Rec	Caser	SASRec	BERT4Rec	HGN	GRU4Rec$_F$	SASRec$_F$	FDSA	S^3-Rec	Improv.
Meituan	HR@1	0.0946	0.1084	0.0804	0.1194	0.1368	0.1797	0.1381	0.1603	0.1436	0.1746	0.1778	**0.2040***	13.52%
	HR@5	0.2660	0.3218	0.2662	0.3382	0.3812	0.4524	0.3985	0.4110	0.3799	0.4386	0.4595	**0.4925***	7.18%
	NDCG@5	0.1813	0.2170	0.1739	0.2303	0.2619	0.3207	0.2713	0.2887	0.2639	0.3098	0.3236	**0.3527***	8.99%
	HR@10	0.3863	0.4709	0.4077	0.4881	0.5267	0.6053	0.5514	0.5573	0.5378	0.5962	0.6164	**0.6368***	3.31%
	NDCG@10	0.2200	0.2651	0.2194	0.2787	0.3090	0.3700	0.3208	0.3359	0.3149	0.3607	0.3743	**0.3994***	6.71%
	MRR	0.1923	0.2242	0.1854	0.2359	0.2617	0.3146	0.2689	0.2863	0.2666	0.3064	0.3167	**0.3421***	8.02%
Beauty	HR@1	0.0678	0.0405	0.0447	0.1337	0.1337	0.1870	0.1531	0.1683	0.1702	0.1778	0.1840	**0.2192***	17.22%
	HR@5	0.2105	0.1461	0.1705	0.3125	0.3032	0.3741	0.3640	0.3544	0.3727	0.3863	0.4010	**0.4502***	12.27%
	NDCG@5	0.1391	0.0934	0.1063	0.2268	0.2219	0.2848	0.2622	0.2656	0.2759	0.2870	0.2974	**0.3407***	14.56%
	HR@10	0.3386	0.2311	0.2872	0.4106	0.3942	0.4696	0.4739	0.4503	0.4753	0.4843	0.5096	**0.5506***	8.05%
	NDCG@10	0.1803	0.1207	0.1440	0.2584	0.2512	0.3156	0.2975	0.2965	0.3090	0.3185	0.3324	**0.3732***	12.27%
	MRR	0.1558	0.1096	0.1226	0.2308	0.2263	0.2852	0.2614	0.2669	0.2751	0.2844	0.2943	**0.3340***	13.49%
Sports	HR@1	0.0763	0.0489	0.0644	0.1160	0.1135	0.1455	0.1255	0.1428	0.1466	0.1573	0.1585	**0.1841***	16.15%
	HR@5	0.2293	0.1603	0.1982	0.3055	0.2866	0.3466	0.3375	0.3349	0.3547	0.3730	0.3855	**0.4267***	10.69%
	NDCG@5	0.1538	0.1048	0.1316	0.2126	0.2020	0.2497	0.2341	0.2420	0.2535	0.2683	0.2756	**0.3104***	12.63%
	HR@10	0.3423	0.2491	0.2967	0.4299	0.4014	0.4622	0.4722	0.4551	0.4758	0.4912	0.5136	**0.5614***	9.31%
	NDCG@10	0.1902	0.1334	0.1633	0.2527	0.2390	0.2869	0.2775	0.2806	0.2925	0.3064	0.3170	**0.3538***	11.61%
	MRR	0.1660	0.1202	0.1435	0.2191	0.2100	0.2520	0.2378	0.2469	0.2549	0.2680	0.2748	**0.3071***	11.75%
Toys	HR@1	0.0585	0.0257	0.0448	0.0997	0.1114	0.1878	0.1262	0.1504	0.1673	0.1797	0.1717	**0.2003***	6.66%
	HR@5	0.1977	0.0978	0.1471	0.2795	0.2614	0.3682	0.3344	0.3276	0.3695	0.3927	0.3994	**0.4420***	10.67%
	NDCG@5	0.1286	0.0614	0.0960	0.1919	0.1885	0.2820	0.2327	0.2423	0.2719	0.2911	0.2903	**0.3270***	12.33%
	HR@10	0.3008	0.1715	0.2369	0.3896	0.3540	0.4663	0.4493	0.4211	0.4782	0.4981	0.5129	**0.5530***	7.82%
	NDCG@10	0.1618	0.0850	0.1248	0.2274	0.2183	0.3136	0.2698	0.2724	0.3070	0.3252	0.3271	**0.3629***	10.94%
	MRR	0.1430	0.0819	0.1131	0.1973	0.1967	0.2842	0.2338	0.2454	0.2717	0.2886	0.2863	**0.3202***	10.95%
Yelp	HR@1	0.0801	0.0624	0.0731	0.2053	0.2188	0.2375	0.2405	0.2428	0.2293	0.2301	0.2198	**0.2591***	6.71%
	HR@5	0.2415	0.2036	0.2249	0.5437	0.5111	0.5745	0.5976	0.5768	0.5858	0.5937	0.5728	**0.6085***	1.82%
	NDCG@5	0.1622	0.1333	0.1501	0.3784	0.3696	0.4113	0.4252	0.4162	0.4137	0.4178	0.4014	**0.4401***	3.50%
	HR@10	0.3609	0.3153	0.3367	0.7265	0.6661	0.7373	0.7597	0.7411	0.7574	0.7706	0.7555	**0.7725**	0.25%
	NDCG@10	0.2007	0.1692	0.1860	0.4375	0.4198	0.4642	0.4778	0.4695	0.4694	0.4751	0.4607	**0.4934***	3.26%
	MRR	0.1740	0.1470	0.1616	0.3630	0.3595	0.3927	0.4026	0.3988	0.3929	0.3962	0.3834	**0.4190***	4.07%
LastFM	HR@1	0.0725	0.0183	0.0349	0.0642	0.0899	0.1211	0.1220	0.0908	0.1385	0.1147	0.0936	**0.1743***	25.85%
	HR@5	0.1982	0.0954	0.1550	0.1817	0.2982	0.3385	0.3569	0.2872	0.3202	0.3073	0.2624	**0.4523***	26.73%
	NDCG@5	0.1350	0.0552	0.0946	0.1228	0.1960	0.2330	0.2409	0.1896	0.2301	0.2113	0.1766	**0.3156***	31.01%
	HR@10	0.3037	0.1578	0.2596	0.2817	0.4431	0.4706	0.4991	0.4193	0.4670	0.4569	0.4055	**0.5835***	16.91%
	NDCG@10	0.1687	0.0753	0.1285	0.1550	0.2428	0.2755	0.2871	0.2324	0.2775	0.2594	0.2225	**0.3583***	24.80%
	MRR	0.1506	0.0743	0.1122	0.1405	0.2033	0.2364	0.2424	0.1983	0.2410	0.2201	0.1884	**0.3072***	26.73%

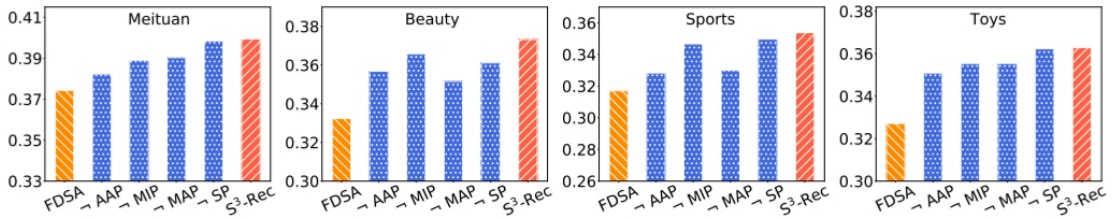

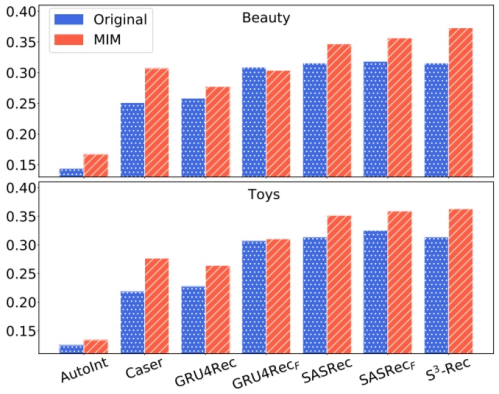

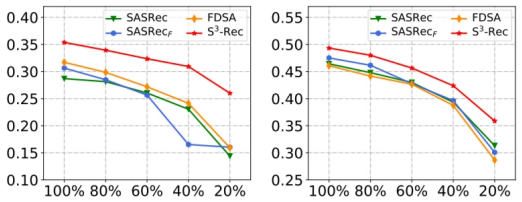

(a) Sports (b) Yelp

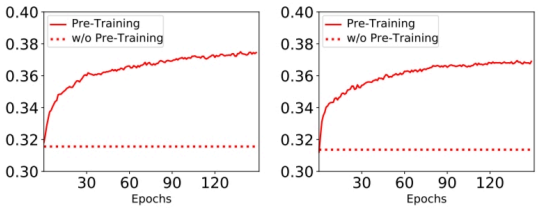

(a) Beauty (b) Toys

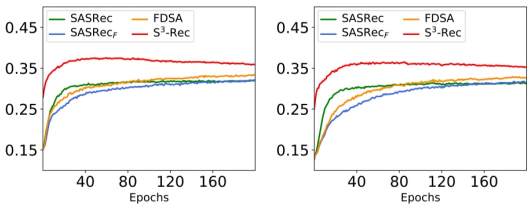

(a) Beauty (b) Toys

- S^3-Rec는 모든 데이터셋에서 baseline 대비 높은 HR/NDCG 성능을 보임.
- 희소한 데이터 상황에서 성능 향상이 더 뚜렷함.
- Ablation study 결과, 각 self-supervised objective는 전체 성능에 기여하며 다중 objective 조합이 가장 우수.
- 모델의 robust representation 능력이 강화되어 기존 sequential 방법보다 추천 안정성이 높음.

6. Insight

- Self-supervision 신호 추가로 표현 학습 범위가 확장되어 sparse scenario에서도 성능 향상 가능.
- Mutual information maximization은 sequence 내 복합적인 관계 학습에 유리함.
- Pre-train + Fine-tune 전략은 시퀀스 추천 task에서 강한 일반화 능력 제공.
- self-supervised objective 설계가 복잡하고 학습 비용 증가 가능.
- 후속 연구로 다양한 augmentation 방식과 더 큰 스케일/멀티모달 데이터에서 self-supervised 적용 가능.