

DEBERTAV3 : IMPROVING DEBERTA USING ELECTRA-STYLE PRE-TRAINING WITH GRADIENT - DISENTANGLED EMBEDDING SHARING

<https://arxiv.org/pdf/2111.09543>

0. Introduction

- 사전학습 언어 모델은 자연어 이해 성능을 크게 향상시켜 왔음
- DeBERTa는 disentangled attention을 통해 BERT 계열 대비 성능을 개선
- 기존 사전학습 방식은 학습 효율과 성능 사이의 트레이드오프 존재
- ELECTRA 방식은 샘플 효율이 높지만 embedding 공유로 인한 gradient 충돌 문제가 있음
- 본 논문은 embedding gradient 충돌을 해결하여 사전학습 효율과 성능을 동시에 개선하는 것을 목표로 함

1. Overview

- DeBERTaV3는 DeBERTa 구조를 기반으로 ELECTRA 스타일 사전학습을 적용
- MLM 대신 replaced token detection 방식을 사용
- generator와 discriminator가 embedding을 공유하되 gradient 흐름을 분리
- 동일한 계산 자원 대비 더 높은 downstream 성능을 달성하는 것이 목적
- 멀티링구얼 확장 모델에서도 성능 향상을 확인

2. Challenges

- generator와 discriminator는 서로 다른 학습 목표를 가짐
- embedding을 단순 공유할 경우 gradient 간섭이 발생
- 이로 인해 embedding 품질 저하 및 학습 비효율 발생
- 대규모 사전학습 환경에서는 작은 비효율도 큰 비용 증가로 이어짐

3. Method

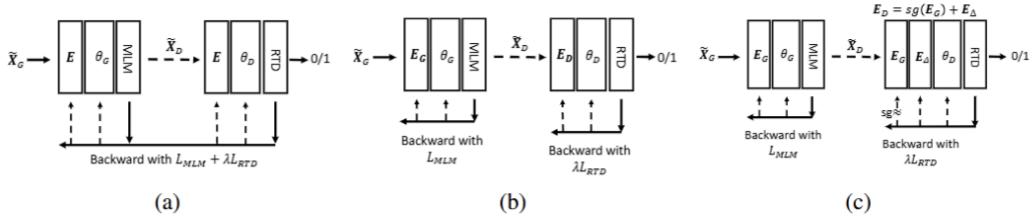


Figure 1: Illustration of different embedding sharing methods. (a) ES: E , θ_G and θ_D will be jointly updated in a single backward pass with regards to $L_{MLM} + \lambda L_{RTD}$. (b) NES: E_G and θ_G will first be updated via the backward pass with regards to L_{MLM} , then E_D and θ_D will be updated via the backward pass with regards to λL_{RTD} . (c) GDES: E_G and θ_G will first be updated in the backward pass with regards to L_{MLM} , then E_D and θ_D will be updated via the backward pass with regards to λL_{RTD} and E_G . sg is the stop gradient operator that prevents the discriminator from updating E_G

Table 1: Average cosine similarity of word embeddings of the generator and the discriminator with different embedding sharing methods.

| Word Embedding Sharing | E_G | E_D | E_Δ |
|------------------------|-------|-------|------------|
| ① ES | 0.02 | 0.02 | - |
| ② NES | 0.45 | 0.02 | - |
| ③ GDES | 0.45 | 0.29 | 0.02 |

Table 2: Fine-tuning results on MNLI and SQuAD v2.0 tasks of base models trained with different embedding sharing methods.

| Model | MNLI-m/mm Acc | SQuAD v2.0 F1/EM |
|-----------------------------|------------------|---------------------|
| BERT _{base} | 84.3/84.7 | 76.3/73.7 |
| ELECTRA _{base} | 85.8/- | -/- |
| DeBERTa _{base} | 86.3/86.2 | 82.5/79.3 |
| DeBERTa+RTD _{base} | | |
| ① ES | 88.8/88.4 | 86.3/83.5 |
| ② NES | 88.3/87.9 | 85.3/82.7 |
| ③ GDES | 89.3/89.0 | 87.2/84.5 |

- 핵심 설계는 gradient-disentangled embedding sharing
- generator와 discriminator가 동일한 embedding 값을 사용하되 gradient는 독립적으로 흐르도록 구조를 분리
- 사전학습은 replaced token detection 기반으로 진행
- generator는 토큰을 생성하고 discriminator는 토큰의 진위를 판별
- 기존 DeBERTa 아키텍처는 대부분 유지됨

4. Experiments

- 자연어 이해 벤치마크 태스크를 통해 성능 평가
- 기존 DeBERTa 및 ELECTRA 계열 모델과 비교
- 단일 언어 및 멀티링구얼 환경에서 실험 수행
- downstream 태스크 평균 성능을 주요 평가 기준으로 사용

5. Results

Table 3: Comparison results on the GLUE development set.

| Model | CoLA Mcc 8.5k | QQP Acc 364k | MNLI-m/mm Acc 393k | SST-2 Acc 67k | STS-B Corr 7k | QNLI Acc 108k | RTE Acc 2.5k | MRPC Acc 3.7k | Avg. |
|----------------------------|---------------------|--------------------|--------------------------|---------------------|---------------------|---------------------|--------------------|---------------------|--------------|
| BERT _{large} | 60.6 | 91.3 | 86.6/- | 93.2 | 90.0 | 92.3 | 70.4 | 88.0 | 84.05 |
| RoBERTa _{large} | 68.0 | 92.2 | 90.2/90.2 | 96.4 | 92.4 | 93.9 | 86.6 | 90.9 | 88.82 |
| XLNet _{large} | 69.0 | 92.3 | 90.8/90.8 | 97.0 | 92.5 | 94.9 | 85.9 | 90.8 | 89.15 |
| ELECTRA _{large} | 69.1 | 92.4 | 90.9/- | 96.9 | 92.6 | 95.0 | 88.0 | 90.8 | 89.46 |
| DeBERTa _{large} | 70.5 | 92.3 | 91.1/91.1 | 96.8 | 92.8 | 95.3 | 88.3 | 91.9 | 90.00 |
| DeBERTaV3 _{large} | 75.3 | 93.0 | 91.8/91.9 | 96.9 | 93.0 | 96.0 | 92.7 | 92.2 | 91.37 |

Table 4: Results on MNLI in/out-domain, SQuAD v2.0, RACE, ReCoRD, SWAG, CoNLL 2003 NER development set. Note that missing results in literature are signified by “-”.

| Model | MNLI-m/mm | SQuAD v2.0 | RACE | ReCoRD | SWAG | NER |
|----------------------------|------------------|------------------|-------------|------------------|-------------|-------------|
| | Acc | F1/EM | Acc | F1/EM | Acc | F1 |
| BERT _{large} | 86.6/- | 81.8/79.0 | 72.0 | - | 86.6 | 92.8 |
| ALBERT _{large} | 86.5/- | 84.9/81.8 | 75.2 | - | - | - |
| RoBERTa _{large} | 90.2/90.2 | 89.4/86.5 | 83.2 | 90.6/90.0 | 89.9 | 93.4 |
| XLNet _{large} | 90.8/90.8 | 90.6/87.9 | 85.4 | - | - | - |
| ELECTRA _{large} | 90.9/- | /88.1 | - | - | - | - |
| Megatron _{336M} | 89.7/90.0 | 88.1/84.8 | 83.0 | - | - | - |
| DeBERTa _{large} | 91.1/91.1 | 90.7/88.0 | 86.8 | 91.4/91.0 | 90.8 | 93.8 |
| DeBERTaV3 _{large} | 91.8/91.9 | 91.5/89.0 | 89.2 | 92.3/91.8 | 93.4 | 93.9 |
| ALBERT _{xxlarge} | 90.8/- | 90.2/87.4 | 86.5 | - | - | - |
| Megatron _{1.3B} | 90.9/91.0 | 90.2/87.1 | 87.3 | - | - | - |
| Megatron _{3.9B} | 91.4/91.4 | 91.2/88.5 | 89.5 | - | - | - |
| DeBERTa _{1.5B} | 91.7/91.9 | 92.2/89.7 | 90.8 | 94.5/94.0 | 92.3 | - |

Table 5: Results on MNLI in/out-domain (m/mm) and SQuAD v2.0 development set. TinyBERT_{small} (Jiao et al., 2019), MiniLMv2_{small} and MiniLMv2_{xsmall} models are pre-trained with knowledge distillation while BERT_{small}, DeBERTaV3_{small} and DeBERTaV3_{xsmall} are trained from scratch with MLM and RTD objective, respectively.

| Model | Vocabulary Size(K) | Backbone #Params(M) | MNLI-m/mm ACC | SQuAD v2.0 F1/EM |
|--|--------------------|---------------------|------------------|------------------|
| Base models: 12 layers, 768 hidden size, 12 heads | | | | |
| BERT _{base} | 30 | 86 | 84.3/84.7 | 76.3/73.7 |
| RoBERTa _{base} | 50 | 86 | 87.6/- | 83.7/80.5 |
| XLNet _{base} | 32 | 92 | 86.8/- | -/80.2 |
| ELECTRA _{base} | 30 | 86 | 88.8/- | -/80.5 |
| DeBERTa _{base} | 50 | 100 | 88.8/88.5 | 86.2/83.1 |
| DeBERTaV3 _{base} | 128 | 86 | 90.6/90.7 | 88.4/85.4 |
| Small models: 6 layers, 768 hidden size, 12 heads | | | | |
| TinyBERT _{small} | 30 | 44 | 84.5/- | 77.7/- |
| MiniLMv2 _{small} | 30 | 44 | 87.0/- | 81.6/- |
| BERT _{small} | 30 | 44 | 81.8/- | 73.2/- |
| DeBERTaV3 _{small} | 128 | 44 | 88.2/87.9 | 82.9/80.4 |
| XSmall models: 12 layers, 384 hidden size, 6 heads | | | | |
| MiniLMv2 _{xsmall} | 30 | 22 | 86.9/- | 82.3/- |
| DeBERTaV3 _{xsmall} | 128 | 22 | 88.1/88.3 | 84.8/82.0 |

Table 6: Results on XNLI test set under the cross-lingual transfer and the translate-train-all settings.

| Model | en | fr | es | de | el | bg | ru | tr | ar | vi | th | zh | hi | sw | ur | Avg |
|----------------------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
| Cross-lingual transfer | | | | | | | | | | | | | | | | |
| XLM | 83.2 | 76.7 | 77.7 | 74.0 | 72.7 | 74.1 | 72.7 | 68.7 | 68.6 | 72.9 | 68.9 | 72.5 | 65.6 | 58.2 | 62.4 | 70.7 |
| mT5 _{base} | 84.7 | 79.1 | 80.3 | 77.4 | 77.1 | 78.6 | 77.1 | 72.8 | 73.3 | 74.2 | 73.2 | 74.1 | 70.8 | 69.4 | 68.3 | 75.4 |
| XLM-R _{base} | 85.8 | 79.7 | 80.7 | 78.7 | 77.5 | 79.6 | 78.1 | 74.2 | 73.8 | 76.5 | 74.6 | 76.7 | 72.4 | 66.5 | 68.3 | 76.2 |
| mDeBERTaV3 _{base} | 88.2 | 82.6 | 84.4 | 82.7 | 82.3 | 82.4 | 80.8 | 79.5 | 78.5 | 78.1 | 76.4 | 79.5 | 75.9 | 73.9 | 72.4 | 79.8 |
| Translate train all | | | | | | | | | | | | | | | | |
| XLM | 84.5 | 80.1 | 81.3 | 79.3 | 78.6 | 79.4 | 77.5 | 75.2 | 75.6 | 78.3 | 75.7 | 78.3 | 72.1 | 69.2 | 67.7 | 76.9 |
| mT5 _{base} | 82.0 | 77.9 | 79.1 | 77.7 | 78.1 | 78.5 | 76.5 | 74.8 | 74.4 | 74.5 | 75.0 | 76.0 | 72.2 | 71.5 | 70.4 | 75.9 |
| XLM-R _{base} | 85.4 | 81.4 | 82.2 | 80.3 | 80.4 | 81.3 | 79.7 | 78.6 | 77.3 | 79.7 | 77.9 | 80.2 | 76.1 | 73.1 | 73.0 | 79.1 |
| mDeBERTaV3 _{base} | 88.9 | 84.4 | 85.3 | 84.8 | 84.0 | 84.5 | 83.2 | 82.0 | 81.6 | 82.0 | 79.8 | 82.6 | 79.3 | 77.3 | 73.6 | 82.2 |

- DeBERTaV3는 기존 DeBERTa 대비 일관된 성능 향상
- ELECTRA 기반 모델 대비도 평균 성능 우위
- 동일하거나 더 적은 사전학습 비용으로 높은 성능 달성
- 멀티링구얼 환경에서도 zero-shot 성능 개선 확인
- 사전학습 안정성과 수렴 속도 모두 개선됨

6. Insight

- 이 논문의 핵심은 새로운 모델 구조가 아니라 학습 신호 제어
- embedding 공유 자체보다 gradient 충돌이 성능 저하의 원인이었음을 명확히 지적
- 사전학습 효율 개선은 단순한 속도 문제가 아니라 표현 품질 문제와 직결됨
- ELECTRA 방식의 한계를 구조적으로 보완한 점이 실질적 기여