Deep Residual Learning for Image Recognition

https://arxiv.org/pdf/1512.03385

0 Introduction

- 딥러닝에서 네트워크 깊이가 증가하면 표현력 향상 가능
- 하지만 일정 depth 이상에서는 성능이 감소하는 degradation 문제 발생
- 이는 overfitting이 아닌 optimization difficulty 문제
- 기존 CNN은 gradient vanishing 문제로 깊은 학습 어려움
- 매우 깊은 네트워크를 안정적으로 학습하는 것이 연구 목적
- 이를 위해 residual learning 방식 제안

1 Overview

- 기존 mapping H(x) 대신 residual function F(x) 학습
- 출력은 H(x) = F(x) + x 형태로 구성
- skip connection으로 입력 정보 직접 전달
- gradient 흐름이 개선되어 깊은 구조에서도 학습 가능
- 34, 50, 101, 152 layer 등 다양한 깊이 실험 수행
- 이미지 분류 및 detection task에서 성능 검증

2 Challenges

- deep network에서 gradient vanishing / exploding 문제 발생
- layer 증가 시 training error 증가하는 degradation 문제 존재
- 기존 CNN 구조는 depth 확장에 한계 존재

- feature 전달 과정에서 정보 손실 발생
- 깊은 모델일수록 학습 안정성과 수렴 속도 저하

3 Method

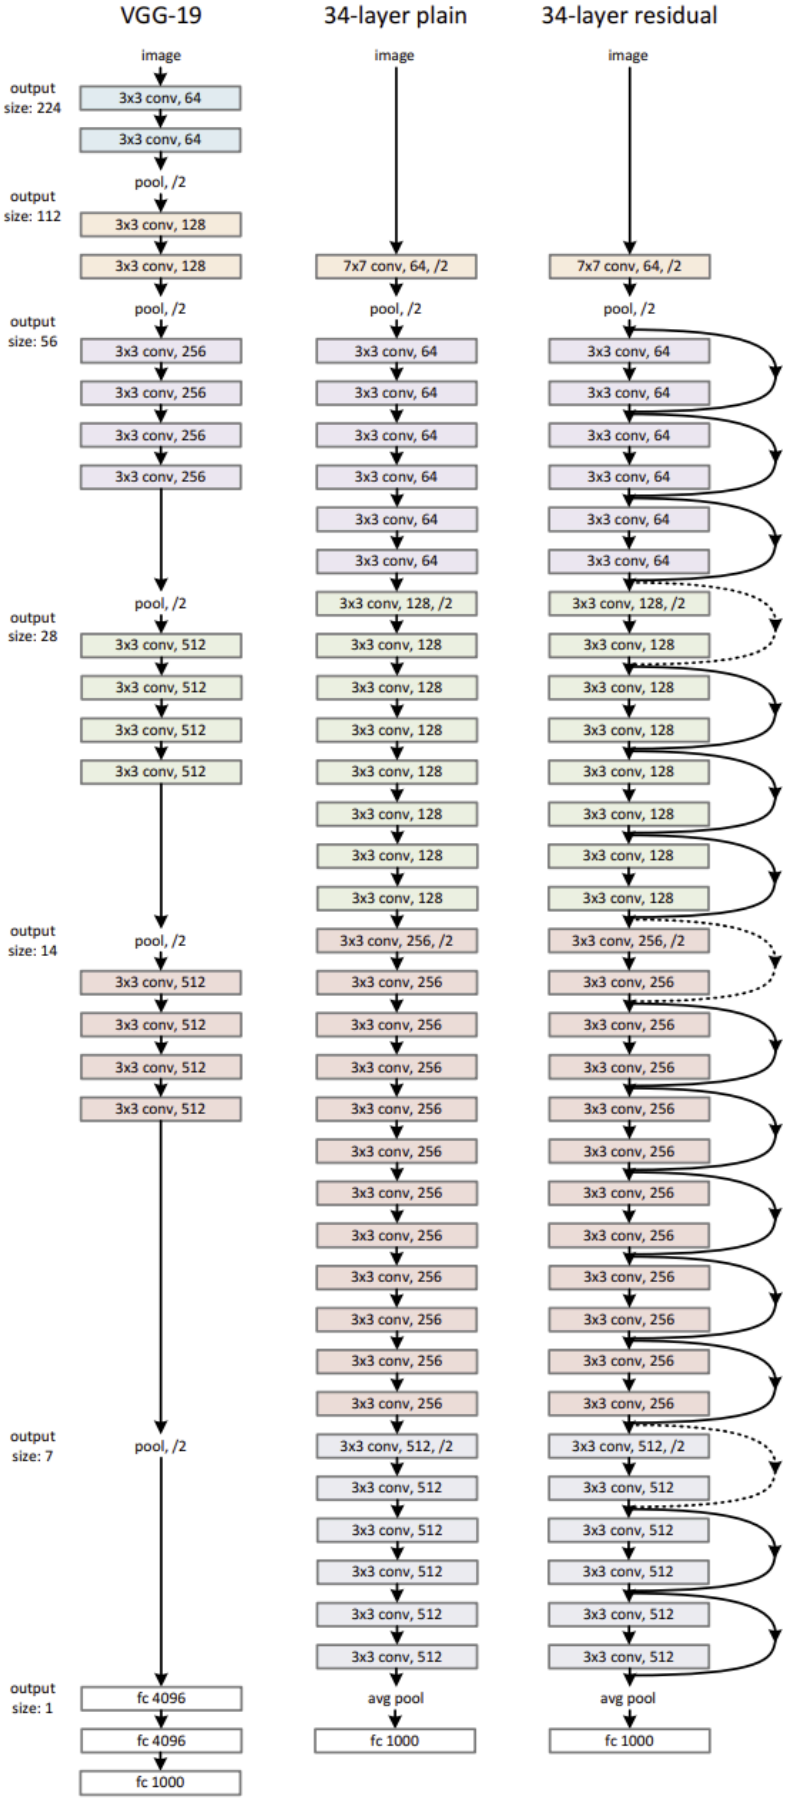
VGG-19
34-layer plain
34-layer residual
image
output size: 224
3x3 conv, 64
3x3 conv, 64
pool, /2
output size: 112
3x3 conv, 128
3x3 conv, 128
pool, /2
output size: 56
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
pool, /2
output size: 28
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
pool, /2
output size: 14
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
pool, /2
output size: 7
fc 4096
fc 4096
fc 1000
output size: 1
7x7 conv, 64, /2
pool, /2
3x3 conv, 64
3x3 conv, 128, /2
3x3 conv, 128
3x3 conv, 256, /2
3x3 conv, 256
3x3 conv, 512, /2
3x3 conv, 512
avg pool
fc 1000

- Residual Connection 기반 구조 설계
- 입력 x를 다음 layer로 전달하는 skip connection 사용
- H(x) 대신 F(x) + x 형태로 학습
- identity mapping으로 정보 손실 최소화
- stacked convolution layers로 deep architecture 구성
- bottleneck 구조로 연산 효율 개선
- Batch Normalization으로 학습 안정성 확보

4 Experiments

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$
conv3_x	28×28	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times8$
conv4_x	14×14	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix}\times6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times23$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times36$
conv5_x	7×7	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

- ImageNet 대규모 데이터셋 사용
- CIFAR-10 데이터셋 추가 실험
- VGG, plain network 등 기존 CNN과 비교
- classification task에서 Top-1, Top-5 error 평가
- object detection task에서도 성능 측정
- depth 증가에 따른 성능 변화 분석

5 Results

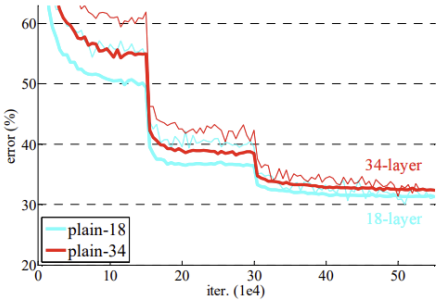

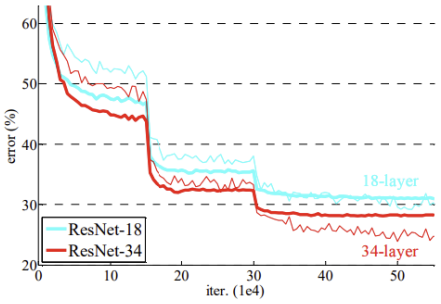

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	**21.43**	**5.71**

method	top-1 err.	top-5 err.
VGG [41] (ILSVRC'14)	-	8.43†
GoogLeNet [44] (ILSVRC'14)	-	7.89
VGG [41] (v5)	24.4	7.1
PReLU-net [13]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25
ResNet-101	19.87	4.60
ResNet-152	**19.38**	**4.49**

method	top-5 err. (**test**)
VGG [41] (ILSVRC'14)	7.32
GoogLeNet [44] (ILSVRC'14)	6.66
VGG [41] (v5)	6.8
PReLU-net [13]	4.94
BN-inception [16]	4.82
ResNet (ILSVRC'15)	**3.57**

method			error (%)
Maxout [10]			9.38
NIN [25]			8.81
DSN [24]			8.22
	# layers	# params	
FitNet [35]	19	2.5M	8.39
Highway [42, 43]	19	2.3M	7.54 (7.72±0.16)
Highway [42, 43]	32	1.25M	8.80
ResNet	20	0.27M	8.75
ResNet	32	0.46M	7.51
ResNet	44	0.66M	7.17
ResNet	56	0.85M	6.97
ResNet	110	1.7M	**6.43** (6.61±0.16)
ResNet	1202	19.4M	7.93

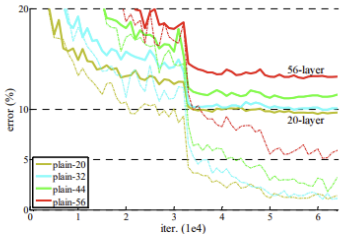

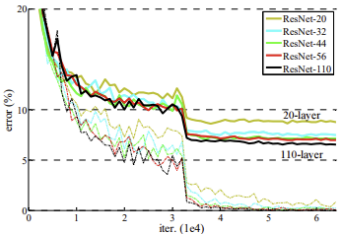

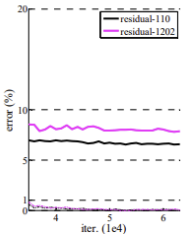

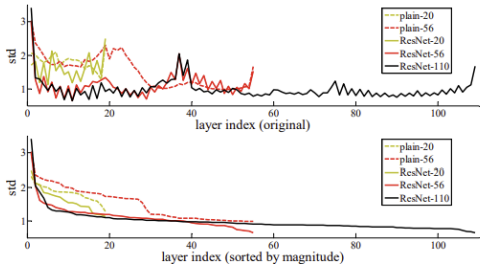

training data	07+12	07++12
test data	VOC 07 test	VOC 12 test
VGG-16	73.2	70.4
ResNet-101	**76.4**	**73.8**

metric	mAP@.5	mAP@[.5, .95]
VGG-16	41.5	21.2
ResNet-101	**48.4**	**27.2**

- ResNet은 기존 CNN 대비 모든 깊이에서 성능 향상
- 152-layer 모델이 가장 높은 성능 기록
- ImageNet 기준 Top-5 error 약 3.57%
- plain network는 depth 증가 시 성능 저하 발생
- ResNet은 depth 증가 시 성능 지속적으로 개선
- detection task에서도 성능 향상 확인

6 Insight

- skip connection은 gradient 흐름을 안정적으로 유지
- 이 구조는 이후 대부분의 딥러닝 모델에 적용됨
- Transformer에서도 동일한 residual 구조 사용
- 단점은 연산량 증가와 구조 복잡성
- 하지만 성능 대비 효율이 매우 뛰어나 표준 아키텍처로 자리잡음