

# Deep Speech 2: End-to-End Speech Recognition in English and Mandarin

<https://arxiv.org/abs/1512.02595>

## 0. Introduction

- 음성 인식(ASR)에서 영어와 만다린을 단일 모델로 처리하는 목표 설정.
- 기존 ASR 파이프라인은 수작업 특징 공학과 복잡한 모듈(HMM 등) 포함.
- 엔드투엔드 딥러닝으로 음성 → 텍스트 변환을 단일 신경망으로 수행.
- 핵심 기여:
  - 영어와 만다린을 동일 구조 모델로 처리, 잡음 및 다양한 억양 대응.
  - 대규모 데이터와 고성능 컴퓨팅 활용으로 학습시간 및 실험 효율 개선.
  - 낮은 지연으로 온라인 서비스 적용 가능.

## 1. Overview


- 모델은 음성을 스펙트로그램 → 문자(또는 음절)로 직접 맵핑.
- 구조: 합성곱 + 순환(RNN) 층, 배치정규화, 양방향 RNN 포함.
- 두 언어에서 인간 수준 성능 달성.
- 파이프라인 단순화, 잡음·억양 대응, 다언어 확장 가능.


## 2. Challenges

- 영어와 만다린은 음운 구조, 문자 체계, 발음 패턴이 달라 단일 모델 적용 어려움.
- 대규모 음성 데이터 처리 시 계산량과 메모리 부담이 큼.
- 잡음, 억양 변화, 다양한 마이크·환경에서 일반화 문제.

- 수작업 특징 추출 제거로 모델 학습 부담 증가.
- 온라인 서비스 요구(실시간 처리, 낮은 지연) 달성 필요.

### 3. Method





- 입력: 음성을 스펙트로그램으로 변환 후 입력.
- 모델 구조:
  - 초기 합성곱 층에서 시간축/주파수축 특징 추출.
  - 다층 순환 신경망(RNN)으로 시간적 정보 학습.
  - 배치정규화, 드롭아웃, 학습률 스케줄링 적용.
- 학습: CTC 손실 함수 사용, 데이터 증강 및 노이즈 삽입으로 강건성 확보.
- 배포 설계: GPU 병렬 처리, 배치 디스패치로 학습·추론 속도 개선.
- 온라인 환경 지원 및 비용 최소화 고려.

## 4. Experiments

Dataset	Speech Type	Hours
WSJ	read	80
Switchboard	conversational	300
Fisher	conversational	2000
LibriSpeech	read	960
Baidu	read	5000
Baidu	mixed	3600
Total		11940

- 데이터셋: 영어 약 11,940 시간, 만다린 약 9,400 시간, 다양한 잡음/환경 포함.
- 비교 대상: 기존 ASR 시스템, 인간 작업자 성능.
- 평가 지표: 단어 오류율(WER), 문자 오류율(CER).

- 실험 변수: 모델 아키텍처(합성곱 층, RNN 깊이), 데이터 크기, 잡음 조건, 병렬 처리 방식.
  - 실험 설계: 대규모 병렬 학습, 다양한 입력 환경 테스트, 실사용 조건 모사.
- 

## 5. Results

Fraction of Data	Hours	Regular Dev	Noisy Dev
1%	120	29.23	50.97
10%	1200	13.80	22.99
20%	2400	11.65	20.41
50%	6000	9.51	15.90
100%	12000	8.46	13.59

Model size	Model type	Regular Dev	Noisy Dev
$18 \times 10^6$	GRU	10.59	21.38
$38 \times 10^6$	GRU	9.06	17.07
$70 \times 10^6$	GRU	8.54	15.98
$70 \times 10^6$	RNN	8.44	15.09
$100 \times 10^6$	GRU	7.78	14.17
$100 \times 10^6$	RNN	7.73	13.06

Read Speech			
Test set	DS1	DS2	Human
WSJ eval'92	4.94	3.60	5.03
WSJ eval'93	6.94	4.98	8.08
LibriSpeech test-clean	7.89	5.33	5.83
LibriSpeech test-other	21.74	13.25	12.69

Accented Speech			
Test set	DS1	DS2	Human
VoxForge American-Canadian	15.01	7.55	4.85
VoxForge Commonwealth	28.46	13.56	8.15
VoxForge European	31.20	17.55	12.76
VoxForge Indian	45.35	22.44	22.15

Noisy Speech			
Test set	DS1	DS2	Human
CHiME eval clean	6.30	3.34	3.46
CHiME eval real	67.94	21.79	11.84
CHiME eval sim	80.27	45.05	31.33

- 영어와 만다린 모두에서 높은 성능 달성.
- 만다린에서는 인간 작업자 수준 성능 달성.
- 학습 및 추론 속도에서 기존 시스템 대비 약 7배 개선.
- 잡음 환경과 다양한 억양 조건에서도 안정적 성능 유지.
- 데이터 규모와 학습 인프라 충분 시 엔드투엔드 방식 경쟁력 높음.
- 단점: 모델 규모가 크고 연산 자원 많이 필요.

## 6. Insight

- 엔드투엔드 딥러닝이 실무 수준 ASR 적용 가능함을 보여줌.
- 언어 구조가 다른 영어와 만다린을 동일 모델로 처리, 다언어 ASR 연구 전환점.
- 실무적 장점: 데이터·컴퓨팅 인프라 충분 시 효과적.
- 단점: 학습·운영 리스크 증가, 데이터 확보 및 잡음 대응 필요.
- 후속 연구: 적은 데이터 학습, 경량화 모델, 다양한 언어·억양·잡음 조건 대응.