

Deep Speech : Scaling up end-to-end speech recognition

<https://arxiv.org/pdf/1412.5567>

0. Introduction

- 음성 인식은 기존에 특정 추출, 음향 모델, 언어 모델 등 여러 모듈이 필요해 복잡한 구조를 가졌음
- 대규모 데이터와 GPU 연산이 가능해지면서 end to end 방식의 단순한 모델이 필요해 졌음
- 논문은 단일 RNN 기반 end to end 모델 Deep Speech 를 제안
- 대규모 음성 데이터, 합성 데이터, GPU 병렬화를 활용해 기존 시스템을 뛰어넘는 성능을 보였음

1. Overview

- 하나의 신경망이 스펙트로그램 입력을 받아 문자 확률을 직접 출력하는 구조
- 모델은 비순환 레이어 3개, 양방향 순환 레이어 1개, 비순환 레이어 1개로 구성됨
- 활성화 함수는 clipped ReLU
- 학습 과정은 CTC 손실을 기반으로 하며 정렬 정보 없이 음성을 문자 시퀀스로 변환함
- 다양한 환경의 음성 데이터에서 동작하도록 설계됨

2. Challenges

- 정렬 정보가 없기 때문에 시간 길이가 긴 음성에서 문자를 직접 예측하기 어려움
- 양방향 순환 레이어는 병렬화가 어려워 연산 부담이 큼
- 실사용 환경은 잡음, 발화 속도, 억양 변화가 크므로 일반화 어려움
- 대규모 모델 학습 시 과적합을 방지하기 위한 증강과 정규화 전략이 필요함

3. Method

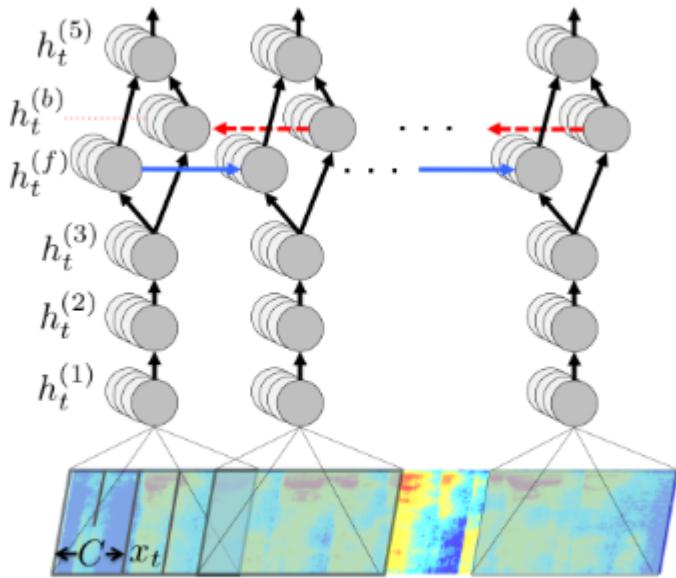


Figure 1: Structure of our RNN model and notation.

- 입력은 스펙트로그램 기반
- 문자 집합은 알파벳, 공백, 아포스트로피, blank 로 구성
- 모델은 총 5개의 레이어로 구성되며 4 번째 레이어가 양방향 순환 구조
- clipped ReLU 로 그라디언트 폭주를 방지
- CTC 손실과 Nesterov momentum 최적화 적용
- GPU 분산 학습을 위해 모델 파티셔닝과 멀티 GPU 병렬 학습 활용
- 드롭아웃을 비순환 레이어에 적용
- 시간 축 시프트 기반 테스트 증강 사용

4. Experiments

Dataset	Type	Hours	Speakers
WSJ	read	80	280
Switchboard	conversational	300	4000
Fisher	conversational	2000	23000
Baidu	read	5000	9600

- 공개 데이터와 자체 수집 데이터를 포함해 대규모 음성 데이터를 사용
- 합성 잡음, 발화 속도 변형, 다양한 환경을 반영한 데이터 증강 활용
- 평가 지표는 WER
- 모델 단일, 양상블, 테스트 시 시프트 적용 등 다양한 설정을 실험
- 비교 대상은 기존 상용 시스템 및 연구 모델
- 데이터 전체 규모는 일부 구간에서만 정확한 수치가 제공되어 부분적으로 모호함 (확실하지 않음)

5. Results

Model	SWB	CH	Full
Vesely et al. (GMM-HMM BMMI) [44]	18.6	33.0	25.8
Vesely et al. (DNN-HMM sMBR) [44]	12.6	24.1	18.4
Maas et al. (DNN-HMM SWB) [28]	14.6	26.3	20.5
Maas et al. (DNN-HMM FSH) [28]	16.0	23.7	19.9
Seide et al. (CD-DNN) [39]	16.1	n/a	n/a
Kingsbury et al. (DNN-HMM sMBR HF) [22]	13.3	n/a	n/a
Sainath et al. (CNN-HMM) [36]	11.5	n/a	n/a
Soltan et al. (MLP/CNN+I-Vector) [40]	10.4	n/a	n/a
Deep Speech SWB	20.0	31.8	25.9
Deep Speech SWB + FSH	12.6	19.3	16.0

System	Clean (94)	Noisy (82)	Combined (176)
Apple Dictation	14.24	43.76	26.73
Bing Speech	11.73	36.12	22.05
Google API	6.64	30.47	16.72
wit.ai	7.94	35.06	19.41
Deep Speech	6.56	19.06	11.85

- Switchboard Hub5 00에서 WER 16.0 기록
- 잡음 환경 데이터셋에서는 WER 19.1로 기존 상용 시스템보다 월등히 우세
- 합성 데이터, 모델 양상블, GPU 병렬 학습이 성능을 크게 높였음
- Ablation 형식의 실험을 통해 각 요소의 기여도를 확인함

6. Insight

- end to end 모델이 기존 파이프라인을 대체할 실질적 가능성을 보여줌
- 거대한 데이터와 계산 자원이 성능 향상의 핵심 요인이었음
- 다양한 환경에서 성능 확보를 위해 합성 데이터가 매우 효과적임
- 계산 비용이 높아 저자원 환경 적용에는 한계가 존재함
- 후속 연구는 모델 효율화, 실시간 처리, 합성 데이터 품질 개선 등이 필요함