DistilBERT, a distilled version of BERT : smaller, faster, cheaper and lighter

https://arxiv.org/pdf/1910.01108

0. Introduction

- BERT는 NLP에서 높은 성능을 보이지만 모델 크기와 계산 비용이 매우 큼
- 실제 서비스나 모바일 환경에서는 높은 메모리와 연산 비용이 문제
- 본 논문은 **knowledge distillation**을 활용해 BERT를 경량화한 DistilBERT 모델을 제안
- 목표는 성능을 최대한 유지하면서 모델 크기와 추론 속도를 개선하는 것

1. Overview

- BERT를 teacher 모델로 사용하고 DistilBERT를 student 모델로 학습
- knowledge distillation을 통해 BERT의 지식을 작은 모델에 전달
- Transformer 구조는 유지하면서 layer 수를 줄여 경량화
- 결과적으로 모델 크기 감소와 추론 속도 개선 달성

2. Challenges

- 대형 언어 모델은 높은 성능을 보이지만 계산 비용이 매우 큼
- 모바일 또는 실시간 서비스 환경에서는 모델 경량화 필요
- 단순한 모델 축소는 성능 저하 문제 발생
- 작은 모델에서도 BERT 수준의 언어 이해 능력을 유지하는 것이 어려움

3. Method

- Teacher 모델
  - 사전 학습된 BERT 사용
- Student 모델
  - Transformer layer 수를 줄인 DistilBERT 구조 사용
- Knowledge Distillation 학습 적용
  - teacher 모델의 출력 분포를 student 모델이 학습
- Pre-training 과정에서 **Triple Loss** 사용
  - language modeling loss
  - distillation loss
  - cosine embedding loss
- 해당 학습 방식으로 teacher 모델의 표현 정보를 student 모델로 전달

4. Experiments

- 학습 데이터
  - Wikipedia
  - BookCorpus
- 비교 모델
  - BERT-base
  - 기존 Transformer 기반 모델
- 평가 벤치마크
  - GLUE benchmark
  - SQuAD question answering
  - 다양한 NLP downstream task
- 평가 지표
  - Accuracy
  - F1 score

- Exact Match

5. Results

Model	**Score**	CoLA	MNLI	MRPC	QNLI	QQP	RTE	SST-2	STS-B	WNLI
ELMo	68.7	44.1	68.6	76.6	71.1	86.2	53.4	91.5	70.4	56.3
BERT-base	79.5	56.3	86.7	88.6	91.8	89.6	69.3	92.7	89.0	53.5
DistilBERT	77.0	51.3	82.2	87.5	89.2	88.5	59.9	91.3	86.9	56.3

Model	IMDb (acc.)	SQuAD (EM/F1)
BERT-base	93.46	81.2/88.5
DistilBERT	92.82	77.7/85.8
DistilBERT (D)	-	79.1/86.9

Model	# param. (Millions)	Inf. time (seconds)
ELMo	180	895
BERT-base	110	668
DistilBERT	66	410

Ablation	**Variation on GLUE macro-score**
$\emptyset$ - L_{cos} - L_{mlm}	-2.96
L_{ce} - $\emptyset$ - L_{mlm}	-1.46
L_{ce} - L_{cos} - $\emptyset$	-0.31
Triple loss + random weights initialization	-3.69

- DistilBERT는 BERT 대비 약 40% 작은 모델 크기
- 약 60% 빠른 추론 속도 달성
- GLUE benchmark에서 약 97% 수준 성능 유지
- 일부 NLP task에서도 BERT와 유사한 성능 확인

6. Insight

- knowledge distillation을 활용한 **모델 경량화 가능성 확인**
- 대형 언어 모델을 실제 서비스 환경에 적용하기 위한 중요한 접근 방법 제시
- DistilBERT 구조는 모바일 NLP 및 실시간 시스템에 적합
- 이후 TinyBERT, MobileBERT 등 다양한 경량화 연구의 기반이 됨