LoRA : Low-Rank Adaptation of Large Language Models

https://arxiv.org/pdf/2106.09685

0. Introduction

- 대형 언어모델은 fine-tuning 시 전체 파라미터 업데이트 필요
- GPT-3 수준 모델은 수십억~수천억 파라미터
- 문제
  - GPU 메모리 요구량 매우 큼
  - 학습 비용 증가
  - task마다 모델 복제 필요
- 기존 접근
  - Adapter, Prefix-Tuning 등 PEFT 방법 존재
  - 하지만 구조 변경 또는 효율 한계 존재
- 핵심 문제
  - 전체 파라미터를 업데이트하지 않고도 성능 유지 가능한가
- 기여
  - weight update를 low-rank 형태로 근사
  - 극소량 파라미터만 학습
  - 성능 유지 또는 향상

1. Overview

- 핵심 아이디어
  - weight 변화 ΔW는 저차원 구조로 표현 가능

- 방식
  - 기존 weight는 고정
  - 작은 행렬 A, B만 학습
- 구조
  - $W = W_0 + BA$
- 적용 위치
  - Transformer attention layer
- 효과
  - 파라미터 수 크게 감소
  - 메모리 및 저장 비용 감소

2. Challenges

- 대형 모델 fine-tuning 문제
  - 메모리 부족
  - 계산 비용 증가
- 기존 방법 한계
  - Adapter → 추가 layer 필요
  - Prefix → 입력 길이 증가
- 이론적 문제
  - weight update가 low-rank로 충분한지 불확실
- 실무 문제
  - rank 선택 기준 없음
  - 적용 layer 선택 문제

3. Method

- 기본 설정

W_0 : pretrained weight

ΔW : 업데이트

- 기존 방식

  $W = W_0 + \Delta W$

- LoRA 방식

  $\Delta W \approx B \times A$

  - $A \in \mathbb{R}^{r \times d}$
  - $B \in \mathbb{R}^{d \times r}$
  - $r \ll d$

- 최종 형태

  $W = W_0 + BA$

- 학습 방식
  - W_0 freeze
  - A, B만 업데이트
- scaling

  $\Delta W = (\alpha / r) \times BA$

- 적용 위치
  - attention projection matrix
  - 주로 Query, Value
- 초기화
  - A random
  - B = 0

4. Experiments

- 모델
  - RoBERTa
  - GPT 계열 일부 (확실하지 않음)

- 데이터
  - GLUE benchmark
- 비교 대상
  - Full fine-tuning
  - Adapter
  - Prefix-Tuning
- 평가 지표
  - accuracy
  - F1 score
- 설정
  - rank r 다양하게 실험

5. Results

Model & Method	# Trainable Parameters	MNLI	SST-2	MRPC	CoLA	QNLI	QQP	RTE	STS-B	Avg.
RoB_{base} (FT)*	125.0M	**87.6**	94.8	90.2	**63.6**	92.8	**91.9**	78.7	91.2	86.4
RoB_{base} (BitFit)*	0.1M	84.7	93.7	**92.7**	62.0	91.8	84.0	81.5	90.8	85.2
RoB_{base} (Adpt^{D})*	0.3M	$87.1_{\pm.0}$	$94.2_{\pm.1}$	$88.5_{\pm1.1}$	$60.8_{\pm.4}$	$93.1_{\pm.1}$	$90.2_{\pm.0}$	$71.5_{\pm2.7}$	$89.7_{\pm.3}$	84.4
RoB_{base} (Adpt^{D})*	0.9M	$87.3_{\pm.1}$	$94.7_{\pm.3}$	$88.4_{\pm.1}$	$62.6_{\pm.9}$	$93.0_{\pm.2}$	$90.6_{\pm.0}$	$75.9_{\pm2.2}$	$90.3_{\pm.1}$	85.4
RoB_{base} (LoRA)	0.3M	$87.5_{\pm.3}$	$\mathbf{95.1}_{\pm.2}$	$89.7_{\pm.7}$	$63.4_{\pm1.2}$	$\mathbf{93.3}_{\pm.3}$	$90.8_{\pm.1}$	$\mathbf{86.6}_{\pm.7}$	$\mathbf{91.5}_{\pm.2}$	**87.2**
$\text{RoB}_{\text{large}}$ (FT)*	355.0M	90.2	**96.4**	**90.9**	68.0	94.7	**92.2**	86.6	92.4	88.9
$\text{RoB}_{\text{large}}$ (LoRA)	0.8M	$\mathbf{90.6}_{\pm.2}$	$96.2_{\pm.5}$	$\mathbf{90.9}_{\pm1.2}$	$\mathbf{68.2}_{\pm1.9}$	$\mathbf{94.9}_{\pm.3}$	$91.6_{\pm.1}$	$\mathbf{87.4}_{\pm2.5}$	$\mathbf{92.6}_{\pm.2}$	**89.0**
$\text{RoB}_{\text{large}}$ (Adpt^{P})†	3.0M	$90.2_{\pm.3}$	$96.1_{\pm.3}$	$90.2_{\pm.7}$	$\mathbf{68.3}_{\pm1.0}$	$\mathbf{94.8}_{\pm.2}$	$\mathbf{91.9}_{\pm.1}$	$83.8_{\pm2.9}$	$92.1_{\pm.7}$	88.4
$\text{RoB}_{\text{large}}$ (Adpt^{P})†	0.8M	$\mathbf{90.5}_{\pm.3}$	$\mathbf{96.6}_{\pm.2}$	$89.7_{\pm1.2}$	$67.8_{\pm2.5}$	$\mathbf{94.8}_{\pm.3}$	$91.7_{\pm.2}$	$80.1_{\pm2.9}$	$91.9_{\pm.4}$	87.9
$\text{RoB}_{\text{large}}$ (Adpt^{H})†	6.0M	$89.9_{\pm.5}$	$96.2_{\pm.3}$	$88.7_{\pm2.9}$	$66.5_{\pm4.4}$	$94.7_{\pm.2}$	$92.1_{\pm.1}$	$83.4_{\pm1.1}$	$91.0_{\pm1.7}$	87.8
$\text{RoB}_{\text{large}}$ (Adpt^{H})†	0.8M	$90.3_{\pm.3}$	$96.3_{\pm.5}$	$87.7_{\pm1.7}$	$66.3_{\pm2.0}$	$94.7_{\pm.2}$	$91.5_{\pm.1}$	$72.9_{\pm2.9}$	$91.5_{\pm.5}$	86.4
$\text{RoB}_{\text{large}}$ (LoRA)†	0.8M	$\mathbf{90.6}_{\pm.2}$	$96.2_{\pm.5}$	$\mathbf{90.2}_{\pm1.0}$	$68.2_{\pm1.9}$	$\mathbf{94.8}_{\pm.3}$	$91.6_{\pm.2}$	$\mathbf{85.2}_{\pm1.1}$	$\mathbf{92.3}_{\pm.5}$	**88.6**
DeB_{XXL} (FT)*	1500.0M	91.8	**97.2**	92.0	72.0	**96.0**	92.7	93.9	92.9	91.1
DeB_{XXL} (LoRA)	4.7M	$\mathbf{91.9}_{\pm.2}$	$96.9_{\pm.2}$	$\mathbf{92.6}_{\pm.6}$	$\mathbf{72.4}_{\pm1.1}$	$\mathbf{96.0}_{\pm.1}$	$\mathbf{92.9}_{\pm.1}$	$\mathbf{94.9}_{\pm.4}$	$\mathbf{93.0}_{\pm.2}$	**91.3**

Model & Method	# Trainable Parameters	E2E NLG Challenge				
		BLEU	NIST	MET	ROUGE-L	CIDEr
GPT-2 M (FT)*	354.92M	68.2	8.62	46.2	71.0	2.47
GPT-2 M ($Adapter^{L}$)*	0.37M	66.3	8.41	45.0	69.8	2.40
GPT-2 M ($Adapter^{L}$)*	11.09M	68.9	8.71	46.1	71.3	2.47
GPT-2 M ($Adapter^{H}$)	11.09M	$67.3_{\pm.6}$	$8.50_{\pm.07}$	$46.0_{\pm.2}$	$70.7_{\pm.2}$	$2.44_{\pm.01}$
GPT-2 M (FT^{Top2})*	25.19M	68.1	8.59	46.0	70.8	2.41
GPT-2 M (PreLayer)*	0.35M	69.7	8.81	46.1	71.4	2.49
GPT-2 M (LoRA)	0.35M	**$70.4_{\pm.1}$**	**$8.85_{\pm.02}$**	**$46.8_{\pm.2}$**	**$71.8_{\pm.1}$**	**$2.53_{\pm.02}$**
GPT-2 L (FT)*	774.03M	68.5	8.78	46.0	69.9	2.45
GPT-2 L ($Adapter^{L}$)	0.88M	$69.1_{\pm.1}$	$8.68_{\pm.03}$	$46.3_{\pm.0}$	$71.4_{\pm.2}$	**$2.49_{\pm.0}$**
GPT-2 L ($Adapter^{L}$)	23.00M	$68.9_{\pm.3}$	$8.70_{\pm.04}$	$46.1_{\pm.1}$	$71.3_{\pm.2}$	$2.45_{\pm.02}$
GPT-2 L (PreLayer)*	0.77M	70.3	8.85	46.2	71.7	2.47
GPT-2 L (LoRA)	0.77M	**$70.4_{\pm.1}$**	**$8.89_{\pm.02}$**	**$46.8_{\pm.2}$**	**$72.0_{\pm.2}$**	$2.47_{\pm.02}$

Model&Method	# Trainable Parameters	WikiSQL Acc. (%)	MNLI-m Acc. (%)	SAMSum R1/R2/RL
GPT-3 (FT)	175,255.8M	**73.8**	89.5	52.0/28.0/44.5
GPT-3 (BitFit)	14.2M	71.3	91.0	51.3/27.4/43.5
GPT-3 (PreEmbed)	3.2M	63.1	88.6	48.3/24.2/40.5
GPT-3 (PreLayer)	20.2M	70.1	89.5	50.8/27.3/43.5
GPT-3 ($Adapter^{H}$)	7.1M	71.9	89.8	53.0/28.9/44.8
GPT-3 ($Adapter^{H}$)	40.1M	73.2	**91.5**	53.2/29.0/45.1
GPT-3 (LoRA)	4.7M	73.4	**91.7**	**53.8/29.8/45.9**
GPT-3 (LoRA)	37.7M	**74.0**	**91.6**	53.4/29.2/45.1

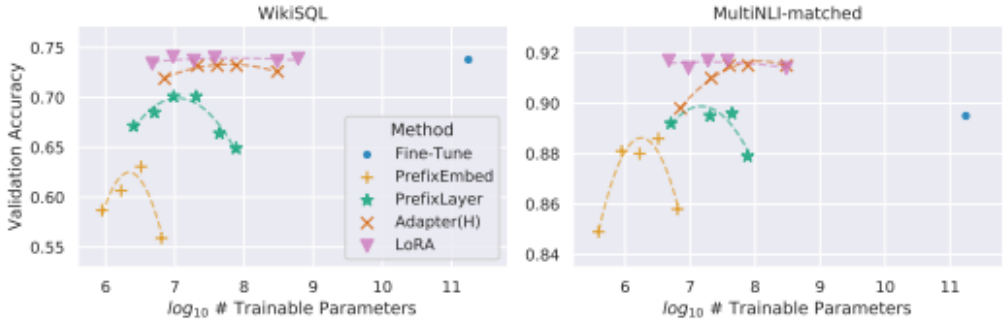

- 성능
  - Full fine-tuning과 거의 동일
  - 일부 task에서 더 높은 성능
- 파라미터
  - 약 0.01% 수준만 학습
- 메모리
  - GPU 사용량 크게 감소

- Ablation
  - rank 증가 시 성능 증가
- 비교
  - Adapter 대비 더 높은 효율

6. Insight

- 핵심 의미
  - weight update는 저차원 구조로 충분히 표현 가능
- 장점
  - 높은 parameter efficiency
  - 기존 모델 구조 유지
  - deployment 비용 절감
- 단점
  - rank 선택 경험적
  - 일부 task에서 성능 변동 가능 (확실하지 않음)
- 실무적 의미
  - LoRA는 LLM fine-tuning의 표준 접근 방식
- 확장 방향
  - QLoRA
  - multi-modal 적용
  - adaptive rank 연구