

Masked Autoencoders Are Scalable Vision Learners

<https://arxiv.org/pdf/2111.06377.pdf>

0. Introduction

- Vision Transformer(ViT) 기반 모델들은 대규모 데이터에서 강력한 성능을 보이나, Supervised Pretraining에 많은 라벨 데이터가 필요함.
- Self-Supervised Learning(SSSL)은 라벨 없이 표현학습을 가능하게 하지만, 이미지 도메인에서 효율적인 SSSL 구조가 제한적임.
- 본 논문은 Masked Autoencoder (MAE) 구조를 제안하여, 이미지에서 효율적이고 확장 가능한 Self-Supervised 학습을 목표로 함.
- 기여:
 1. ViT backbone과 자연스럽게 결합되는 Masked Autoencoder 구조 제안
 2. High masking ratio(예: 75%) 적용으로 효율적 학습
 3. Label 없이 사전 학습 후 다양한 Vision downstream task에서 성능 검증

1. Overview

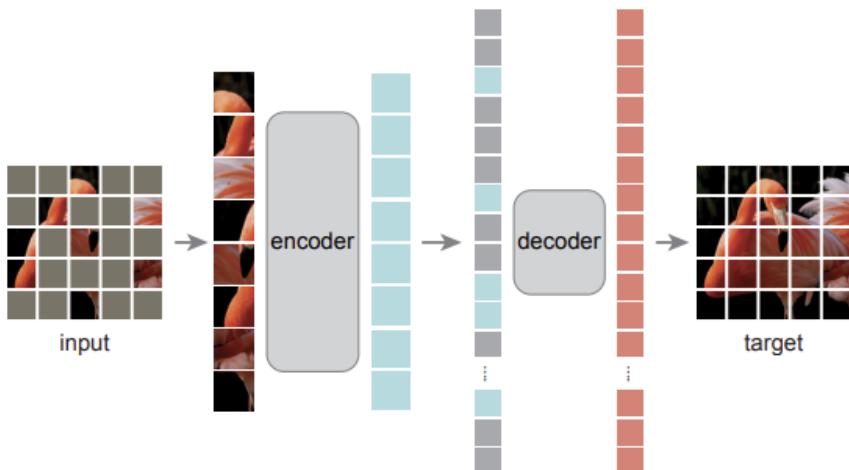
- 기본 아이디어: 입력 이미지를 Patch 단위로 분할하고, 주어진 patch의 일부(랜덤 75%)를 마스킹
- Encoder:
 - Visible patch만 입력으로 사용
 - ViT 기반 Transformer 구조
- Decoder:
 - Encoder 출력과 mask token을 모두 사용하여 원본 이미지 복원
- Pretraining → Fine-tuning 단계:

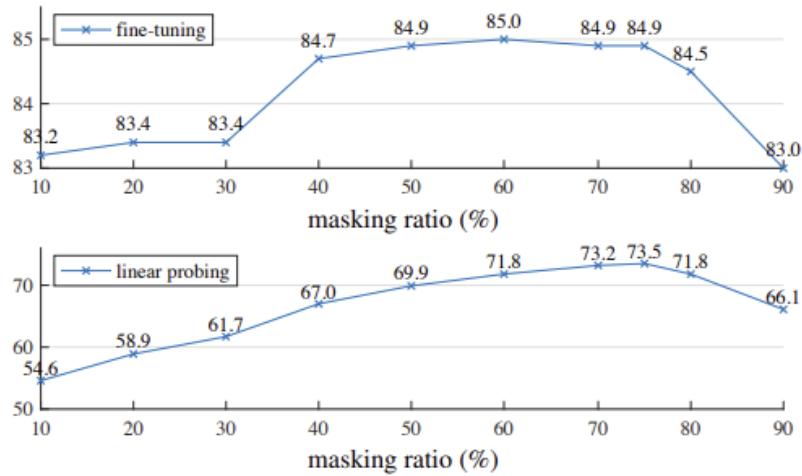
- Self-Supervised 단계에서 이미지 복원을 학습
- 이후 Fine-tuning을 통해 분류/탐지 성능 향상

2. Challenges

- 이미지 SSL에서 높은 성능을 얻기 위해서는:
 - 표현 다양성 확보
 - 계산 효율성 유지
 - Transformer 구조와 자연스러운 통합 필요
- 기존 Autoencoder 방식은 전체 입력을 처리해야 하므로 계산량 증가
- 높은 masking 비율에서 정보 손실 없이 좋은 표현 학습이 어려움

3. Method





blocks	ft	lin
1	84.8	65.5
2	84.9	70.0
4	84.9	71.9
8	84.9	73.5
12	84.4	73.3

(a) **Decoder depth.** A deep decoder can improve linear probing accuracy.

dim	ft	lin
128	84.9	69.1
256	84.8	71.3
512	84.9	73.5
768	84.4	73.1
1024	84.3	73.1

(b) **Decoder width.** The decoder can be narrower than the encoder (1024-d).

case	ft	lin	FLOPs
encoder w/ [M]	84.2	59.6	3.3×
encoder w/o [M]	84.9	73.5	1×

(c) **Mask token.** An encoder without mask tokens is more accurate and faster (Table 2).

case	ft	lin
pixel (w/o norm)	84.9	73.5
pixel (w/ norm)	85.4	73.9
PCA	84.6	72.3
dVAE token	85.3	71.6

(d) **Reconstruction target.** Pixels as reconstruction targets are effective.

case	ft	lin
none	84.0	65.7
crop, fixed size	84.7	73.1
crop, rand size	84.9	73.5
crop + color jit	84.3	71.9

(e) **Data augmentation.** Our MAE works with minimal or no augmentation.

case	ratio	ft	lin
random	75	84.9	73.5
block	50	83.9	72.3
block	75	82.8	63.9
grid	75	84.0	66.0

(f) **Mask sampling.** Random sampling works the best. See Figure 6 for visualizations.

- Masking Strategy: 입력 이미지 patch 중 75%를 무작위로 masking, Encoder는 Visible patch만 계산하여 계산량 감소
- Encoder: Transformer 기반, 입력 patch embedding과 positional encoding
- Decoder: Lightweight Transformer, Mask token embedding 포함 전체 patch 복원
- Loss Function: Reconstruction loss(MSE), mask된 patch만 복원 오차 측정
- Training: Pretraining 단계에서 masking → encoder/decoder 학습, Fine-tuning 단계에서 classification 또는 downstream task 수행

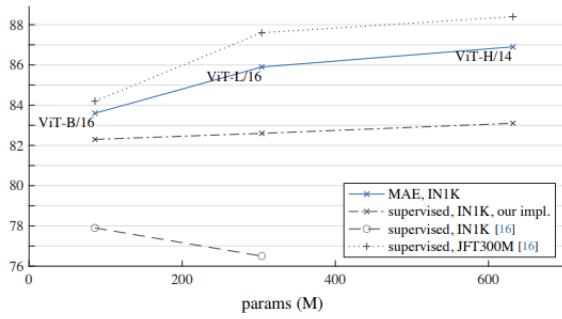
4. Experiments

- 데이터셋: ImageNet-1k (1.28M train images, 50k validation)
- Baseline 비교: ViT(Supervised), SimMIM, BEiT, iGPT

- 평가 지표: Top-1 Accuracy, Fine-tuning 성능
- 실험 설정: Encoder depth, masking ratio, decoder depth 실험, Fine-tuning 시 learning rate, batch size 조정

5. Results

method	pre-train data	ViT-B	ViT-L	ViT-H	ViT-H448
scratch, our impl.	-	82.3	82.6	83.1	-
DINO [5]	IN1K	82.8	-	-	-
MoCo v3 [9]	IN1K	83.2	84.1	-	-
BEiT [2]	IN1K+DALLE	83.2	85.2	-	-
MAE	IN1K	83.6	85.9	86.9	87.8



method	pre-train data	AP ^{box}		AP ^{mask}	
		ViT-B	ViT-L	ViT-B	ViT-L
supervised	IN1K w/ labels	47.9	49.3	42.9	43.9
MoCo v3	IN1K	47.9	49.3	42.7	44.0
BEiT	IN1K+DALLE	49.8	53.3	44.4	47.1
MAE	IN1K	50.3	53.3	44.9	47.2

Table 4. COCO object detection and segmentation using a ViT Mask R-CNN baseline. All entries are based on our implementation. Self-supervised entries use IN1K data *without* labels. Mask AP follows a similar trend as box AP.

method	pre-train data	ViT-B	ViT-L
supervised	IN1K w/ labels	47.4	49.9
MoCo v3	IN1K	47.3	49.1
BEiT	IN1K+DALLE	47.1	53.3
MAE	IN1K	48.1	53.6

Table 5. ADE20K semantic segmentation (mIoU) using UperNet. BEiT results are reproduced using the official code. Other entries are based on our implementation. Self-supervised entries use IN1K data *without* labels.

dataset	ViT-B	ViT-L	ViT-H	ViT-H448	prev best
iNat 2017	70.5	75.7	79.3	83.4	75.4 [55]
iNat 2018	75.4	80.1	83.0	86.8	81.2 [54]
iNat 2019	80.5	83.4	85.7	88.3	84.1 [54]
Places205	63.9	65.8	65.9	66.8	66.0 [19] [†]
Places365	57.9	59.4	59.8	60.3	58.0 [40] [‡]

Table 6. Transfer learning accuracy on classification datasets, using MAE pre-trained on IN1K and then fine-tuned. We provide system-level comparisons with the previous best results.

[†]: pre-trained on 1 billion images. [‡]: pre-trained on 3.5 billion images.

	IN1K			COCO		ADE20K	
	ViT-B	ViT-L	ViT-H	ViT-B	ViT-L	ViT-B	ViT-L
pixel (w/o norm)	83.3	85.1	86.2	49.5	52.8	48.0	51.8
pixel (w/ norm)	83.6	85.9	86.9	50.3	53.3	48.1	53.6
dVAE token	83.6	85.7	86.9	50.3	53.2	48.1	53.4
△	0.0	-0.2	0.0	0.0	-0.1	0.0	-0.2

Table 7. Pixels vs. tokens as the MAE reconstruction target. △ is the difference between using dVAE tokens and using normalized pixels. The difference is statistically insignificant.

- MAE는 기존 Self-Supervised 방법 대비 성능 우위
- Masking ratio 75%에서 효율적 학습
- Decoder를 간소화하면서 계산량 절약
- Fine-tuning 성능 향상

6. Insight

- Key Strengths: Masking 기반 구조로 연산 효율 극대화, Label 없이 강력한 표현 학습 가능, 다양한 downstream task 확장 가능
- Limitations: High masking 비율의 정보 손실 가능성, Decoder 구조 설계 민감도 존재
- 후속 연구 방향: Multi-Modal MAE(이미지+텍스트), Video MAE(시계열 영상), Masking 전략 최적화 연구