An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling

https://arxiv.org/pdf/1803.01271

0. Introduction

- sequence modeling에서 RNN이 표준으로 사용됨
- CNN 기반 접근은 상대적으로 덜 연구됨
- CNN과 RNN의 성능을 공정하게 비교할 필요 존재
- 어떤 구조가 더 효과적인지 empirical하게 검증하는 것이 목적

1. Overview

- RNN과 CNN 기반 모델 성능 비교
- Temporal Convolutional Networks 기반 CNN 사용
- 동일한 실험 환경에서 공정한 비교 수행
- long-term dependency 처리 능력 분석

2. Challenges

- long-term dependency 학습의 어려움
- RNN은 gradient vanishing 문제 존재
- CNN은 receptive field 제한 문제 존재
- 모델 구조에 따른 학습 안정성 차이 존재

- 공정한 비교를 위한 실험 설계 어려움

3. Method

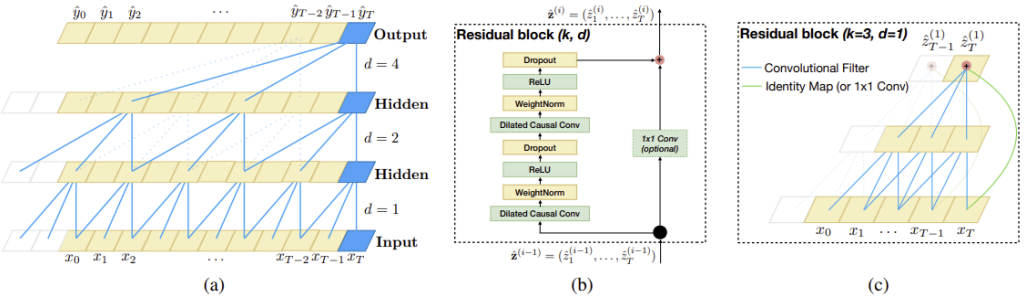

- TCN 기반 CNN 구조 사용
- dilated convolution으로 receptive field 확장
- causal convolution으로 미래 정보 차단
- residual connection으로 학습 안정성 확보
- RNN, LSTM, GRU와 동일 조건에서 비교

4. Experiments

- language modeling, music modeling 등 다양한 task 사용
- 동일 데이터셋 및 환경에서 실험 진행
- RNN, LSTM, GRU와 성능 비교
- task별 standard metric 사용

5. Results

Sequence Modeling Task	Model Size (≈)	Models			
		LSTM	GRU	RNN	**TCN**
Seq. MNIST (accuracy^h)	70K	87.2	96.2	21.5	**99.0**
Permuted MNIST (accuracy)	70K	85.7	87.3	25.3	**97.2**
Adding problem T=600 (loss$^\ell$)	70K	0.164	**5.3e-5**	0.177	**5.8e-5**
Copy memory T=1000 (loss)	16K	0.0204	0.0197	0.0202	**3.5e-5**
Music JSB Chorales (loss)	300K	8.45	8.43	8.91	**8.10**
Music Nottingham (loss)	1M	3.29	3.46	4.05	**3.07**
Word-level PTB (perplexity$^\ell$)	13M	**78.93**	92.48	114.50	88.68
Word-level Wiki-103 (perplexity)	-	48.4	-	-	**45.19**
Word-level LAMBADA (perplexity)	-	4186	-	14725	**1279**
Char-level PTB (bpc$^\ell$)	3M	1.36	1.37	1.48	**1.31**
Char-level text8 (bpc)	5M	1.50	1.53	1.69	**1.45**

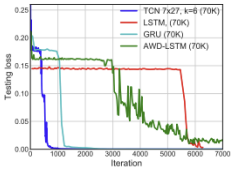

(a) $T = 200$

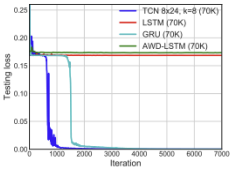

(b) $T = 600$

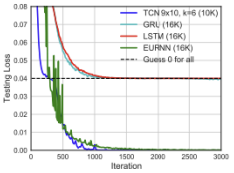

(a) $T = 500$

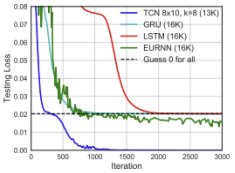

(b) $T = 1000$

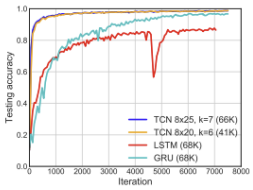

(a) Sequential MNIST

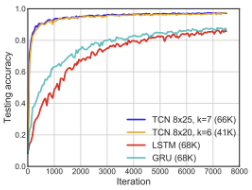

(b) P-MNIST

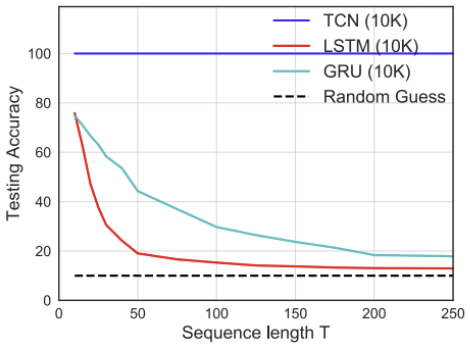

- TCN이 대부분 task에서 더 높은 성능 기록
- long-term dependency 처리에서 강점 확인
- 학습 안정성과 수렴 속도 우수
- 깊은 구조에서도 성능 유지

6. Insight

- sequence modeling에서 RNN 필수라는 가정 약화
- CNN 기반 접근이 강력한 대안으로 확인

- 병렬 처리 가능해 실무 적용에 유리
- Transformer 등장 이전 중요한 전환점 역할