DeepAR : Probabilistic Forecasting with Autoregressive Recurrent Networks

https://arxiv.org/pdf/1704.04110

0. Introduction

- 시계열 예측은 수요 예측, 재고 관리, 에너지 소비 예측 등 다양한 산업 문제에서 중요함
- 기존 시계열 모델(ARIMA, Exponential Smoothing 등)은 보통 단일 시계열을 개별적으로 학습함
- 실제 산업 데이터는 수천 개 이상의 시계열이 존재하고 데이터 길이와 패턴이 서로 다름
- 기존 방법은 확장성 부족 및 데이터 부족 문제 발생
- 논문에서는 RNN 기반 확률 시계열 예측 모델 DeepAR 제안
- 여러 시계열을 동시에 학습하여 공통 패턴 학습하고 미래 값을 확률 분포 형태로 예측함

1. Overview

- DeepAR은 autoregressive RNN 기반 시계열 예측 모델
- 과거 시점 데이터를 이용해 다음 시점 값을 예측하는 구조
- LSTM 기반 RNN 사용하여 시계열 패턴과 계절성 학습
- 입력 데이터
    - 이전 시점 관측값
    - 시간 정보 (요일, 월 등)
    - 시계열 메타 정보

- 출력은 미래 값의 확률 분포 파라미터

2. Challenges

- 시계열마다 값의 규모 차이 존재
- 데이터 길이 부족 및 데이터 희소성 문제
- 실제 응용에서는 단순 예측값보다 불확실성 추정 필요
- 시계열 데이터는 계절성과 장기 의존성 존재

3. Method

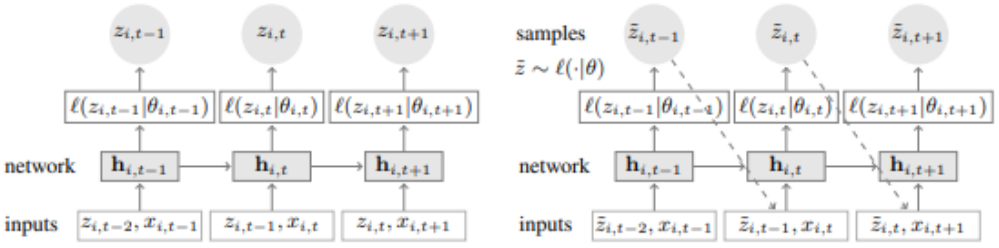

- 모델 구조는 autoregressive LSTM 기반 RNN
- 이전 시점 값과 covariates를 입력으로 사용
- RNN hidden state가 시계열 패턴 학습
- 출력층에서 확률 분포 파라미터 예측
- 학습은 negative log likelihood 기반 likelihood optimization 사용
- 시계열 규모 차이를 해결하기 위해 scale normalization 적용

4. Experiments

- 실제 산업 데이터 기반 실험 수행
- 여러 개 시계열을 동시에 학습하는 환경 구성
- 비교 모델

    - ARIMA
    - Exponential Smoothing
    - 기존 RNN 기반 모델
- 평가 지표
    - RMSE
    - quantile loss
    - probabilistic forecast accuracy

5. Results

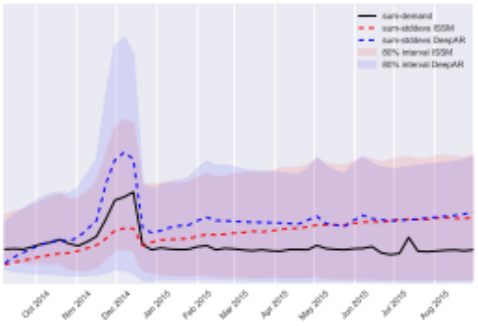

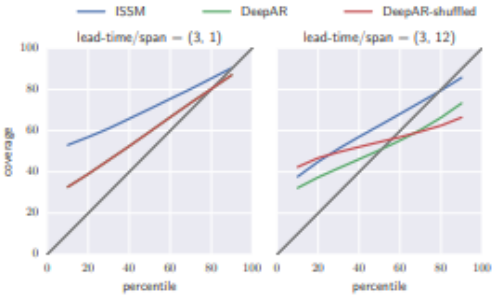

	0.5-risk					0.9-risk			average
					parts				
(L, S)	$(0, 1)$	$(2, 1)$	$(0, 8)$	all(8)	$(0, 1)$	$(2, 1)$	$(0, 8)$	all(8)	average
Snyder (baseline)	1.00	1.00	1.00	**1.00**	1.00	1.00	1.00	1.00	1.00
Croston	1.47	1.70	2.86	1.83	-	-	-	-	1.97
ISSM	1.04	1.07	1.24	1.06	1.01	1.03	1.14	1.06	1.08
ETS	1.28	1.33	1.42	1.38	1.01	1.03	1.35	1.04	1.23
rnn-gaussian	1.17	1.49	1.15	1.56	1.02	0.98	1.12	1.04	1.19
rnn-negbin	**0.95**	**0.91**	0.95	**1.00**	1.10	**0.95**	1.06	0.99	0.99
DeepAR	0.98	**0.91**	**0.91**	1.01	**0.90**	**0.95**	**0.96**	**0.94**	**0.94**
					ec-sub				
(L, S)	$(0, 2)$	$(0, 8)$	$(3, 12)$	all(33)	$(0, 2)$	$(0, 8)$	$(3, 12)$	all(33)	average
Snyder	1.04	1.18	1.18	1.07	1.0	1.25	1.37	1.17	1.16
Croston	1.29	1.36	1.26	0.88	-	-	-	-	1.20
ISSM (baseline)	1.00	1.00	1.00	1.00	1.00	1.00	**1.00**	1.00	1.00
ETS	0.83	1.06	1.15	0.84	1.09	1.38	1.45	0.74	1.07
rnn-gaussian	1.03	1.19	1.24	0.85	0.91	1.74	2.09	0.67	1.21
rnn-negbin	0.90	0.98	1.11	0.85	1.23	1.67	1.83	0.78	1.17
DeepAR	**0.64**	**0.74**	**0.93**	**0.73**	**0.71**	**0.81**	1.03	**0.57**	**0.77**
					ec				
(L, S)	$(0, 2)$	$(0, 8)$	$(3, 12)$	all(33)	$(0, 2)$	$(0, 8)$	$(3, 12)$	all(33)	average
Snyder	0.87	1.06	1.16	1.12	0.94	1.09	1.13	1.01	1.05
Croston	1.30	1.38	1.28	1.39	-	-	-	-	1.34
ISSM (baseline)	1.00	1.00	1.00	1.00	1.00	1.00	**1.00**	1.00	1.00
ETS	0.77	0.97	1.07	1.23	1.05	1.33	1.37	1.11	1.11
rnn-gaussian	0.89	0.91	0.94	1.14	0.90	1.15	1.23	**0.90**	1.01
rnn-negbin	0.66	0.71	**0.86**	**0.92**	0.85	1.12	1.33	0.98	0.93
DeepAR	**0.59**	**0.68**	0.99	0.98	**0.76**	**0.88**	**1.00**	0.91	**0.85**

- DeepAR은 기존 통계 모델 대비 예측 성능 향상 확인
- 여러 시계열을 동시에 학습할 경우 일반화 성능 개선
- 확률 분포 기반 예측으로 prediction interval 제공 가능
- 대규모 시계열 데이터에서도 안정적인 성능 확인

6. Insight

- 여러 시계열을 동시에 학습하는 **global forecasting model** 제시
- 확률 분포 기반 예측으로 **불확실성 추정 가능**
- 대규모 시계열 데이터에 적용 가능한 딥러닝 기반 방법 제안
- autoregressive 구조로 예측 속도 느림
- RNN 기반이라 긴 시계열 처리 효율 제한 가능