

ETSformer : Exponential Smoothing Transformers for Time-series Forecasting

<https://arxiv.org/abs/2202.01381>

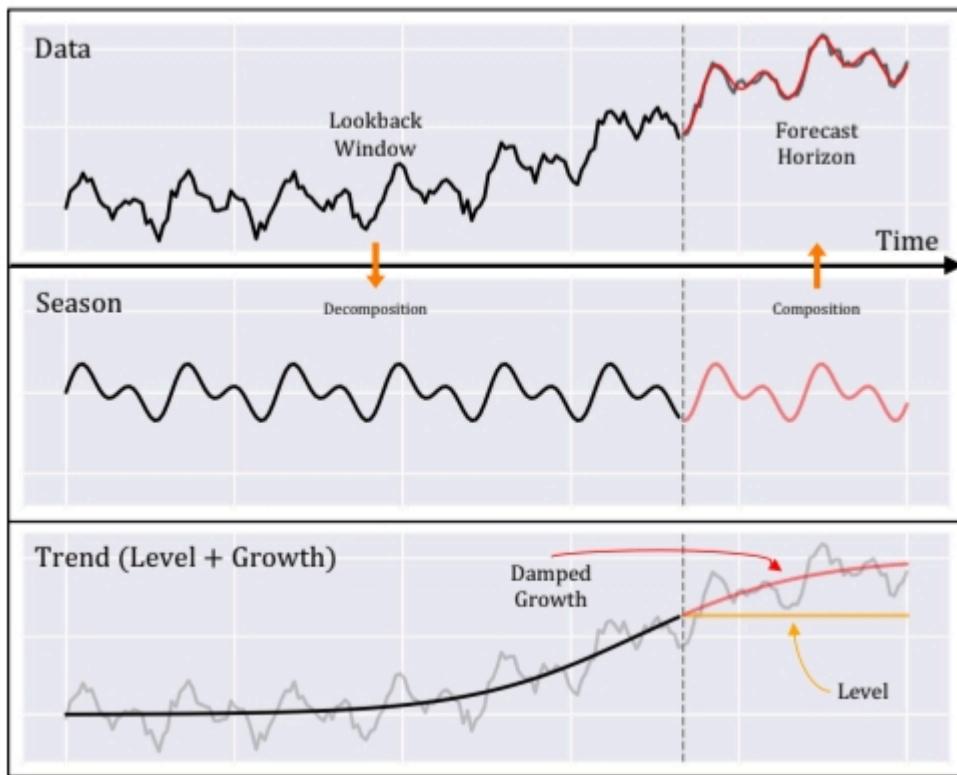
0. Introduction

- 시계열 예측은 다양한 분야에서 중요하지만, 기존 Transformer 모델은 장기 의존성 학습, 해석 가능성, 효율성 측면에서 한계가 있음
- ETSformer는 지수평활 개념을 통합하여 예측 정확도와 해석 가능성을 개선함
- Exponential Smoothing Attention과 Frequency Attention을 통해 시계열의 수준, 성장, 계절 구성 요소를 분리하고 학습
- 다양한 실제 데이터셋에서 성능을 검증하며, 모듈화된 Transformer 구조를 제시

1. Overview

- ETSformer는 전통적 시계열 분해 방식과 Transformer를 결합
- ESA : 시간 지연을 고려하여 최근 관측값에 가중치를 더함
- FA : Fourier 변환을 활용해 주요 계절 패턴 추출
- 출력은 수준, 성장, 계절 요소의 합으로 구성된 예측값
- 단변량 및 다변량 시계열 모두 적용 가능

2. Challenges



- 기존 Transformer는 계절성과 장기 추세 모델링에 한계
- dot-product self-attention은 최근 관측값의 중요성을 충분히 반영하지 못함
- 비정상 또는 잡음 데이터는 패턴 추출을 어렵게 함
- 기존 방법은 수작업으로 설계한 변수를 사용하거나 단순화된 추세 제거 방법에 의존

3. Method

$$\text{Level} : e_t = \alpha(x_t - s_{t-p}) + (1 - \alpha)(e_{t-1} + b_{t-1})$$

$$\text{Growth} : b_t = \beta(e_t - e_{t-1}) + (1 - \beta)b_{t-1}$$

$$\text{Seasonal} : s_t = \gamma(x_t - e_t) + (1 - \gamma)s_{t-p}$$

$$\text{Forecasting} : \hat{x}_{t+h|t} = e_t + h b_t + s_{t+h-p}$$

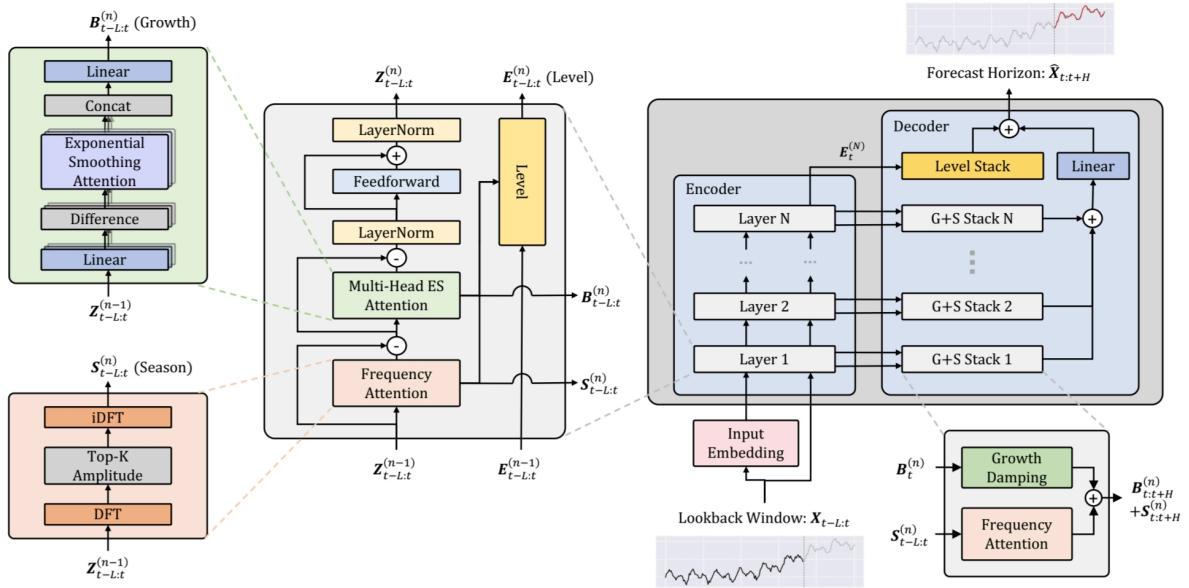


Figure 2: ETSformer model architecture.

- ESA : 상대 시간 지연 기반으로 주목하여 최근 데이터 강조
- FA : Fourier 변환을 이용해 주요 계절 성분 선택
- 분해 블록 : 시계열을 수준, 성장, 계절로 분리하여 해석 가능하게 함
- Residual Learning : 복잡한 잠재 패턴 학습을 위해 깊은 구조에서 잔차 학습 적용
- 입력 데이터는 정규화 후 lookback 윈도우로 분할, 출력은 분해된 요소를 합산하여 생성

4. Experiments

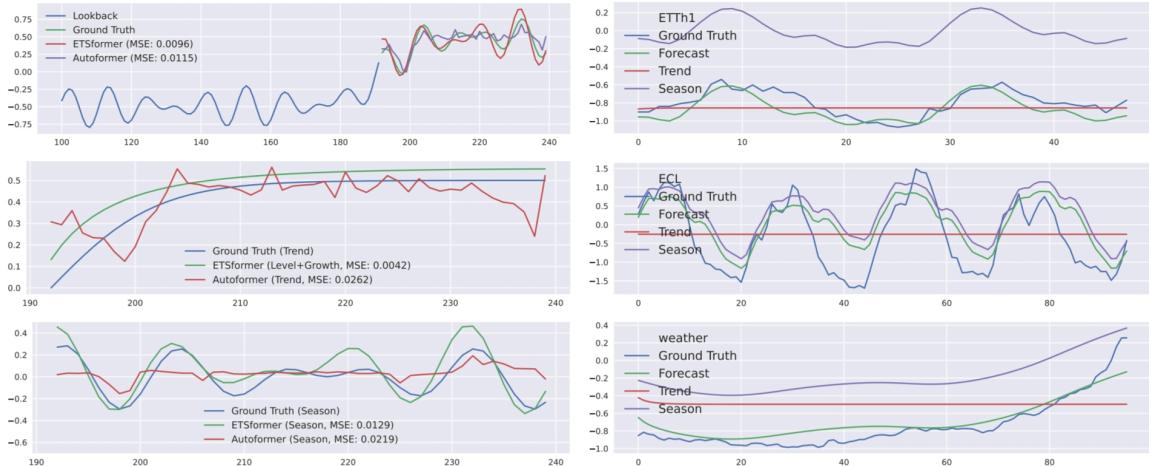
- 벤치마크 : 6개의 실제 데이터셋 단변량 및 다변량 포함
- 비교 대상 : LogTrans, Informer, Autoformer 등 Transformer 기반 모델
- 평가 지표 : MSE, MAE 등 표준 시계열 예측 지표
- ESA 및 FA 기여도를 검증하기 위한 Ablation Study 수행

5. Results

Table 1: Multivariate forecasting results over various forecast horizons. Best results are **bolded**, and second best results are underlined.

Methods		ETSFformer		Autoformer		Informer		LogTrans		Reformer		LSTnet		LSTM	
Metrics		MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ETTm2	96	0.189	0.280	<u>0.255</u>	<u>0.339</u>	0.365	0.453	0.768	0.642	0.658	0.619	3.142	1.365	2.041	1.073
	192	0.253	0.319	<u>0.281</u>	<u>0.340</u>	0.533	0.563	0.989	0.757	1.078	0.827	3.154	1.369	2.249	1.112
	336	0.314	0.357	<u>0.339</u>	<u>0.372</u>	1.363	0.887	1.334	0.872	1.549	0.972	3.160	1.369	2.568	1.238
	720	0.414	0.413	<u>0.422</u>	<u>0.419</u>	3.379	1.388	3.048	1.328	2.631	1.242	3.171	1.368	2.720	1.287
ECL	96	0.187	0.304	<u>0.201</u>	<u>0.317</u>	0.274	0.368	0.258	0.357	0.312	0.402	0.680	0.645	0.375	0.437
	192	0.199	0.315	<u>0.222</u>	<u>0.334</u>	0.296	0.386	0.266	0.368	0.348	0.433	0.725	0.676	0.442	0.473
	336	0.212	0.329	<u>0.231</u>	<u>0.338</u>	0.300	0.394	0.280	0.380	0.350	0.433	0.828	0.727	0.439	0.473
	720	0.233	0.345	<u>0.254</u>	<u>0.361</u>	0.373	0.439	0.283	0.376	0.340	0.420	0.957	0.811	0.980	0.814
Exchange	96	0.085	0.204	<u>0.197</u>	<u>0.323</u>	0.847	0.752	0.968	0.812	1.065	0.829	1.551	1.058	1.453	1.049
	192	0.182	0.303	<u>0.300</u>	<u>0.369</u>	1.204	0.895	1.040	0.851	1.188	0.906	1.477	1.028	1.846	1.179
	336	0.348	0.428	<u>0.509</u>	<u>0.524</u>	1.672	1.036	1.659	1.081	1.357	0.976	1.507	1.031	2.136	1.231
	720	1.025	0.774	<u>1.447</u>	<u>0.941</u>	2.478	1.310	1.941	1.127	1.510	1.016	2.285	1.243	2.984	1.427
Traffic	96	0.607	0.392	<u>0.613</u>	<u>0.388</u>	0.719	0.391	0.684	0.384	0.732	0.423	1.107	0.685	0.843	0.453
	192	0.621	0.399	0.616	<u>0.382</u>	0.696	0.379	0.685	0.390	0.733	0.420	1.157	0.706	0.847	0.453
	336	0.622	<u>0.396</u>	0.622	0.337	0.777	0.420	0.733	0.408	0.742	0.420	1.216	0.730	0.853	0.455
	720	0.632	<u>0.396</u>	<u>0.660</u>	0.408	0.864	0.472	0.717	0.396	0.755	0.423	1.481	0.805	1.500	0.805
Weather	96	0.197	0.281	<u>0.266</u>	<u>0.336</u>	0.300	0.384	0.458	0.490	0.689	0.596	0.594	0.587	0.369	0.406
	192	0.237	0.312	<u>0.307</u>	<u>0.367</u>	0.598	0.544	0.658	0.589	0.752	0.638	0.560	0.565	0.416	0.435
	336	0.298	0.353	<u>0.359</u>	<u>0.359</u>	0.578	0.523	0.797	0.652	0.639	0.596	0.597	0.587	0.455	0.454
	720	0.352	0.388	<u>0.419</u>	<u>0.419</u>	1.059	0.741	0.869	0.675	1.130	0.792	0.618	0.599	0.535	0.520
ILI	24	2.527	1.020	<u>3.483</u>	<u>1.287</u>	5.764	1.677	4.480	1.444	4.400	1.382	6.026	1.770	5.914	1.734
	36	2.615	1.007	<u>3.103</u>	<u>1.148</u>	4.755	1.467	4.799	1.467	4.783	1.448	5.340	1.668	6.631	1.845
	48	2.359	0.972	<u>2.669</u>	<u>1.085</u>	4.763	1.469	4.800	1.468	4.832	1.465	6.080	1.787	6.736	1.857
	60	2.487	1.016	<u>2.770</u>	<u>1.125</u>	5.264	1.564	5.278	1.560	4.882	1.483	5.548	1.720	6.870	1.879

Datasets		ETTh2	ETTm2	ECL	Traffic
ETSFformer	MSE	0.262	0.110	0.163	0.571
	MAE	0.337	0.222	0.287	0.373
w/o Level	MSE	0.434	0.464	0.275	0.649
	MAE	0.466	0.518	0.373	0.393
w/o Season	MSE	0.521	0.131	0.696	1.334
	MAE	0.450	0.236	0.677	0.779
w/o Growth	MSE	0.290	0.115	0.167	0.583
	MAE	0.359	0.226	0.288	0.383
MH-ESA → MHA	MSE	0.656	0.343	0.205	0.586
	MAE	0.639	0.451	0.323	0.380



- ETSformer는 모든 데이터셋에서 기존 모델 대비 우수한 성능 기록
- ESA는 추세 모델링 향상, FA는 계절 패턴 추출 개선
- Ablation Study 결과 각 구성 요소가 성능 향상에 의미 있는 기여
- 분해된 구성 요소 시각화를 통해 인간 해석 가능성 제공

6. Insight

- 시계열 특성을 반영한 inductive bias 도입으로 Transformer의 정확도와 해석 가능성 모두 향상
- ESA와 FA는 시계열에서 기존 self-attention의 근본적 한계를 보완
- 모듈화된 분해 구조는 장기 예측에서 해석 가능성을 제공하는 일반적 접근
- 향후 연구 방향 : 불규칙 샘플링 또는 다해상도 시계열 확장