Neural ODE for Time Series

https://arxiv.org/html/2502.09885v1

0. Introduction

- 시계열 데이터는 시간 간격이 일정하지 않은 경우가 많음
- 기존 RNN, Transformer는 대부분 **discrete-time 가정** 기반
- irregular sampling, missing data 문제 존재
- 이를 해결하기 위해 **Neural Differential Equations (NDE)** 등장
- 본 논문은
  - Neural ODE, CDE, SDE 등 NDE 계열을 통합 정리
  - 시계열 적용 방식과 구조 분석
  - 한계점과 향후 방향 제시

1. Overview

- 핵심 아이디어
  - 시계열을 **연속적인 함수로 모델링**
- 접근 방식
  - hidden state를 미분방정식으로 정의
  - ODE solver를 통해 상태 변화 계산
- 주요 구성
  - continuous-time representation
  - solver-based computation
  - time-aware modeling
- 적용 분야
  - forecasting, anomaly detection, healthcare 등

2. Challenges

- irregular time series 처리 어려움
- 기존 모델은 fixed timestep에 의존
- 연속적인 dynamics modeling 필요
- long-term dependency 학습 한계
- 계산 비용 증가
  - solver 반복 계산 필요
- 학습 안정성 문제
  - gradient 계산 복잡

3. Method

- Neural ODE
  - hidden state 변화
  - 시간에 따른 미분방정식으로 정의
- Neural CDE
  - 입력 시계열을 continuous path로 변환
  - path-driven dynamics modeling
- Neural SDE
  - stochastic 요소 포함
  - uncertainty modeling 가능
- 공통 구조
  - 입력 → continuous representation
  - dynamics function 정의
  - ODE/SDE solver 적용
- 학습 방식

    - adjoint method 사용 (메모리 효율)
    - solver 설정이 성능에 영향

4. Experiments

- 다양한 시계열 데이터셋 사용
- 평가 항목
    - forecasting accuracy
    - modeling stability
    - irregular data 처리 성능
- 비교 모델
    - RNN 계열
    - Transformer 계열
- 실험 목적
    - continuous-time 모델의 성능 검증

5. Results

- irregular time series에서 성능 우수
- missing data 상황에서 강점
- stochastic modeling 필요 상황에서 SDE 유리
- 단점
    - 계산 속도 느림
    - 대규모 데이터에서 비효율
- 일부 경우 Transformer 대비 성능 우위 또는 유사

6. Insight

- 기존 모델과 다른 핵심 차이

    - discrete → continuous modeling
- 장점
    - irregular data 처리 강함
    - 시간 흐름 자체를 모델링
- 단점
    - 계산 비용 높음
    - 구현 복잡
- 실무 적용
    - 일반 forecasting

      → Transformer, Linear 모델이 효율적
    - irregular / event-driven 데이터

      → NDE 적합
- 향후 방향
    - Transformer + NDE 결합 가능성