Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting

https://arxiv.org/pdf/1709.04875

0. Introduction

- 도시 교통 예측은 스마트 교통 시스템과 도시 관리에서 중요한 문제
- 교통 데이터는 시간 변화와 공간 관계가 동시에 존재하는 spatio-temporal 데이터 특성을 가짐
- 기존 시계열 모델이나 RNN 기반 모델은 공간 관계를 충분히 반영하지 못하는 한계 존재
- 본 논문은 교통 센서 네트워크를 그래프로 표현하고 시공간 정보를 동시에 학습하는 딥러닝 모델을 제안함

1. Overview

- 도로 네트워크를 그래프로 모델링하여 교통 센서 간 관계를 표현
- 교통 속도 데이터를 시계열 형태로 입력하여 미래 교통 상태 예측
- Graph Convolution과 Temporal Convolution을 결합한 STGCN 모델 구조 제안
- RNN 없이 convolution 기반 구조만 사용하여 학습 효율 개선

2. Challenges

- 교통 데이터는 도로 네트워크 구조 때문에 일반적인 격자 형태 데이터가 아님
- 시간 의존성과 공간 의존성을 동시에 학습해야 하는 어려움 존재
- RNN 기반 모델은 학습 속도와 장기 의존성 처리에서 한계 존재

- 센서 간 관계를 효과적으로 표현할 수 있는 모델 구조 필요

3. Method

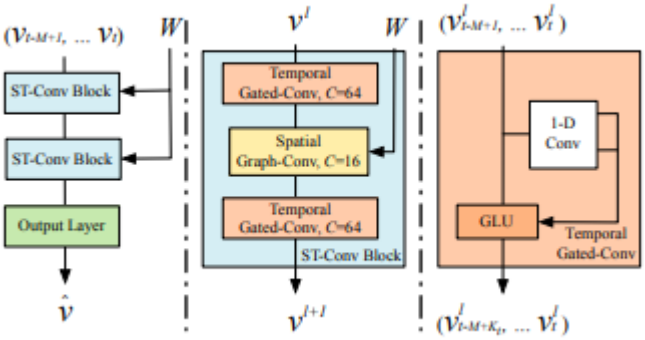

- 교통 센서를 노드, 도로 연결을 엣지로 하는 그래프 구조 구성
- 모델은 **ST-Conv Block**을 기반으로 구성됨

구성 단계

- Temporal Convolution
  - 시간 축에서 교통 흐름 패턴 학습
- Graph Convolution
  - 인접 센서 간 공간 관계 학습
- Temporal Convolution
  - 시간적 패턴을 다시 정제하여 예측 성능 향상
- 전체 모델은 이러한 블록을 여러 층으로 구성하여 교통 흐름을 예측

4. Experiments

Model	BJER4 (15/ 30/ 45 min)		
	MAE	MAPE (%)	RMSE
HA	5.21	14.64	7.56
LSVR	4.24/ 5.23/ 6.12	10.11/ 12.70/ 14.95	5.91/ 7.27/ 8.81
ARIMA	5.99/ 6.27/ 6.70	15.42/ 16.36/ 17.67	8.19/ 8.38/ 8.72
FNN	4.30/ 5.33/ 6.14	10.68/ 13.48/ 15.82	5.86/ 7.31/ 8.58
FC-LSTM	4.24/ 4.74/ 5.22	10.78/ 12.17/ 13.60	5.71/ 6.62/ 7.44
GCGRU	3.84/ 4.62/ 5.32	9.31/ 11.41/ 13.30	5.22/ 6.35/ 7.58
STGCN(Cheb)	**3.78/ 4.45/ 5.03**	**9.11/ 10.80/ 12.27**	**5.20/ 6.20/ 7.21**
STGCN(1st)	3.83/ 4.51/ 5.10	9.28/ 11.19/ 12.79	5.29/ 6.39/ 7.39

- 사용 데이터셋
  - METR-LA 교통 센서 데이터
  - PEMS-BAY 교통 센서 데이터
- 데이터 특징
  - 수백 개 교통 센서
  - 일정 시간 간격으로 측정된 교통 속도 데이터
- 비교 모델
  - ARIMA
  - Fully Connected LSTM
  - 기존 Graph Convolution 기반 모델
- 평가 지표
  - MAE
  - RMSE
  - MAPE

5. Results

Model	PeMSD7(M) (15/ 30/ 45 min)			PeMSD7(L) (15/ 30/ 45 min)		
	MAE	MAPE (%)	RMSE	MAE	MAPE (%)	RMSE
HA	4.01	10.61	7.20	4.60	12.50	8.05
LSVR	2.50/ 3.63/ 4.54	5.81/ 8.88/ 11.50	4.55/ 6.67/ 8.28	2.69/ 3.85/ 4.79	6.27/ 9.48/ 12.42	4.88/ 7.10/ 8.72
ARIMA	5.55/ 5.86/ 6.27	12.92/ 13.94/ 15.20	9.00/ 9.13/ 9.38	5.50/ 5.87/ 6.30	12.30/ 13.54/ 14.85	8.63/ 8.96/ 9.39
FNN	2.74/ 4.02/ 5.04	6.38/ 9.72/ 12.38	4.75/ 6.98/ 8.58	2.74/ 3.92/ 4.78	7.11/ 10.89/ 13.56	4.87/ 7.02/ 8.46
FC-LSTM	3.57/ 3.94/ 4.16	8.60/ 9.55/ 10.10	6.20/ 7.03/ 7.51	4.38/ 4.51/ 4.66	11.10/ 11.41/ 11.69	7.68/ 7.94/ 8.20
GCGRU	2.37/ 3.31/ 4.01	5.54/ 8.06/ 9.99	4.21/ 5.96/ 7.13	2.48/ 3.43/ 4.12 *	5.76/ 8.45/ 10.51 *	4.40/ 6.25/ 7.49 *
STGCN(Cheb)	**2.25/ 3.03/ 3.57**	5.26/ **7.33/ 8.69**	**4.04/ 5.70/ 6.77**	**2.37/ 3.27/ 3.97**	**5.56/ 7.98/ 9.73**	**4.32/ 6.21/ 7.45**
STGCN(1st)	2.26/ 3.09/ 3.79	**5.24**/ 7.39/ 9.12	4.07/ 5.77/ 7.03	2.40/ 3.31/ 4.01	5.63/ 8.21/ 10.12	4.38/ 6.43/ 7.81

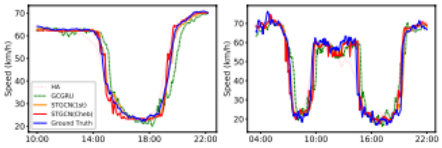

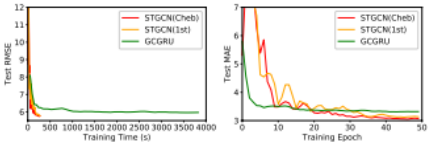

Dataset	Time Consumption (s)		
	STGCN(Cheb)	STGCN(1st)	GCGRU
PeMSD7(M)	**272.34**	271.18	3824.54
PeMSD7(L)	1926.81	**1554.37**	19511.92

- STGCN 모델이 대부분 실험에서 기존 모델보다 낮은 예측 오차 기록
- 특히 중장기 예측 구간에서 성능 향상 확인
- RNN 기반 모델보다 학습 속도와 계산 효율성 개선
- 그래프 기반 공간 정보 활용이 교통 예측 정확도 향상에 기여

6. Insight

- 시공간 데이터 분석에서 그래프 기반 모델의 효과 확인
- convolution 기반 구조만으로도 시간 의존성 학습 가능
- 해당 모델 구조는 교통 데이터 외에도 다양한 시공간 예측 문제에 적용 가능