Argo-Bench: Evaluating Data Agents on Enterprise-Scale Workflows

https://arxiv.org/abs/2610.02122

1. Problem

- 해결하려는 문제: 기존 Text-to-SQL 벤치마크는 쿼리 생성 능력에 집중해, AI가 복잡한 기업 데이터를 분석하고 올바른 의사결정을 내리는지 평가하기 어렵다.
- 왜 중요한가? 실제 업무는 여러 테이블의 정보를 연결하고, 분석 결과를 예산 배분·사기 탐지 등의 실행 가능한 결정으로 바꿔야 하기 때문이다.
- 기존 평가의 한계
  - 공개 데이터셋은 실제 기업의 데이터 규모와 복잡성을 충분히 반영하지 못한다.
  - SQL 실행이나 정답 수치의 일치만으로는 의사결정의 품질을 측정할 수 없다.
  - 실제 기업 데이터는 민감해 평가용으로 공개하기 어렵다.

2. Method

- 핵심 아이디어: 실제 기업과 유사한 대규모 시뮬레이션 환경을 만들고, AI 에이전트가 데이터를 분석해 제출한 결과를 실제 시뮬레이션 결과와 비교한다.
- 핵심 구성요소
  - 대규모 데이터 환경: 뉴욕 음식 배달 플랫폼을 모델링한 주문 8,100만 건, 테이블 235개, 약 75억 행의 데이터 웨어하우스.
  - 숨겨진 Ground Truth: 에이전트에는 관측 가능한 기업 데이터만 제공하고, 시뮬레이터의 실제 상태와 결과는 채점에 활용한다.
  - 실행 가능한 업무: SQL 조회뿐 아니라 Python 기반 분석, 예측, 예산 배분, 사기 계정 제재 등의 결과물을 제출한다.
  - 결과 기반 평가: 답변의 형식이나 쿼리 정확도보다 제출한 결정이 시뮬레이션에서 얼마나 좋은 결과를 내는지 평가한다.

    - Reference Solution: 모든 작업에 실행 가능한 참조 풀이를 제공해, 주어진 데이터만으로 문제를 해결할 수 있음을 검증한다.
- 기존 방법과의 차이: '쿼리를 정확히 생성했는가?'에서 '데이터를 통해 상황을 추론하고, 실제로 효과적인 결정을 내렸는가?'로 평가의 초점을 확장한다.

3. Experiments & Results

실험 규모

- 데이터 분석 및 의사결정 작업 210개.
- 최신·공개 가중치 모델 등 14개 모델 평가.
- 이 중 178개 작업은 예측, 조치, 예산 배분 등의 결과물을 요구한다.

주요 결과

- 가장 높은 성능을 보인 모델도 평균 59.5점을 기록했으며, 전체 작업 중 34.8%에서만 95점 이상을 달성했다.
- 특정 보너스 예산 삭감 과제에서는 두 모델 모두 예산 제약을 만족했지만, 한 모델은 약 −$86K, 다른 모델은 약 +$3.09M의 순절감액을 기록했다.
- 추가 맥락과 힌트를 제공한 47개 비교 설정에서 평균 점수가 18.5점에서 61.7점으로 상승했다. 다만 여러 힌트를 함께 변경했으므로 개별 요소의 효과는 분리되지 않았다.

무엇이 개선됐는가?

- 모델 자체의 성능을 개선하는 알고리즘보다는 기업 데이터 에이전트의 실제 업무 수행 능력을 현실적으로 측정하는 평가 방법을 제안한다.
- 제약 조건을 만족하는 것과 실제로 좋은 의사결정을 하는 것이 다르다는 점을 보여준다.

4. Insight

- 핵심 기여: 대규모 기업 데이터 환경에서 AI 에이전트의 능력을 쿼리 정확도가 아니라 데이터 추론부터 최종 의사결정의 결과까지 연결해 평가한다.
- 한계점
    - 뉴욕의 음식 배달 플랫폼이라는 단일 도메인에 기반하므로 다른 산업에 그대로 일반화하기 어렵다.
    - 시뮬레이션이 실제 기업의 복잡성을 완벽히 재현한다고 보장할 수 없다.
    - 벤치마크 성능이 실제 기업 환경에서의 성능을 직접 입증하지는 않는다.