Back to the Future: The Evolving Universal Relation Model

https://arxiv.org/pdf/2610.36833

1. Problem

- 문제: 계약서, 이메일, 보고서 등 비정형 문서에서 복잡한 분석 질의를 수행하려면 데이터베이스의 구조와 데이터를 미리 준비해야 함.
- 기존 방법의 한계
  - RAG: 문서를 검색하고 답변할 수 있지만, 재사용 가능한 관계형 데이터베이스를 직접 구축하지 못함.
  - Schema-first ETL: 스키마와 추출 항목을 미리 정의해야 하므로 새로운 질의에 유연하게 대응하기 어려움.
- 중요성: 사전에 모든 데이터를 모델링하지 않고도 조인, 집계, 비교가 가능한 데이터베이스가 필요함.

2. Method

- 핵심 아이디어: Query-first Database Construction — 질의를 먼저 받고 필요한 만큼 데이터베이스를 점진적으로 구축함.
- EUR (Evolving Universal Relation Model): 사용자에게는 하나의 개념적 관계를 제공하고, 내부적으로 실제 스키마와 데이터를 점진적으로 구성함.
- 핵심 메커니즘
  1. Reveal: 질의에 필요한 속성, 개념, 관계를 파악하고 개념적 관계를 확장함.
  2. Organize: 파악한 개념을 엔터티 테이블과 관계 테이블로 구성하고 기존 스키마와 통합함.
  3. Materialize: 문서에서 필요한 정보를 추출하고 검증한 뒤 저장함.

- 기존 방법과 차이: 기존에는 질의가 완성된 데이터베이스를 사용하지만, EUR에서는 질의가 데이터베이스의 구조와 내용을 발전시키는 계기가 됨.
- 장점: 기존에 추출한 사실을 재사용해 반복적인 문서 처리 부담을 줄일 수 있음.

3. Experiments & Results

- 실험: 대학 강의 정보를 담은 문서에 두 개의 질의를 순차적으로 적용하는 사례를 제시함.
- 첫 번째 질의: 학과, 학교, 연도별 강의 정보를 추출하고 관련 테이블을 구성함.
- 두 번째 질의: 학생, 수강 관계, 학점 정보를 추가하면서 기존 강의 정보를 재사용함.
- 주요 결과: 모델의 동작 방식을 사례로 보여주지만, 정확도, 지연 시간, 비용 절감률 등 정량적 성능 개선 수치는 제시하지 않음.

4. Insight

- 핵심 기여: 데이터베이스를 미리 완성하는 대상이 아니라, 질의에 따라 점진적으로 구축하고 발전시키는 대상으로 재정의함.
- 한계점
  - 실제 데이터셋을 이용한 성능 비교와 정량적 검증이 부족함.
  - 스키마 진화, 데이터 추출, 인덱스 관리 등에 따른 추가 비용을 평가할 필요가 있음.
  - 추출 정보의 오류와 모순을 관리하고 데이터 일관성을 보장하는 방법에 대한 추가 검증이 필요함.
- 가져갈 포인트
  - RAG의 검색과 답변을 넘어, 재사용 가능한 구조화 데이터와 데이터베이스 상태를 유지하는 것이 중요함.
  - 데이터 추출을 일회성 전처리가 아니라 질의에 따라 실행되는 과정으로 설계할 수 있음.
  - 후속 연구에서는 기존 RAG 및 ETL 방식과 정확도, 비용, 응답 시간을 비교할 필요가 있음.