Characterizing High Bandwidth Flash for LLM Serving

https://arxiv.org/abs/2609.39131

1. Problem

- LLM의 대규모 모델 가중치와 KV cache로 인해 GPU 메모리 용량이 부족해짐.
- 중요성: 메모리 병목은 추론 속도와 에너지 효율을 저하시킴.

2. Method

- HBM·HBF·호스트 메모리를 활용한 계층형 메모리 구조.
- KV cache 재사용을 고려한 데이터 배치 및 스케줄링.
- 차별점: 메모리 확장뿐 아니라 캐시 관리와 작업 스케줄링을 함께 최적화.

3. Experiments & Results

- 에이전트 워크로드 기반 시뮬레이션으로 성능 평가.
- 작업 완료 시간 36.1~87.7% 감소.
- 에너지 소비 최대 59.1% 절감.
- HBF 예상 쓰기 수명 1.21년 → 14.82년.

4. Insight

- 핵심 기여: 메모리 계층과 캐시 스케줄링의 공동 최적화로 LLM 서빙 효율 개선.
- 한계: 주요 결과가 시뮬레이션 기반이며 실제 하드웨어 검증이 필요함.
- 가져갈 포인트: LLM 서빙 최적화는 연산 성능뿐 아니라 데이터 배치, KV cache 재사용, 메모리 이동 비용까지 고려해야 함.