

Data Agents: Agentic Data Systems

<https://arxiv.org/abs/2609.24137>

1. Problem

- 문제: 기존 데이터 시스템은 사람이 직접 설계한 파이프라인과 고정된 규칙에 의존해, 이질적인 데이터를 의미적으로 이해하고 복잡한 분석 작업을 자율적으로 수행하기 어려움.
- 왜 중요한가: 데이터 수집 → 정제 → 분석 → 의사결정까지 사람이 일일이 파이프라인을 설계하지 않고 자율적으로 연결·수행하는 데이터 시스템이 필요함.

2. Method

- 핵심 아이디어: 데이터 처리 시스템 자체를 Data Agent로 만들어, 자연어로 주어진 분석 목표를 이해하고 필요한 데이터와 연산을 찾아 실행 가능한 파이프라인을 자동 생성·최적화·검증함.
- 기존 방식과 차이:
 - 기존: 사람이 ETL/SQL/워크플로우를 직접 설계 → 시스템은 실행
 - Data Agent: 목표만 제시 → Agent가 데이터 탐색부터 파이프라인 생성·실행까지 수행
- 핵심 구성요소 6개:
 - Semantic Data Organization: 구조화/비구조화 데이터를 의미적으로 연결하고 검색
 - Semantic Operators: 기존 filter/join/group-by에 semantic filter/grouping/extraction 등을 추가
 - Agentic Pipeline Orchestration: 여러 Agent가 작업을 분해하고 적절한 연산 순서를 결정
 - Feedback Loop: 실행 결과와 검증 결과를 이용해 잘못된 파이프라인을 수정
 - Memory: 과거 작업·메타데이터·성공한 파이프라인을 저장하고 재사용

- Proactive Adaptation: 데이터나 사용자 요구 변화에 맞춰 파이프라인을 지속적으로 조정
- Embedding → 경량 LLM → 강력한 LLM의 cascading 방식으로 semantic operation의 비용을 줄임.

3. Experiments & Results

- DABStep: 450개 데이터 분석 문제
 - Easy: 94.44%
 - Hard: 50.79%
 - 비교 대상 2위 시스템 대비 각각 +6.94%p, +5.55%p
- Spider 2.0-Lite: 547개 Text-to-SQL 문제
 - DataAgent: 44.50
 - ReForce + o3: 37.84
 - +6.66점
- 실행 시간
 - DABStep: 2.32× 빠름 (6.5분 → 2.8분)
 - Spider 2.0-Lite: 1.45× 빠름 (7.4분 → 5.1분)
- LLM Token 사용량
 - DABStep의 복잡한 matching task에서 입력 토큰 178.5k → 27.6k
 - 최대 6.5× 감소
- Ablation 결과:
 - Semantic Organization, Feedback Loop, Memory를 제거하면 모두 성능 저하
 - 특히 복잡한 multi-step reasoning에서는 Feedback와 Memory의 효과가 큼

4. Insight

- 핵심 기여: 단순히 LLM에게 데이터 분석을 시키는 것이 아니라, 데이터 자체에 대한 semantic layer + agentic pipeline + feedback + memory를 결합해 데이터 분석 시스템 전체를 자율화함.
- 한계:

- 완전한 자율 시스템은 아직 아님.
- 스스로 새로운 문제를 발견하고 사용자 요청 없이 작업을 시작하거나 지속적으로 안정적인 자기개선을 수행하는 것은 향후 과제로 남아 있음.
- 데이터 보안·개인정보·도메인 지식 통합 문제도 남아 있음.
- 내가 가져갈 포인트:
 - RAG ≠ 단순 문서 검색 → 데이터 분석에서는 데이터 탐색 → SQL/semantic operation → 검증 → 수정 → 결과 생성까지 연결할 수 있음.
 - Data Agent의 핵심은 LLM 자체보다 데이터 시스템과 Agent의 결합임.
 - Semantic Data Organization + Memory + Feedback Loop가 일반적인 단순 Agent와 차별화되는 핵심 요소.
 - 데이터 엔지니어링 관점에서는 고정된 ETL 파이프라인 → 목표 기반의 동적 데이터 파이프라인이라는 방향성이 중요함.