Data.Readme: Documenting Table Relationships for Diverse Data Tasks

https://arxiv.org/pdf/2610.25131

1\. Problem — 해결하려는 문제

- 문제: 수천~수만 개의 테이블이 있는 데이터 레이크에서, LLM이 질문에 필요한 테이블과 테이블 간 관계를 찾아내기 어렵다.
- 기존 방식의 한계:
  - 테이블 이름과 컬럼 정보만으로는 비슷한 테이블을 구분하기 어렵다.
  - 필요한 테이블을 찾기 위해 매번 많은 데이터를 탐색해야 한다.
  - 탐색 비용과 지연 시간이 증가하고, 잘못된 테이블 선택으로 분석 정확도도 떨어진다.
- 왜 중요한가? 복잡한 데이터 분석에서 LLM의 추론 능력뿐 아니라, 분석에 사용할 데이터를 정확히 찾는 능력이 성능을 좌우하기 때문이다.

2\. Method — 핵심 아이디어

- 핵심 아이디어: 데이터 레이크 전체에 테이블 간 관계를 미리 정리한 일종의 `README`를 만들어 LLM 에이전트가 재사용하게 한다.
- 기존 방법과의 차이: 기존의 개별 테이블 설명을 넘어, 테이블 간 관계와 차이까지 구조화한다.

핵심 구성요소는 세 가지다.

- Confusable tables: 이름이나 스키마가 비슷하지만 지역, 기간, 집계 수준 등이 다른 테이블을 구분한다.
- Joinable tables: 의미적으로 연결해 조인할 수 있는 테이블을 식별한다.
- Union-able tables: 스키마가 호환되어 합칠 수 있는 테이블을 찾는다.

추가 메커니즘:

- 오프라인 인덱싱: LLM 등을 활용해 테이블 관계를 사전에 추출한다.
- 에이전트 탐색 도구: 질문과 관련된 테이블 및 연결 관계를 인덱스에서 검색한다.
- 예산 기반 최적화: `DensitySelect` 알고리즘으로 제한된 비용에서 문서화할 테이블을 선택한다.

3\. Experiments & Results — 실험 및 결과

\- 실험 환경

- 최대 12,829개 테이블을 포함한 데이터 레이크 2종.
- 데이터 탐색, 데이터 분석(NL2SQL 등), 데이터 과학(분류·회귀) 평가.
- 6개 LLM과 비교: GPT-5.4 계열, GPT-OSS-120B, DeepSeek-V4 계열 등.
- 비교 대상: 개별 테이블 설명, BM25·벡터 검색, 기존 데이터 에이전트 및 코딩 에이전트.

\- 주요 결과

평가 항목	주요 결과
데이터 탐색	48개 실험 조건 중 47개에서 동등한 탐색 제한을 둔 비교 방법보다 우수
데이터 분석	48개 조건 중 45개에서 최고 성능
데이터 과학	기존 코딩 에이전트에 Data.Readme를 추가했을 때 분류 성능의 gain recovery가 24.80% → 98.47%
회귀 분석	gain recovery가 77.62% → 99.82%
인덱스 구축 비용	예산 최적화 시 BIRD 데이터에서 비용 $104.20 → $22.17, 성능 저하는 1.94%p

\- 무엇이 개선됐나?

- 테이블 검색 정확도와 후속 분석 성능이 함께 개선됐다.
- 기존 코딩 에이전트에 결합해도 성능 향상을 얻을 수 있다.
- 논문 초록은 작업 정확도를 최대 40%p 개선하고, 지연 시간을 최대 6배 줄였다고 보고한다.

4\. Insight — 핵심 인사이트

\- 핵심 기여 한 줄: LLM이 매번 데이터를 탐색하도록 두는 대신, 테이블 간 관계를 사전에 문서화해 데이터 탐색을 재사용 가능한 지식으로 바꿨다.

\- 한계점 및 아쉬운 점

- 사전 인덱스 구축에 추가 비용이 발생하며, 데이터가 자주 변경되면 갱신이 필요하다.
- 잘못된 테이블 관계를 추출하면 검색 및 분석 결과에도 영향을 줄 수 있다.
- 실험 결과가 다양한 실제 운영 환경과 데이터 종류에서도 동일하게 재현되는지는 추가 검증이 필요하다.