

Demystifying Agent Skills: Why They Work—Until They Don't

<https://arxiv.org/pdf/2608.14036>

1. Problem

- LLM Agent의 Skill이 왜 효과적인지, 언제 실패하는지 불명확함
- 단순 성공률 비교만으로는 Skill의 실제 역할을 설명하기 어려움
- 중요한 이유: Agent가 과거 경험을 어떻게 재사용해야 하는지 이해할 필요가 있음

2. Method

- 과거 경험을 Raw / Workflow Memory / Skill 형태로 나누어 비교
- 8,135개 trial과 240개 trajectory를 분석
- Skill의 효과를 12개 사용 방식으로 분류
- Skill은 지식 전달보다 과거의 성공적인 작업 절차를 안정적으로 재현하는 역할이 핵심

3. Experiments & Results

- 성공률
 - Raw: 59.1%
 - Workflow Memory: 55.9%
 - Skill: 61.9%
- Skill 사용 시 환경 오류: 5.3% → 0.2%
- 출력 형식 오류: 7.4% → 3.2%
- 반면 잘못된 Skill 적용 문제: 0.8% → 10.0%
- Skill이 많아질수록 retrieval precision은 29.6% → 3.3%로 감소
- Terminal-Bench-2에서 Skill: 79.2%로 가장 높은 성능

4. Insight

- 핵심: Skill은 새로운 지식을 주입하기보다 성공적인 행동 절차를 안정화함
- 한계: Skill이 많아지면 retrieval이 어려워지고, 잘못된 Skill은 오히려 방해가 될 수 있음
- 가져갈 점: Agent Memory는 단순 저장보다 재사용 가능한 절차로 구조화하는 것이 중요함