

Harness Handbook: Making Evolving Agent Harnesses Readable, Navigable, and Editable

<https://arxiv.org/pdf/2607.13285>

1. Problem

- 해결하려는 문제
 - AI Agent의 Harness(프롬프트, Tool 호출, 실행 로직)는 점점 복잡해지면서 원하는 기능이 어디에 구현되어 있는지 찾기 어려움.
 - 기존 코드 검색은 구조 중심이라 행동(Behavior) 단위의 수정이 비효율적임.
- 왜 중요한가
 - Agent 개발과 유지보수에서 코드 탐색 비용이 성능과 생산성을 크게 좌우하기 때문.

2. Method

- 핵심 아이디어
 - Behavior 중심으로 Harness를 문서화하는 Harness Handbook을 구축.
 - Behavior와 실제 코드를 연결하여 필요한 구현 위치를 빠르게 찾도록 지원.
- 기존 방법과 차이점
 - 파일이나 함수 중심이 아닌 Behavior 중심 탐색을 수행.
 - 단계적으로 관련 코드를 좁혀가는 탐색 방식을 사용.
- 주요 구성요소
 - Harness Handbook
 - Behavior-Guided Progressive Disclosure (BGPD)
 - Behavior ↔ Source Code 매핑

3. Experiments & Results

- 대규모 Agent Harness 환경에서 Behavior Localization 성능 평가.
- 기존 코드 탐색 방식과 비교 실험 수행.
- Behavior Localization F1 최대 18.8% 향상.
- Planner Token 사용량 약 8~13% 감소.
- Edit Plan 품질이 향상되어 복잡한 코드 수정 작업에서 더 높은 성능을 보임.

4. Insight

- 핵심 기여
 - Behavior 중심 문서화를 통해 Agent Harness의 탐색성과 수정 효율을 크게 향상.
- 한계점
 - Harness 구조와 Behavior 정의 품질에 성능이 영향을 받을 수 있음.
- 가져갈 포인트
 - AI Agent에서는 모델 성능뿐 아니라 Behavior를 쉽게 찾고 수정할 수 있는 구조가 매우 중요하다는 점을 보여준 연구.