

# Harnessing the Reasoning Economy: A Survey of Efficient Reasoning for Large Language Models

<https://arxiv.org/pdf/2503.24377>

## 1. Problem

- 해결하려는 문제
  - LLM은 복잡한 추론(System 2)을 수행할수록 추론 토큰, 연산량, 추론 시간이 크게 증가하는 Reasoning Inefficiency 문제가 발생함.
- 왜 중요한가?
  - 실제 서비스에서는 정확도뿐 아니라 추론 비용(Latency, GPU 비용, Token Cost)도 함께 최적화해야 함.

## 2. Method

- 핵심 아이디어
  - Reasoning Economy라는 개념을 중심으로 성능(Benefit)과 계산 비용(Budget)의 균형을 맞추는 최신 연구들을 체계적으로 정리한 Survey 논문.
- 기존 방법과 차이점
  - 기존 Survey는 CoT나 추론 자체를 다뤘다면, 이 논문은 같은 성능을 더 적은 비용으로 달성하는 방법에 초점을 맞춤.
- 핵심 구성
  - Reasoning Inefficiency 원인 분석
    - 불필요하게 긴 CoT
    - 반복 추론
    - 쉬운 문제에도 과도한 추론

- Post-training
  - SFT
  - RL
  - Distillation
  - Compression
- Test-time Inference
  - Adaptive Reasoning
  - Early Exit
  - Dynamic Routing
  - Reasoning Length Control
- Reasoning Pattern 분석
  - 언제 깊게 추론하고 언제 빠르게 답할지 결정하는 전략

### 3. Experiments & Results

- 어떤 실험을 했는가?
  - 새로운 실험이 아니라 Efficient Reasoning 관련 연구들을 비교·분석한 Survey 논문.
- 주요 결과
  - 다양한 연구에서 추론 토큰 감소, 추론 시간 단축, GPU 비용 절감을 달성하면서도 기존 정확도를 대부분 유지함.
- 개선된 점
  - 필요한 경우에만 깊게 추론하는 Adaptive Reasoning이 가장 유망한 방향으로 제시됨.
  - 추론 비용과 지연 시간이 감소해 실제 서비스 적응성이 향상됨.

### 4. Insight

- 핵심 기여
  - LLM 추론을 정확도보다 '정확도 대비 비용(Efficiency)' 관점에서 체계적으로 정리한 대표적인 Survey.
- 한계점

- 새로운 알고리즘을 제안하지 않음.
- 기존 연구를 정리·분석하는 Review 논문임.
- 2025년 초까지의 연구만 포함.
- 가져갈 포인트
  - Reasoning Economy라는 새로운 평가 관점
  - Adaptive Reasoning, Dynamic Routing, Early Stopping, Reasoning Compression이 핵심 연구 방향
  - 앞으로는 "더 오래 생각하는 모델"보다 "필요할 때만 생각하는 모델"이 중요해질 것으로 전망됨.