KVStream: Adaptive Parallel Storage Management for KV Caching in Large-Scale LLM Serving

https://arxiv.org/pdf/2610.31827

1. Problem

- LLM의 KV Cache가 GPU·CPU 메모리를 초과하면 SSD나 원격 Storage에서 읽어야 한다.
- 기존 방식은 Storage I/O 병렬성이 부족해 추론 속도와 처리량이 저하된다.

2. Method

- 여러 Storage(NVMe, PFS)를 활용해 KV Cache를 병렬로 읽는 시스템 제안.
- 핵심 메커니즘:
  - Batched Retrieval: KV 읽기 요청을 묶어서 처리.
  - Deferred Writes: 쓰기 작업을 지연해 읽기 간섭 최소화.
  - Multi-path Replication: 여러 Storage에 KV 복제.
  - Adaptive Routing: 먼저 읽기를 완료한 Storage에 다음 작업 할당.

3. Experiments & Results

- 14B~110B 모델, 최대 128 GPUs 환경에서 평가.
- LMCache 대비:
  - 최대 1.49× Throughput
  - 최대 6.1× 빠른 TTFT
  - 128 GPU 환경에서 1.23~1.36× Throughput

- 핵심 성능 향상 요인은 Completion-driven Routing.

4. Insight

- 핵심 기여: 여러 Storage의 대역폭을 동적으로 활용해 KV Cache Retrieval 성능을 개선.
- 한계: KV 복제로 Storage Write 비용 증가. KV 재사용률이 낮거나 메모리에 충분히 캐싱되는 환경에서는 효과 제한.
- 가져갈 포인트:
  - 정적 분배보다 실제 완료 속도 기반 동적 스케줄링이 효과적이다.
  - 새로운 하드웨어 추가보다 기존 자원의 병렬 활용이 중요할 수 있다.
  - I/O 최적화가 LLM Serving의 TTFT와 Throughput을 크게 개선할 수 있다.