

Memory Efficient Tabular Foundation Models

<https://arxiv.org/abs/2607.27546>

1. Problem

- Tabular Foundation Model(TFM)은 높은 예측 성능을 제공하지만 GPU 메모리 사용량이 매우 커 실제 배포가 어려움
- 특히 TabPFN과 같은 In-Context Learning 기반 모델은 추론 시 메모리 요구량이 높음
- 정확도를 유지하면서 메모리 사용량을 줄일 수 있는 효율적인 배포 방법이 필요함

2. Method

- TabPFN 기반 모델에 **Post-Training Quantization(PTQ)** 적용
- FP32 모델을 FP16, INT8, INT4 등 저정밀 형식으로 변환해 모델 크기 감소
- 추가 학습 없이 모델만 압축해 메모리 효율 향상
- 다양한 정밀도에서 메모리 절감 효과와 성능 유지 여부 비교 분석

3. Experiments & Results

- 30개의 Tabular Benchmark 데이터셋에서 성능 평가
- FP32, FP16, INT8, INT4 모델 비교
- INT4 Quantization 적용 시 최대 7.6배 메모리 절감(약 87% 감소) 달성
- 정확도는 Full Precision 대비 거의 유지됐으며, 강력한 Classical ML Baseline보다 높은 성능 유지

4. Insight

- 핵심 기여

- Quantization만으로 Tabular Foundation Model의 메모리 사용량을 크게 줄이면서 성능을 거의 유지할 수 있음을 입증함
- 한계점
 - TabPFN 계열 모델 중심으로 검증되어 다른 TFM에 대한 일반화는 추가 검증이 필요함
 - 메모리 효율성에 초점을 맞춰 추론 속도와 에너지 효율은 제한적으로 분석함
- 내가 가져갈 포인트
 - Foundation Model도 Quantization을 통해 실무 배포 가능성을 크게 높일 수 있음
 - 모델 성능뿐 아니라 메모리와 하드웨어 비용까지 함께 고려하는 것이 실제 서비스에서 중요함