NousDB - A Fast Query Engine for Semantic Analytics

https://arxiv.org/pdf/2610.28551

1\. Problem

- 문제: LLM 기반 데이터 분석은 호출 비용이 높고 처리 속도가 느리며, 배치 처리 시 정확도가 떨어질 수 있음.
- 중요성: 대규모 데이터 분석에서 속도·비용·정확도를 동시에 개선해야 함.

2\. Method

- 쿼리 최적화: 필터 푸시다운 등으로 불필요한 LLM 호출 감소.
- 토큰 기반 배치 처리: 레코드 수가 아닌 토큰 사용량을 기준으로 배치 크기 결정.
- 결과 검증: 배치 결과와 개별 호출 결과의 일치도를 검증.
- 부하 분산: 토큰 비용에 따라 작업을 효율적으로 분배.

3\. Experiments & Results

- 여러 데이터셋과 LLM을 대상으로 기존 시스템과 성능 비교.
- 최대 86배 빠른 쿼리 실행
- 최대 19배 토큰 사용량 절감
- 필터 최적화로 LLM 처리 대상 감소.
- 배치 처리의 정확도 저하를 검증 메커니즘으로 제어.

4\. Insight

- 핵심 기여: 쿼리 최적화, 토큰 기반 배치 처리, 결과 검증을 통합해 LLM 데이터 분석의 효율성을 개선.
- 한계: 개별 호출과의 일치도가 실제 정답의 정확성을 보장하지는 않음.
- 가져갈 포인트: LLM 호출 전에 데이터를 최대한 줄이고, 토큰 비용과 결과 품질을 함께 고려해 실행 계획을 최적화해야 함.