

OmniTable: A Unified Wide-Table System for Petabyte-Scale LLM Data Curation and Exploration

<https://arxiv.org/abs/2609.11148>

1. Problem

- 문제
 - LLM 학습 데이터가 수백 개의 물리 테이블과 여러 처리 파이프라인에 분산됨.
 - 새로운 Feature를 추가할 때 데이터셋별로 파이프라인을 수동 구성해야 함.
 - Feature의 버전과 데이터 lineage가 제대로 관리되지 않아 어떤 데이터/Feature가 학습 결과에 영향을 줬는지 추적하기 어려움.
- 왜 중요한가?
 - 데이터가 PB 단위로 커질수록 데이터 정제·Feature 생성·검증 자체가 LLM 개발의 병목이 되기 때문.

2. Method

- 핵심 아이디어
 - 사용자에게는 모든 데이터를 하나의 논리적 Wide Table로 보여줌.
 - 실제 저장은 여러 Physical Table로 분리하여 성능과 확장성을 확보.
 - Catalog가 논리 컬럼과 물리 테이블의 매핑을 관리.
- 기존 방법과 다른 점
 - 기존: Table → Pipeline → Job 중심
 - OmniTable: Row + Feature → 선언 → 자동 실행 중심
 - 사용자가 Feature의 계산 방법만 선언하면 시스템이 의존성 DAG 분석, 실행 계획 생성, CPU/GPU 자동 라우팅, Operator Fusion, 실패 데이터 재처리, Feature

version 및 lineage 기록 등을 자동 수행.

- 주요 구성요소
 - Catalog
 - 데이터와 Feature의 메타데이터, 버전, lineage, 논리-물리 매핑 관리
 - Feature & Execution Engine
 - Feature dependency를 자동 해결하고 CPU/GPU 작업을 적절한 환경에 배치
 - Autonomous Governance
 - partition, column splitting, compaction, materialization 등을 자동 수행
 - Exploration Service
 - Global ID Index, ClickHouse OLAP, Materialized View를 활용해 대규모 데이터 탐색 지원

3. Experiments & Results

- 실제 Production 환경에서 평가
 - 35+ PB
 - 305B+ records
 - Web 데이터: 25 PB / 300B+ records / 800+ logical columns
 - 200+ features, 392+ batches
- End-to-End
 - 전체 데이터 curation: 14일 → 2.5일
 - Manual steps: 45 → 12
 - Pipeline: 24 → 10
 - 전체 처리 속도: 5.6배 향상
 - Feature backfill: 9.5일 → 1.7일
- PB-scale 확장성
 - 1 TB → 25 PB에서 18–23 TB/h 처리량 유지
 - 기존 workflow는 25 PB에서 약 2 TB/h
 - Autonomous Governance 제거 시 PB 규모 처리량이 3배 이상 감소

- Execution Engine
 - Operator Fusion:
 - CPU 사용량 55.9% 감소
 - 처리 시간 38h → 14h
 - UDF-level Fault Tolerance:
 - 500 GB에서 599.97M records 정상 처리
 - 이상 데이터 약 31K개만 격리
 - 기존 방식 약 52h → 6.2h
 - Adaptive Tuning:
 - 다양한 데이터 크기에서 100% first-submit success
 - 전문가 수동 튜닝 대비 비용 5% 이내
- Data Exploration
 - Global ID Index:
 - Point lookup P50: 184s → 8.3s
 - P99: 612s+ → 14.7s
 - ClickHouse OLAP:
 - Aggregation query 94–154배 가속
 - 응답시간 10초 이하
 - Materialized View:
 - Filtered export 1.6–4.2배 가속
 - 20 TB/h 이상 처리량 달성

4. Insight

- 핵심 기여
 - LLM 데이터 처리의 단위를 테이블/파이프라인에서 데이터 + Feature로 전환하고, 이를 PB 규모에서 자동 운영하는 데이터 인프라를 제시함.
- 한계 / 아쉬운 점
 - 실험이 실제 Ant Group Production 환경 중심이라 일반적인 기업이나 오픈 환경에서 동일한 성능이 나오는지 확실하지 않음.

- 기존 시스템과의 비교가 주로 workflow-level coordination cost에 초점이 있어 모든 관련 데이터 처리 시스템과의 직접적인 종합 benchmark는 부족함.
- 내가 가져갈 포인트
 - LLM 자체의 학습 성능을 개선하는 논문이 아니라, LLM 학습 데이터를 어떻게 관리·생성·추적·탐색할 것인가를 다룬 논문.
 - Feature Store, Data Lake/Lakehouse, Workflow Orchestration, Data Lineage, 자동화를 하나의 시스템 관점에서 연결했다는 점이 핵심.
 - 데이터 엔지니어 관점에서는 LLM 시대의 Data Infrastructure가 어떤 방향으로 발전하는지 보여주는 사례.