

Potential Applications of HBF in LLM Serving Systems

<https://arxiv.org/abs/2608.13127>

1. Problem

- 문제: LLM serving에서 모델 크기·KV cache·서비스 모델 수가 커지면서 HBM 용량 부족이 병목이 됨.
- HBM은 bandwidth는 높지만 capacity 확장이 어렵고 비싸기 때문에, 단순히 HBM만 늘리는 방식에는 한계가 있음.

2. Method

- 핵심 아이디어: HBM을 대체하는 게 아니라 HBF(High-Bandwidth Flash)를 추가 capacity layer로 사용.
- HBM → KV cache 등 latency/bandwidth-critical 데이터
- HBF → read-mostly한 model weight / MoE expert weight
- Integrated HBM/HBF stack 구조를 제안:
 - HBM의 빠른 실행 경로는 유지
 - HBF로 resident weight capacity를 크게 확장
 - HBF의 추가 capacity를 expert/model replication에 활용
- 기존 HBM-only serving과 다른 점은 메모리 bandwidth를 늘리는 것보다 resident model state를 더 많이 유지하는 데 초점을 둔다는 점.

3. Experiments & Results

- MoE serving
 - Qwen3-235B-A22B, H100-class 4-node 환경
 - 80GB HBM + 최대 512GB HBF/GPU
 - 8 → 32 experts/device:
 - 평균 TPOT 10.20 → 9.13ms (-10.5%)

- p95 TPOT 10.74 → 9.73ms (-9.4%)
 - Cross-node expert traffic 최대 16.1% 감소
- 요청률 8 → 32 req/s에서 TPOT 개선폭 11.1% → 15.4%
- Multi-model serving
 - 27개 모델, 1B-40B parameters, 총 약 620GB weight
 - HBM-only 80GB → HBF 활용 시 최대 512GB capacity
 - 1× → 4× capacity:
 - Mean TTFT 196.1 → 6.8ms
 - 28.7× 감소
 - 모델 activation/loading event 212 → 0
 - Hot model replication 적용 시 TTFT 6.83 → 6.05ms (-11%)
 - 요청률 0.5 → 5 req/s에서 TTFT 개선폭 4.1× → 19.4×

4. Insight

- 핵심 기여: HBF를 단순한 대용량 메모리가 아니라, LLM weight/expert를 더 많이 상주시켜 locality·replication·load balancing을 개선하는 capacity 확장 계층으로 활용함.
- 한계: HBF가 HBM의 critical bandwidth path를 방해하지 않는다는 가정에 크게 의존하며, 실제 HBF의 latency/packaging/interconnect 특성을 완전히 검증한 실측 결과는 아님. KV cache도 HBF에 넣지 않음.
- 내가 가져갈 포인트:
 - LLM serving의 memory 문제는 bandwidth뿐 아니라 capacity/residency 문제이기도 함.
 - MoE에서는 expert replication, multi-model에서는 model residency/replication으로 추가 capacity를 성능으로 전환할 수 있음.
 - 핵심은 "더 큰 메모리 = 더 많은 데이터 저장"이 아니라 "더 많은 model state를 local하게 유지 = communication/loading 감소"라는 관점.