

Rethinking the Evaluation of Harness Evolution for Agents

https://arxiv.org/abs/2607.12227?utm_source=substack&utm_medium=email

1. Problem

- 기존 Harness Evolution 연구는 Evolution에 사용한 동일한 Benchmark에서 성능을 평가
- Test-time Search 효과와 Harness 자체의 개선 효과를 구분하기 어려움
- Benchmark Overfitting으로 인해 실제 일반화 성능을 과대평가할 가능성 존재
- 공정하고 일반화 가능한 평가 프로토콜이 필요

2. Method

- Harness Evolution과 Search 기반 방법을 동일한 Compute Budget에서 비교
- Parallel Sampling, Best-of-N 등 강력한 Search Baseline 추가
- Evolution에 사용하지 않은 Held-out Task에서 일반화 성능 평가
- Search 효과와 Harness 개선 효과를 분리하여 분석

3. Experiments & Results

- Benchmark : Terminal-Bench 2.1
- Models : GPT-5.4, Claude Opus 4.6
- 동일한 추론 예산에서 Harness Evolution과 Search Baseline 비교
- Harness Evolution은 단순 Search보다 항상 우수하지 않음
- 일부 성능 향상은 Harness 개선보다 추가 Search 효과에서 비롯됨
- Held-out Task에서는 성능 향상이 제한적이며 일반화가 어려운 경우 확인

4. Insight

핵심 기여

- Harness Evolution의 평가 방식 자체를 재검토하고 공정한 Evaluation Protocol을 제안

한계점

- 새로운 Harness Evolution 알고리즘을 제안하지 않음
- 분석이 특정 Agent Benchmark에 집중되어 추가 검증이 필요