Retriever-Free Retrieval: Navigating Documents with Decision Models

https://arxiv.org/abs/2610.35868

1\. Problem

- 기존 RAG는 키워드나 임베딩 유사도에 의존해 관련 문서를 놓칠 수 있음.
- 검색 성능이 전체 RAG 성능을 제한한다는 문제.

2\. Method

- LLM이 Retriever 없이 직접 문서를 탐색하는 DecisionRAG 제안.
- 문서를 계층적으로 구성하고, LLM이 각 단계에서 탐색할 후보를 판단.
- 후보들을 동시에 비교해 효율적으로 관련 문서 선택.

3\. Experiments & Results

- 4개 데이터셋에서 검색 및 QA 성능 평가.
- 검색 성능: 기존 방법 대비 최대 17.4%p 향상.
- 검색 속도: 기존 Reranking 대비 최대 145배 빠름.
- RAG 정답률도 개선됨.

4\. Insight

- 핵심 기여: 유사도 기반 검색을 LLM의 의사결정 기반 탐색으로 전환.
- 한계: 문서의 계층 구조와 탐색 경로의 품질에 영향을 받음.
- 가져갈 포인트: LLM을 답변 생성뿐 아니라 검색 과정에도 활용할 수 있으며, Retrieval을 단순 검색이 아닌 의사결정 문제로 접근할 수 있음.