

ScaleSense: Cost-Intelligent Scaling Framework via Learned Resource Estimation in Alibaba AnalyticDB

<https://arxiv.org/abs/2608.07945>

1. Problem

- 해결하려는 문제
 - 클라우드 데이터 웨어하우스에서 쿼리마다 필요한 CPU, 메모리, I/O 등의 자원이 달라 최적의 리소스 할당량을 결정하기 어려움
 - 실제 운영 환경에서는 성능 저하를 피하기 위해 리소스를 과도하게 할당하는 over-provisioning이 발생함
 - 특히 CPU가 아닌 I/O 등의 병목 때문에 리소스를 더 할당해도 성능이 좋아지지 않는 경우가 있음
- 왜 중요한가?
 - 과도한 리소스 할당은 성능 향상 없이 클라우드 비용만 증가시키므로, 쿼리별로 성능과 비용 사이의 최적점을 찾는 것이 중요함

2. Method

- 핵심 아이디어
 - 쿼리가 실행되기 전에 해당 쿼리가 필요로 하는 다차원 리소스 사용량을 예측하고, 이를 바탕으로 적절한 리소스를 자동으로 할당함
 - 이를 위해 ScaleSense라는 query-level scaling framework를 제안함
- 기존 방법과 다른 점
 - 단순히 CPU 사용량만 예측하는 것이 아니라
 - query execution plan의 구조

- hardware configuration
- CPU, memory, I/O 등 여러 리소스를 함께 고려함
- 예측값 하나만 내는 것이 아니라 quantile-based prediction을 사용해 리소스 사용량의 불확실성까지 고려함
- 핵심 구성요소
 1. multi-faceted query encoder
 - query plan topology와 하드웨어 정보를 함께 인코딩
 2. quantile-based resource predictor
 - 쿼리의 다차원 리소스 요구량을 예측하고 prediction interval을 제공
 3. auto-scaling controller
 - 예측 결과를 바탕으로 성능과 비용 사이의 pareto frontier를 탐색
 - 사용자가 성능 우선인지 비용 우선인지에 따라 적절한 리소스 설정을 선택
 - 정책이 바뀌어도 모델을 다시 학습할 필요 없음

3. Experiments & Results

- 실험 데이터
 - Alibaba AnalyticDB의 실제 production workload
 - 136만 개 이상의 쿼리를 대상으로 평가
- 주요 결과
 - 리소스 사용량 예측에서 state-of-the-art 수준의 정확도와 안정적인 prediction interval coverage를 달성
 - 최적 리소스 설정 선택 성능이 기존 최고 baseline보다 76.7% 개선
 - 성능 최적화 정책에서는 사용자가 요구한 성능 조건을 만족하면서 비용을 최대 5.22배 절감
 - 실제 서비스 환경에서도 낮은 inference overhead로 동작 가능함을 보임
- 무엇이 개선됐는가?
 - 무작정 리소스를 많이 할당하는 방식에서 벗어나 쿼리별 필요한 만큼만 할당할 수 있게 됨

- 성능을 유지하면서 클라우드 인프라 비용을 크게 줄임

4. Insight

- 핵심 기여 한 줄
 - 쿼리별 리소스 사용량을 학습하고, 불확실성까지 고려해 성능-비용 최적점을 자동으로 선택하는 실용적인 autoscaling framework를 제안함
- 한계점 / 아쉬운 점
 - 실제 Alibaba AnalyticDB production workload에 강하게 의존하므로 다른 DB 시스템이나 클라우드 환경에서도 동일한 성능이 나오는지 추가 검증이 필요함
 - 새로운 workload나 시스템 환경에서의 distribution shift 대응은 중요한 후속 과제임
- 내가 가져갈 포인트
 - 단순히 더 좋은 예측 모델을 만드는 것보다 예측 결과를 실제 시스템의 의사결정 (auto-scaling)으로 연결하는 것이 중요함
 - 운영 시스템에서는 예측값 자체보다 불확실성을 고려한 안전한 의사결정이 중요함
 - prediction → decision → cost/performance optimization까지 하나의 pipeline으로 설계한 것이 핵심 포인트임