Semantic Atoms for Scalable Text Analysis in Data Analytics in the Era of LLM-Based Agents

https://arxiv.org/abs/2610.34860

1. Problem

- LLM 기반 텍스트 분석은 반복적인 호출과 처리 비용이 발생하고, 대규모 데이터 분석에 비효율적임.
- 목표: 비정형 텍스트를 효율적으로 정형화하고 후속 데이터 분석에 활용하는 것.

2. Method

- Semantic Atoms: LLM이 텍스트에서 추출한 의미 정보를 재사용 가능한 데이터로 저장하는 방식.
- 핵심 구성요소
  - Tagging: 개별 텍스트에서 감정, 키워드 등 추출
  - Categorization: 여러 텍스트에서 공통 주제와 카테고리 발견
- 추출 결과는 테이블로 저장하고 SQL/Python으로 집계 및 분석함.
- 기존 방식과 달리 의미 분석 결과를 반복적으로 추출하지 않고 재사용함.

3. Experiments & Results

- 고객 리뷰 및 기업 피드백 등 대규모 텍스트 데이터로 감정·주제 분류 실험.
- 주요 결과
  - 감정 분석 Accuracy: 97.3%
  - 주제 분류 Accuracy: 94.2%
  - LLM 호출 횟수: 기존 방식 대비 최대 41.8배 감소
- 대규모 텍스트 분석의 효율성과 재사용성을 개선함.

4. Insight

- 핵심 기여: LLM의 의미 해석과 SQL/Python의 정량적 분석을 결합한 텍스트 분석 구조 제안.
- 한계: 의미 추출 오류가 후속 분석에 영향을 줄 수 있으며, 다양한 분석 작업으로의 확장성 검증이 필요함.
- 가져갈 포인트: LLM 분석 결과를 일회성 응답으로 끝내지 않고 정형 데이터로 저장하면 후속 분석과 데이터 파이프라인에 재활용할 수 있음.