

Speculate While You Reason: Teaching Agents to Predict Their Next Tool Call via Joint Agent-Speculator RL

https://arxiv.org/abs/2607.25816?utm_source=substack

1. Problem

- 해결하려는 문제
 - LLM Agent는 Tool 응답 대기 시간이 길어 전체 추론 속도가 느림
 - 기존 Tool Speculation은 별도 모델이나 캐시를 사용해 다음 Tool Call을 예측하지만 Agent와 행동 차이 때문에 정확도가 낮음
- 왜 중요한가?
 - Agent의 병목은 LLM 추론보다 Tool 대기 시간이므로 이를 줄이면 전체 응답 속도 향상 가능

2. Method

- 핵심 아이디어
 - Agent가 직접 다음 Tool Call을 예측하도록 학습
 - Agent와 Speculator를 하나의 모델(Self-Speculating Agent)로 통합
- 기존 방법과 차이점
 - 기존: 별도 Speculator 모델 또는 캐시 사용
 - 제안: 하나의 모델이 추론과 Tool Call 예측을 동시에 수행
- 핵심 메커니즘
 - Joint Agent-Speculator RL 적용
 - Agent rollout으로 speculation target 자동 생성

- Agent 모드와 Speculator 모드를 번갈아 학습
- Prefix KV Cache 공유로 추가 비용 최소화

3. Experiments & Results

- 실험
 - Agentic Search QA
 - Conversational Tool-use Agent
- 주요 결과
 - Qwen3-4B: Hit@1 44.1 → 61.2
 - Qwen3.5-4B: Hit@1 48.9 → 66.3
- 개선점
 - 다음 Tool Call 예측 정확도 크게 향상
 - Agent 성능(Task Success) 유지

4. Insight

- 핵심 기여
 - Agent 자체가 미래 Tool Call을 예측하도록 RL로 학습한 최초의 프레임워크 제안
- 한계점
 - Tool Call 중심 환경에서만 검증됨
 - 실제 지연 시간 감소는 시스템 환경에 따라 달라질 수 있음
- 가져갈 포인트
 - Latency를 RL 학습 목표로 활용한 점이 핵심
 - 별도 모델보다 하나의 모델에 두 역할을 학습시키는 방식이 효율적
 - 미래 Tool Call을 미리 예측하는 방식은 향후 Agent 최적화의 중요한 방향으로 보임