

The Danger of Overthinking: Examining the Reasoning-Action Dilemma in Agentic Tasks

https://arxiv.org/abs/2502.08235?utm_source=substack

1. Problem

- LRM(Large Reasoning Model)은 Agent 환경에서 지나치게 긴 추론을 수행하는 경향이 있음
- 과도한 추론은 행동 횟수를 줄이고 작업 성공률을 낮춤
- 추론 시간과 비용이 증가해 실제 Agent 활용성이 떨어짐
- 언제 생각하고 언제 행동할지에 대한 균형이 필요함

2. Method

- Agent의 추론 과정을 분석하는 Overthinking Evaluation Framework 제안
- Overthinking 정도를 측정하는 Overthinking Score 정의
- 대표적인 Overthinking 패턴 3가지 분석
 - Analysis Paralysis
 - Rogue Actions
 - Premature Disengagement
- Reasoning Model과 Non-Reasoning Model을 동일한 환경에서 비교 평가함

3. Experiments & Results

- SWE-bench Verified 기반 Software Engineering Agent Task 사용

- 총 4,018개의 Agent Trajectory 분석
- Overthinking Score가 높을수록 작업 성공률이 감소하는 경향 확인
- Reasoning Model이 Non-Reasoning Model보다 Overthinking에 더 취약함
- Overthinking Score가 낮은 실행 결과를 선택하면 성능은 약 30% 향상되고 추론 비용은 약 43% 감소함

4. Insight

- 핵심 기여
 - Agent의 Overthinking을 정량적으로 분석하고 평가하는 기준을 제시함
- 한계점
 - SWE-bench 중심으로 검증되어 다른 Agent 환경에 대한 일반화는 추가 연구가 필요함
 - Overthinking을 완전히 해결하는 학습 기법까지는 제시하지 않음
- 내가 가져갈 포인트
 - Agent는 추론을 많이 하는 것보다 적절한 시점에 행동하는 것이 더 중요함
 - 추론 비용과 성능을 함께 고려하는 Agent 설계가 필요함