

The Danger of Overthinking: Examining the Reasoning-Action Dilemma in Agentic Tasks

<https://arxiv.org/abs/2502.08235>

1 Problem

- 문제
 - Agent가 문제를 해결할 때 필요 이상으로 reasoning을 길게 수행하는 overthinking 현상을 분석
 - reasoning이 길어질수록 항상 성능이 좋아지는 것이 아니라 action을 늦추거나 잘못된 행동으로 이어질 수 있는 문제를 다룸
- 왜 중요한가
 - Agent는 많이 생각하는 것뿐 아니라 적절한 시점에 reasoning을 멈추고 행동하는 것이 중요함

2 Method

- 핵심 아이디어
 - Agent의 reasoning과 action trajectory를 분석해 overthinking이 성능에 미치는 영향을 평가
 - SWE-bench Verified의 4,018개 trajectory를 대상으로 분석
- 주요 유형
 - Analysis Paralysis: 과도한 reasoning으로 action을 수행하지 못함
 - Rogue Actions: 불필요한 reasoning 이후 잘못된 action을 수행
 - Premature Disengagement: 충분히 해결하지 않았는데 너무 빨리 종료
- 기존 방법과 차이

- 단순히 reasoning token 수를 줄이는 것이 아니라 reasoning과 실제 action의 관계를 trajectory 수준에서 분석

3 Experiments & Results

- SWE-bench Verified에서 reasoning model과 non-reasoning model의 행동을 비교
- overthinking 정도와 task 성능의 관계를 분석
- overthinking이 심할수록 성능이 낮아지는 경향을 확인
- reasoning model이 non-reasoning model보다 overthinking 경향이 강하게 나타남
- overthinking이 적은 trajectory를 선택하는 것만으로도 성능이 약 30% 향상되고 계산 비용이 43% 감소

4 Insight

- 핵심 기여
 - Agent에서는 더 오래 생각하는 것보다 언제 reasoning을 멈추고 action할지가 중요하다라는 것을 실험적으로 보여줌
- 한계점
 - SWE-bench 중심의 실험이라 다른 agent 환경에서도 동일한 결과가 나타나는지는 추가 검증이 필요
- 내가 가져갈 포인트
 - reasoning budget을 무조건 늘리는 것은 좋은 전략이 아님
 - Think → Act → Observe 사이의 전환 타이밍을 최적화하는 것이 중요
 - Agent 학습에서도 reasoning 능력뿐 아니라 적절한 action timing을 함께 고려할 필요가 있음