Tile-Based Decompression in Compiled GPU Engines

https://arxiv.org/pdf/2610.32695

1. Problem

- GPU 데이터베이스는 압축 해제 후 데이터를 메모리에 저장하는 과정에서 메모리 사용량과 대역폭 낭비 발생함
- 대용량 데이터 처리 시 GPU 메모리 병목이 성능 저하의 원인이 됨

2. Method

- 압축 데이터를 한 번에 해제하지 않고 타일 단위로 해제하는 방식 제안함
- 해제한 데이터를 GPU Shared Memory에 유지하고 SQL 연산과 결합함
- CB2T 연산자를 통해 압축 해제와 쿼리 실행을 통합함

3. Experiments & Results

- SSB, TPC-H, StackExchange 데이터셋으로 실험함
- 기존 방식 대비 GPU 메모리 사용량 최대 4배 감소
- 메모리 대역폭 사용량 최대 6배 감소
- 메모리 사용량을 줄이면서 쿼리 실행 속도 유지함

4. Insight

- 핵심 기여: 압축 해제와 쿼리 실행을 결합해 GPU 메모리 효율성을 개선함
- 한계: 압축 알고리즘에 따라 해제 비용이 달라지며 GPU 환경에 따라 최적화 필요함
- 가져갈 포인트: 데이터 압축률뿐 아니라 압축 해제 비용과 메모리 이동까지 고려한 데이터 처리 최적화가 중요함