

TokTier: Exact Stateful Tokenization for Agentic LLM Serving

https://arxiv.org/abs/2607.29678?utm_source=substack&utm_medium=email

1. Problem

- Agent는 긴 prompt를 반복해서 처리해 tokenization 비용이 커짐.
- KV cache는 재사용하면서도 tokenization은 매번 전체 수행 → TTFT의 최대 64% 차지.

2. Method

- Tokenization 자체를 stateful/incremental하게 관리.
- 변경된 부분만 다시 tokenize하고, token boundary가 불안정하면 범위를 넓혀 수정.
- 재사용이 어려운 경우 GPU tokenization으로 처리.
- 핵심은 기존 tokenizer와 결과가 정확히 동일하도록 보장하는 것.

3. Experiments & Results

- 17개 tokenizer, 12.4TB corpus, 93K+ agent steps 검증 → divergence 0건.
- Incremental tokenization: 기존 방식 대비 최대 437× faster.
- GPU tokenization: 최대 491× faster.
- vLLM 적용 시 Median TTFT 16~34% 감소, P99 23% 감소.

4. Insight

- 핵심: KV cache뿐 아니라 tokenization도 stateful하게 재사용하면 agent serving을 크게 줄일 수 있음.
- 특히 긴 context + 작은 변경이 반복되는 coding agent에서 효과가 큼.

- → Agent serving 최적화는 inference뿐 아니라 prompt → tokenization → KV cache 전체 pipeline을 봐야 함.