

tse_tick: A Python Library for Parsing and Querying Nikkei NEEDS Tick Data from the Tokyo Stock Exchange

<https://arxiv.org/abs/2608.23053>

1. Problem

- TSE tick 데이터는 파일이 많고 schema가 복잡함.
- 파싱, 저장, 조회가 느림.
- 대규모 데이터 처리가 병목이 됨.

2. Method

- `tse_tick` Python 라이브러리를 제안.
- Raw 데이터를 Parquet으로 변환.
- Polars로 빠르게 처리.
- DuckDB로 필요한 데이터만 조회.
- Streaming과 partition pruning을 사용.

3. Experiments & Results

- Parsing: pandas 대비 최대 59.8× 빠름.
- Query: CSV scan 대비 약 410× 빠름.
- Peak memory: 24.5GB → 2.4GB.
- 속도와 메모리 효율을 모두 개선.

4. Insight

- 핵심: 금융 tick 데이터 처리 파이프라인을 빠르고 효율적으로 만듦.
- 새로운 모델보다 데이터 엔지니어링에 초점.
- 저장 방식과 I/O 최적화가 매우 중요함.