

# Unifying In-Memory Data Analytics through Sparse Compilation

<https://arxiv.org/abs/2609.30497>

## 1. Problem

- 다양한 데이터 분석 작업의 실행 성능을 높이고 최적화 비용을 줄이는 문제.
- 작업마다 별도로 최적화하면 개발 비용이 커지고 성능 개선에 한계가 있음.

## 2. Method

- Reffine: 공통 중간 표현(IR)을 활용하는 컴파일러 기반 분석 엔진.
- 연산 융합으로 중간 데이터 생성을 줄이고, 자동 병렬화와 희소 데이터 최적화를 적용.
- 개별 작업에 맞춘 구현 대신 통합된 최적화 체계를 제공.

## 3. Experiments & Results

- 32코어 환경에서 SQL, 스트리밍, 그래프 분석 성능 평가.
- DuckDB 대비 최대 24.9배, Umbra 대비 최대 3.2배, Polars 대비 평균 18.3배, NetworkX 대비 평균 47.9배 빠른 성능 보고.
- 개선 효과는 워크로드에 따라 다름.

## 4. Insight

- 핵심 기여: 공통 IR과 컴파일러 최적화를 통해 다양한 데이터 분석 작업의 실행 성능을 개선.
- 한계: 모든 유형의 연산에 최적화된 것은 아니며, 특정 작업에서는 다른 엔진이 유리할 수 있음.
- 가져갈 포인트: 데이터 처리 성능은 알고리즘뿐 아니라 데이터 표현, 메모리 접근, 연산 융합, 병렬화에도 크게 좌우됨.