

VersaDB: A High-Performance AI Storage Database for Unifying Mutimodal Datasets

<https://arxiv.org/abs/2608.22795>

1. Problem

- 문제
 - 멀티모달 AI 데이터의 저장·로딩·셔플 과정에서 I/O 병목 발생
 - 기존 저장 방식은 다양한 AI workload에 최적화하기 어려움
- 왜 중요한가?
 - 데이터 공급 속도가 전체 학습 성능을 제한하기 때문

2. Method

- 핵심 아이디어
 - AI 학습에 특화된 데이터베이스 VersaDB 제안
- 기존 방법과 다른 점
 - 저장 구조부터 random access, shuffle, 병렬 처리를 고려
- 핵심 구성
 - Page 기반 저장
 - Scalar / Blob 분리
 - Indexing
 - Sharding
 - Prefetch 및 병렬 처리
 - Compression / Cache

3. Experiments & Results

- 11개 데이터셋과 LMDB, TFRecord, Raw data 비교
- Reading, Shuffle Reading, Preprocessing 성능 평가
- 최대 5.35x 속도 향상
- 분산 환경에서 최대 40x speedup
- 여러 데이터셋에서 메모리 사용량도 크게 감소

4. Insight

- 핵심 기여
 - AI workload에 맞춘 저장 구조로 데이터 로딩 병목을 줄임
- 한계
 - 일부 ARM64 및 특정 데이터셋에서 성능·메모리 문제가 존재
- 가져갈 포인트
 - 데이터 로딩 최적화는 worker 증가만이 아니라 데이터 layout, indexing, caching, 병렬화를 함께 설계하는 것이 중요함.