

VISUAL PLANNING: LET'S THINK ONLY WITH IMAGES

<https://arxiv.org/abs/2505.11409>

1. Problem

- 기존 LLM/MLLM

- 대부분 텍스트 기반 추론- 공간적·기하학적 문제에서 비효율적- 인간은 이미지/스케치 기반으로 사고

핵심 질문

- 텍스트 없이도 추론이 가능한가?

2. Method

- 아이디어: 이미지 시퀀스를 통한 추론 (visual planning)- 텍스트 대신 이미지 흐름 자체가 reasoning 역할

학습 방식

- 강화학습 기반 (VPRL)- vision 모델을 planning에 맞게 최적화

차별점

- 기존: text-based reasoning

- 제안: visual-only reasoning

3. Experiments & Results

Task

- Maze- FrozenLake

- navigation/grid 환경

결과

- 텍스트 기반 방법 대비 성능 향상

- spatial planning에서 특히 효과적

해석

- 공간 문제에서는 visual representation이 더 적합

4. Insight

핵심 기여

- 추론은 반드시 텍스트일 필요 없음

의미

- 로봇 / navigation / embodied AI에 활용 가능

한계

- task 범위 제한적- 일반 reasoning 확장 불확실

Takeaway

- 공간 문제 → 이미지 기반 추론이 더 효율적