WaRP: Workload-Aware Request Planning for Vector Retrieval on Object Storage

https://arxiv.org/html/2610.29689v1

1\. Problem

- 해결하려는 문제: 객체 스토리지(S3) 기반 벡터 검색에서 잦은 작은 읽기 요청으로 인한 지연시간 및 API 비용 문제 해결 목적임
- 기존 방법의 한계: 고정된 요청 병합 기준으로는 다양한 워크로드에 최적으로 대응하기 어려움
- 중요성: 검색 정확도를 유지하면서 데이터 접근 속도와 스토리지 비용을 동시에 개선할 필요 있음

2\. Method

- 핵심 아이디어: 워크로드 특성에 맞춰 스토리지 읽기 요청을 동적으로 계획하고 병합하는 방식임
- 주요 메커니즘
  - Request Planning: 읽기 구간을 분석해 요청을 병합하고 요청 수와 처리시간 간 균형 최적화함
  - Adaptive Frontier Search: 동적 계획법 기반으로 근사 최적의 요청 계획을 탐색함
  - Payload Reordering: 함께 접근할 가능성이 높은 데이터를 물리적으로 가깝게 재배치해 불필요한 읽기 감소시킴
- 기존 방법과 차이: 고정 임계값 대신 워크로드 및 스토리지 지연 특성을 반영함
- 핵심 특징: ANN 검색 알고리즘이나 후보 벡터는 변경하지 않고 I/O 처리 방식만 최적화함

3\. Experiments & Results

- 실험 환경: AWS S3와 Lance 기반, 7개 데이터셋 평가. 최대 1억 개 벡터 사용함

- 주요 결과 — 기존 Lance 대비

지표	WaRP	WaRP + Reorder
QPS 개선	1.06~2.89배	1.09~3.48배
GET 요청 감소	1.14~2.60배	2.12~5.19배
Recall	기존 수준 유지	기존 수준 유지

- 플래너 실행시간은 쿼리당 약 0.5~2.2ms 수준임
- 최적화 플래너의 목적함수 오차는 평균 1.2% 미만임
- 요청 계획과 데이터 재배치를 함께 적용할 때 성능 개선 효과가 더 큼
- 주의점: 리전 간 데이터 전송 비용까지 고려하면 총비용이 증가할 가능성 있음

4\. Insight

- 핵심 기여: 벡터 검색의 정확도를 바꾸지 않고 원격 스토리지 I/O 계획을 최적화해 처리량과 비용을 개선함
- 한계점
  - AWS S3와 Lance 중심의 평가로 다른 환경에서의 일반화 여부는 추가 검증 필요함
  - 요청 병합 시 불필요한 데이터 읽기가 증가할 수 있음
  - 데이터 재배치 효과가 실제 접근 패턴의 지역성에 의존함
- 가져갈 포인트
  - 분산 시스템에서는 연산량뿐 아니라 네트워크·스토리지 요청 횟수 최적화도 중요함
  - 고정 임계값보다 워크로드 적응형 최적화가 유리할 수 있음
  - 성능 평가 시 QPS뿐 아니라 요청 수, 데이터 전송량, overfetch 및 총비용까지 함께 고려해야 함